因果噪声预测条件下的海洋声音分离 BS-RoFormer

匿名

摘要

常规海洋声音分离器只能从当前混合信号中估计持续变化的背景。本文研究一个严格因果的问题：根据过去声景预测当前期望背景，并将预测结果作为 BS-RoFormer 的条件，能否改善目标声源分离。系统编码历史三分之一倍频程声级（TOL），预测当前背景频谱，并将预测潜表示或显式预测频谱分别通过特征拼接、FiLM 调制和交叉注意力注入 BS-RoFormer 的子带 token；预测损失与分离损失联合优化。实验采用部署级时间隔离、配对 SI-SDR 统计、五档信号强度和实时因子评估。六类信号代理实验在 768 个配对样本上选择 FiLM；其相对无条件分离器的 SI-SDR 提升（SI-SDRi）增加 0.34 dB，且 JS 散度不能单独预测收益。随后使用 42 小时连续真实水听器录音，在固定 1 小时历史下比较 5 秒、30 秒、1 分钟和 10 分钟预测窗；只有学习预测在验证集优于 persistence 时才采用。四种尺度在 1024 个留出真实背景片段上均取得显著配对增益，5 秒最佳，为 +1.226 dB（95% 区间 $[1.082, 1.381]$），实时因子为 0.0024。只有 5 秒尺度的学习预测优于 persistence，说明时间条件有用，但复杂动态预测并非总是必要。

1 引言

被动声学背景会随航运、天气、生物活动和季节变化。只观察当前混合信号的分离器必须同时估计目标与背景。长时间声景预测提供了另一个严格因果的信息源：混合信号到达前，背景本应是什么样。本文假设该先验可能帮助分离器抑制可预测能量，同时保留意外出现的注入声源。

本文将 Band-Split RoPE Transformer（BS-RoFormer）[4] 与因果循环预测编码器结合。贡献包括：（1）可微的预测–分离联合模型；（2）拼接、FiLM、交叉注意力与无预测基线的匹配消融；（3）经泄漏审计的部署级划分；（4）同时报告分离质量、预测误差、统计不确定性、信号强度鲁棒性和计算可用性的评估协议；（5）包含六类信号，并按频谱偏移、源–背景重叠及频谱熵配对分析的广分布生成器；（6）四种子小时分辨率的连续真实录音实验；（7）可在本地试听和下载结果的前端。

2 数据与波形构造

我们使用 NOAA–Navy SanctSound 小时级 TOL 产品 [5]。MB03_01 与 MB03_02 用于训练，MB03_03 用于验证，MB03_04 为留出测试集。时刻 t 的样本只有在此前 H 小时及当前小时均有限且严格逐小时连续时才有效。归一化统计量仅由两个训练部署拟合。

公开 TOL 是聚合产品，无法确定波形相位。对当前频谱 S_t，我们在 FFT 频点上插值其 dB 包络，使用固定种子采样随机相位和类 Rayleigh 幅度抖动，逆 FFT 后归一化 RMS，得到背景代理 n_t。该代理保留粗粒度实测频谱包络，但不保留瞬态、相位或小时内事件，不能表述为恢复的现场原始音频。

现场实验直接使用对应的连续 8 kHz SanctSound 水听器录音：MB03_01、02、03 各 6 小时，以及连续 24 小时的 MB03_04 测试日，共 42 小时。先对 1 秒 Hann 周期图在 25–4000 Hz 的 23 个三分之一倍频程积分，再平均为 5 秒特征，并在功率域聚合为 30 秒、1 分钟或 10 分钟。该实验不合成任何背景波形相位。

原始注入信号 s_t 采用 MINUS 中的可控合成逻辑：谐波分音、带限噪声、起音/释音包络与低频幅度调制。广分布配置新增扫频、非谐波、多脉冲、调频与带限噪声，并放宽载频、调制、包络、瞬态及噪声占比范围。每个样本确定性地重采样信号族、参数和信号背景比。混合信号为 $x_t = n_t + s_t$，并通过共同缩放避免削波。

3 方法

令 $S_{t-H:t-1} \in \mathbb{R}^{H\times F}$ 为归一化历史 TOL。GRU 产生

$$z_t = \mathrm{LN}(\mathrm{GRU}(S_{t-H:t-1})), \tag{1}$$

$$\widehat{S}_t = g_\theta(z_t). \tag{2}$$

编码器只读取截止 $t-1$ 的观测。三种注入方案均令 $c_t = \widehat{S}_t$；基线删除预测器。

BS-RoFormer 将混合信号 STFT 频点变为子带 token $X \in \mathbb{R}^{B\times T\times K\times D}$。令 $P_k(c_t)$ 为逐子带投影，$E(c_t)$ 为预测频率箱 token 序列。我们在时间/频率 Transformer 之前比较三个残差注入算子：

$$\text{拼接：}\ \widetilde{X}_k = X_k + f([X_k; P_k(c_t)]), \tag{3}$$

$$\text{FiLM：}\ \widetilde{X}_k = (1+\tanh\gamma_k(c_t))\odot X_k + \beta_k(c_t), \tag{4}$$

$$\text{交叉注意力：}\ \widetilde{X} = X + \mathrm{Attn}(X, E(c_t), E(c_t)). \tag{5}$$

三条残差支路均初始化为零，使所有实验从相同音频映射开始。拼接先把局部特征宽度加倍再用 MLP 融合；FiLM 直接改变子带 token 的尺度与偏置；交叉注意力学习音频与预测频率箱之间的内容相关对齐。

端到端目标为

$$\mathcal{L} = \mathcal{L}_{\text{wave}} + \tfrac{1}{2}\sum_r \mathcal{L}_{\text{complex STFT},r} + \lambda\|\widehat{S}_t - S_t\|_1, \tag{6}$$

条件模型取 $\lambda = 0.2$。预测和分离损失均可反向更新预测编码器，因此这是联合训练，而不是冻结特征导出。

4 实验协议

所有方案共享样本、合成种子、优化器日程、模型宽度、分离器核心初始权重和检查点规则。验证 SI-SDRi 最高的检查点仅在 MB03_04 上评估一次。SI-SDR 采用尺度不变投影形式，SI-SDRi 为输出 SI-SDR 减去混合信号 SI-SDR。我们还报告残余海洋背景 SI-SDR、预测 MAE、实时因子（RTF）、参数量和配对胜率。区间使用固定种子的逐样本配对 bootstrap。盲源分离评估背景见 Vincent 等 [6]。

分布偏移计算先把波形功率汇聚到 $K = 64$ 个对数频率箱并归一化为 p，以原始窄谐波生成器 512 次采样的均值分布为 q。除方向性 $D_{\mathrm{KL}}(p\|q)$ 外，主指标采用有限且对称的 JS 散度 [3]：

$$D_{\mathrm{JS}}(p,q) = \tfrac{1}{2}D_{\mathrm{KL}}(p\|m) + \tfrac{1}{2}D_{\mathrm{KL}}(q\|m), \quad m = (p+q)/2. \tag{7}$$

由于“偏离旧生成器”不等于“信号更复杂”，还报告归一化频谱熵 $H(p)/\log_2 K$，以及源与海洋背景功率直方图交集 $\sum_k \min(p_k, n_k)$。

表 1：匹配的 2000 步广分布条件注入消融。

注入方式	验证 SI-SDRi (dB)	测试 SI-SDRi (dB)	配对 Δ_0 (dB)	参数量 (千)
无条件	4.96	5.00	0	231
特征拼接	5.17	5.30	+0.15	238
FiLM	**5.35**	**5.39**	**+0.34**	255
交叉注意力	4.99	5.11	+0.01	220

4.1 条件注入消融与选型

每个训练部署使用 4000 个样本，所有模型训练 2000 步，SNR 从 $[-12, 12]$ dB 均匀采样。选型只依据 MB03_03：FiLM 验证 SI-SDRi 为 5.35 dB，高于拼接的 5.17 dB 和交叉注意力的 4.99 dB。普通 256 样本 MB03_04 测试上三者分别为 5.39、5.30 和 5.11 dB，无条件模型为 5.00 dB。因此测试集确认了选择，但没有参与选择。

固定 0 dB 时，FiLM 相对相同无条件输出增加 0.34 dB（$[0.21, 0.48]$），拼接增加 0.15 dB（$[0.02, 0.27]$），交叉注意力增加 0.01 dB（$[-0.08, 0.10]$）。FiLM 与任务结构匹配：背景频谱天然指出哪些子带特征应衰减、放大或平移；其浅层乘加调制保留音频证据。拼接必须重新学习压缩加倍后的特征，交叉注意力则要从粗粒度小时频谱中估计对齐关系，其额外自由度在当前数据量下没有得到回报。这是与结果一致的机制解释，而非因果证明。

表 2：按注入信号强度分层（每档 128 个样本）。

输入 SNR (dB)	条件模型 SI-SDR (dB)	条件模型 SI-SDRi (dB)	基线 SI-SDRi (dB)
-12	-4.63	7.30	7.32
-6	1.00	6.95	6.78
0	5.85	5.81	5.40
+6	9.55	3.51	2.94
+12	11.94	-0.10	-0.70

在弱信号与等强度输入下，FiLM 至少改善 5.81 dB。输入为 +12 dB 时，混合信号已由目标主导，因此 SI-SDRi 接近零，但绝对目标 SI-SDR 仍为 11.94 dB。由此，不同输入强度不应共用单一改善阈值，而应同时检查改善量和绝对输出质量。

4.2 广分布信号实验

主分布实验固定输入 SNR 为 0 dB，每个信号族使用 128 个 MB03_04 留出样本，共 768 个；两个模型的海洋波形、源波形、时间戳和 SNR 完全配对。

全部样本上，基线为 5.36 dB，FiLM 为 5.70 dB，配对增益为 0.34 dB。条件增益与 JS 的相关系数为 -0.085；从最低 JS 五分位的 0.54 dB 降至最高五分位的 0.00 dB。因此，“与旧生成器距离越远，海洋先验越有用”的解释不成立。

频谱熵更有解释力。增益与熵的相关系数为 0.145；最高熵五分位提升 +0.80 dB（$[0.47, 1.17]$）。按信号族看，带限噪声提升 +0.54 dB（$[0.19, 0.92]$），脉冲列提升 0.47 dB（$[0.16, 0.79]$），调频信号提升 0.43 dB（$[0.08, 0.82]$）。

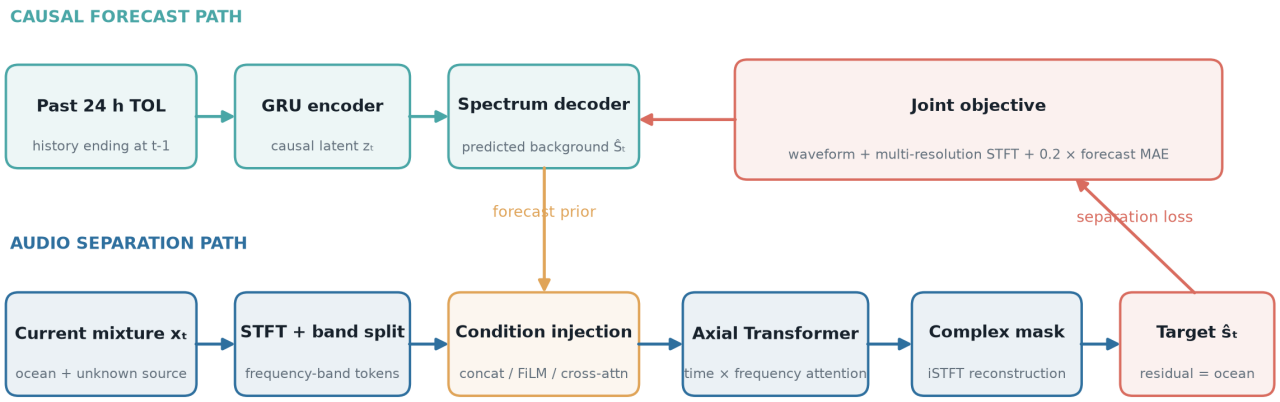


图 1: FC-BSR 架构。截止 $t-1$ 的历史 TOL 先预测当前海洋频谱，再通过拼接、FiLM 或交叉注意力注入 BS-RoFormer 子带 token。预测与分离损失联合训练；无条件基线删除预测路径。

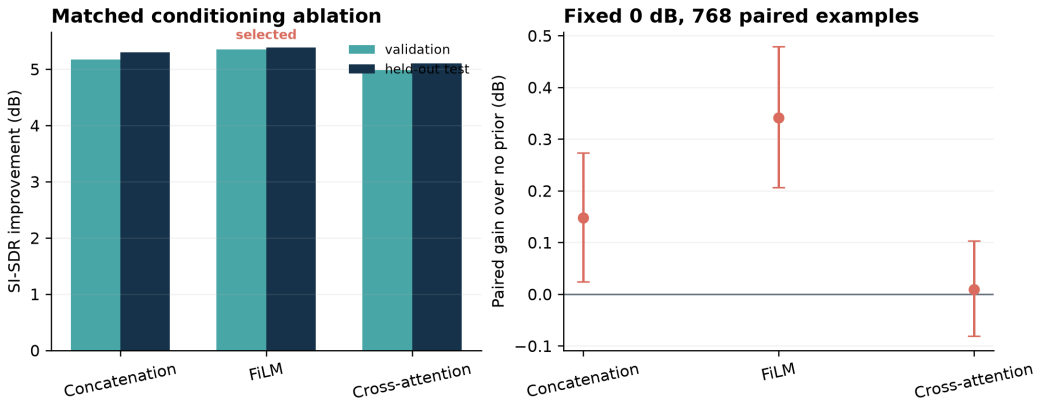


图 2: 匹配的条件注入消融。左图仅用 MB03_03 验证集选型；右图为 MB03_04 上固定 0 dB、768 个配对样本的相对无先验增益。FiLM 增益最大且区间排除零，交叉注意力则没有显著收益。

FiLM 因而在多类信号上利用了先验，对弥散目标收益最大；原始 JS/KL 距离并非决定变量。

5 子小时真实波形实验

子小时实验固定历史覆盖为 1 小时，对应 720、120、60 或 6 个因果历史步。对目标窗 t，模型只能读取 $S_{t-H:t-1}$，背景目标直接取真实波形 N_t。在该窗内注入广分布合成源，$x_t = N_t + \alpha s_t$，因此信号与噪声真值仍完全干净。四种分辨率共享绝对片段时刻与注入种子。

GRU 最多预训练 2500 步。由于短窗海洋频谱具有很强持续性，零残差初始化对应 step 0 的 persistence 预测；只有学习检查点降低 MB03_03 的预测 MAE 时才替换它。选中预测器后将其冻结，FiLM 分离器至少训练 3000 步、最多 5000 步，仅按 MB03_03 SI-SDRi 选择检查点，最后一次性在 MB03_04 评估。这样分离损失不能暗中破坏预测准确率。

四种条件模型均通过五档 SNR 工程门槛，RTF 均约为 0.0024。5 秒窗的绝对 SI-SDRi 与配对增益最高，但四组增益区间重叠，不能据此宣称分辨率排序具有显著性。更重要的负结论是：更复杂的预测不必然更有用。只有 5 秒验证 MAE 相对 persistence 改善 1.4%；10 分钟尺度仅有 60 个独立下一窗训练样本，GRU 明显过拟合。时间背景信息确实有用，但当前数据下多数信息由 persistence 即可提供。

6 真实事件上的无参考评估

真实事件录音没有隔离的目标和背景声轨，因此无法计算 SI-SDR。我们采用 DCLDE 2013 北大西洋露脊鲸

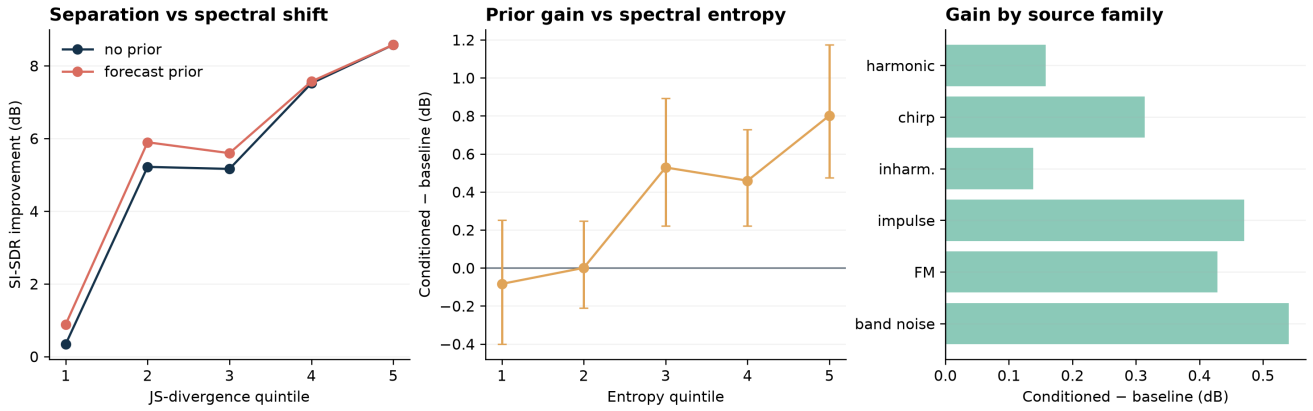


图 3: 0 dB 输入 SNR 下的广分布结果。左：随 JS 偏移五分位变化的 SI-SDRi；中：条件增益随频谱熵变化，误差线为配对 bootstrap 95% 区间；右：各信号族的 FiLM 增益，带限噪声、脉冲与调频信号收益最大。

表 3: 连续真实海洋录音上的子小时预测与分离。区间为 1024 个留出片段的配对 bootstrap 95% 区间。

窗口	历史步数	选中预测	验证 MAE (dB)	条件 SI-SDRi (dB)	基线 SI-SDRi (dB)	配对增益 (dB)	95% 区间 (dB)
5 秒	720	GRU，第 1600 步	1.366	**29.753**	28.527	**+1.226**	[1.082, 1.381]
30 秒	120	persistence	0.782	29.630	28.534	+1.095	[0.935, 1.265]
1 分钟	60	persistence	0.687	29.661	28.533	+1.128	[0.971, 1.298]
10 分钟	6	persistence	1.371	29.711	28.535	+1.176	[1.036, 1.326]

数据集 [1]：把连续 2 kHz 单声道 WAV 切成 8 秒片段，并按录音日而非片段划分。确定的上扫声标注构成正样本；负样本排除全部确定或可能事件及其前后 2 秒。平衡清单包含 5292 个训练、2696 个验证和 2676 个测试片段。只有干净的训练/验证背景会被加入局部合成上扫声来监督分离器。匹配条件实验为每个目标读取此前 8 个 8 秒、30 带频谱；文件开头不足 64 秒因果历史的片段从两组同时排除，最终留下 1225 个真实正测试片段，且它们都不参与检查点选择。残差 GRU 把验证 MAE 从 persistence 的 2.081 dB 降至 1.921 dB（改善 7.67%），随后冻结。BS-RoFormer 与 FC-BSR 共享样本、种子、迁移权重、2500 步预算和仅验证集选点规则；只有 FC-BSR 通过 FiLM 接收预测。两者受控验证 SI-SDRi 分别为 13.871 和 13.925 dB。

依据学习式无参考分离评价 [2] 和近期语义无参考指标 [7] 的思想，我们单独训练事件二分类器，在验证日做温度校准后冻结。其测试 AUROC、平均精度和 F1 分别为 0.9704、0.9738 和 0.9196。对分离器事件估计 $\hat{e}$，强制满足 $\hat{n} = x - \hat{e}$，再构造 $y_g = \hat{n} + 10^{g/20}\hat{e}$，其中 $g \in \{-60, -30, -24, -18, -12, -6, 0\}$ dB。可信输出应降低 $\hat{n}$ 的事件概率、让 $\hat{e}$ 保留事件证据、随 g 增大单调恢复判别概率，并尽量不改动标注区间外的样本。恒等输出（$\hat{e} = 0$）和全归事件（$\hat{e} = x$）用于排除投机解。

表 4: 1225 个真实事件上的匹配模型比较。箭头表示优选方向；两者均无真实分离真值。

方法	$p(x)$	$p(\hat{n})\downarrow$	$p(\hat{e})\uparrow$	单调率 ↑	区间外改动 ↓
BS-RoFormer	.855	.523	.901	.986	.0956
FC-BSR	.855	**.507**	.901	.985	.1022

FC-BSR 相对 BS-RoFormer 进一步把背景事件概率降低 0.0160；以三个录音日均值做配对 bootstrap，区间为 $[-0.0210, -0.0132]$。事件声轨概率差为 -0.00035（$[-0.00283, 0.00552]$），恢复单调率差为 -0.00109（$[-0.00342, 0.00265]$），均无法区分。更强抑制伴随小而一致的保真代价：区间外相对改动增加 0.00662（$[0.00331, 0.00781]$），标注区间外能量增加 0.0101（$[0.00310, 0.01574]$）。恒等输出与全归事件对照仍排除两种投机解：前者不删除任何事件，后者改动全部非事件音频。因此，预测先验在不降低事件声轨证据的情况下改善了真实事件的语义移除，但没有在所有保真指标上无条件获胜；该权衡只有联合报告语义与部分真值约束才可见。

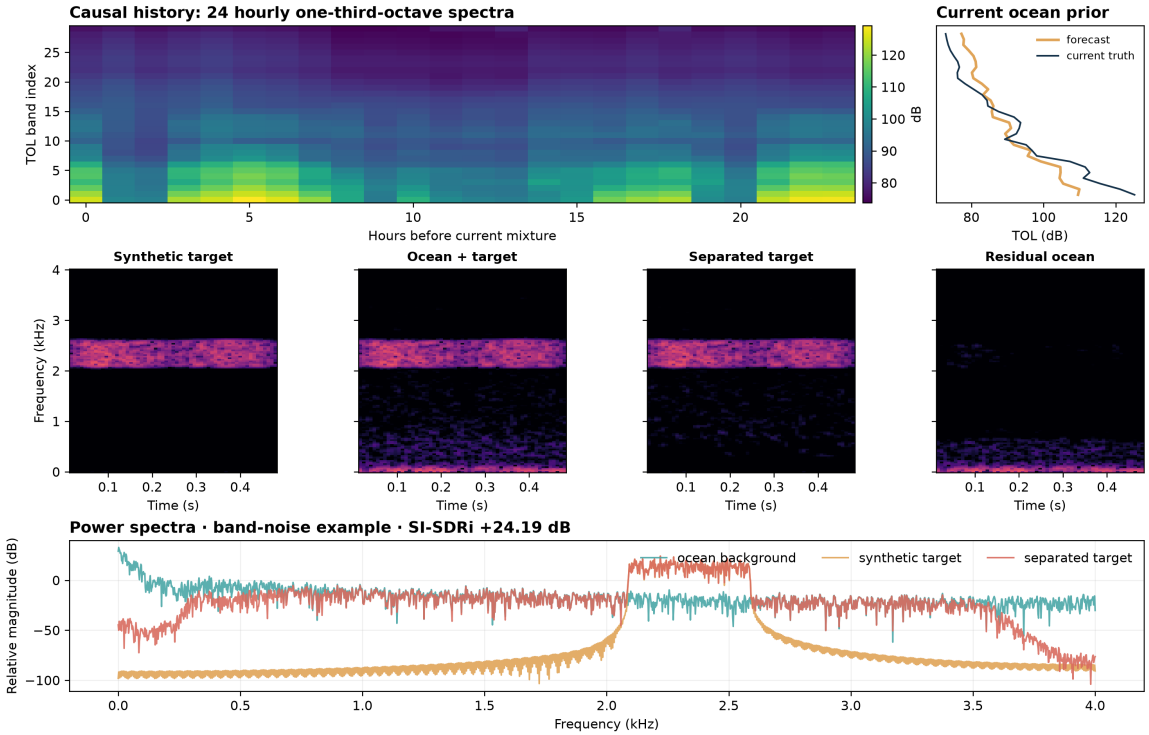


图 4: 一个有代表性的高熵带限噪声样本。上部为因果历史 TOL 与当前海洋频谱预测；中部为合成目标、混合、分离目标和残余海洋的时频图；下部叠加其功率谱。该例直观展示所选 FiLM 先验在保留弥散带目标的同时去除低频海洋能量。

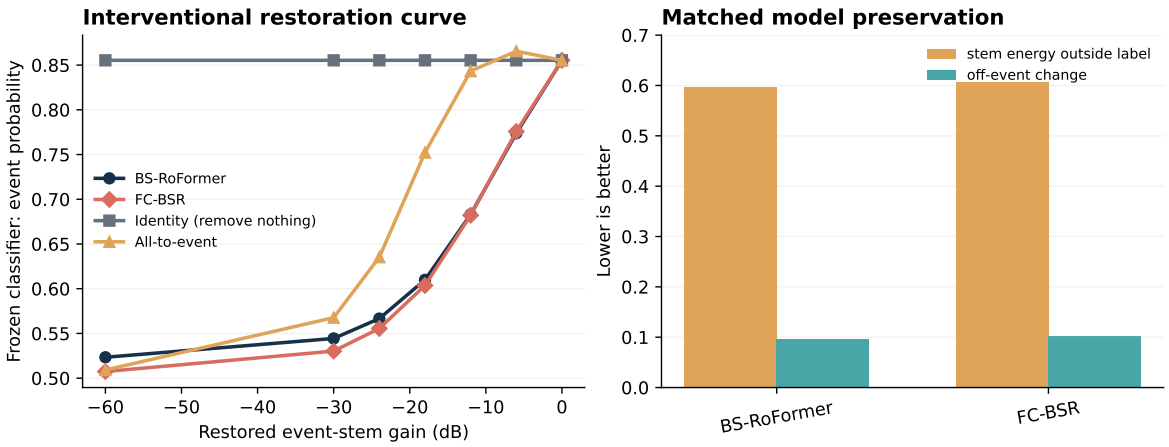


图 5: 没有分离真值的真实事件评估。左：FC-BSR 比匹配 BS-RoFormer 抑制事件略强，两者恢复曲线都近似单调；恒等输出和全归事件用于审计指标。右：更强的语义移除伴随小幅保真代价。

7 实用性判据

工程门槛要求：总体 SI-SDRi 不低于 5 dB；输入 SNR 不高于 0 dB 时改善至少 3 dB；更强输入的绝对目标 SI-SDR 不低于 8 dB；前端 RTF 小于 1。FiLM 通过全部四项。批量评估 RTF 为 0.0040；完整分块前端在 RTX 3060 上处理 10 秒 WAV 的 RTF 为 0.043。但科学假设只有在未见过的相位对齐录音上，条件模型相对无条件基线的配对 SI-SDRi 增益为正且 95% 区间排除零时才成立。代理实验满足该条件，现场音频仍待验证。

8 本地应用

仓库包含验证集选出的约 1 MB FiLM 检查点和不依赖前端框架的本地 Web 应用。用户上传最近 24 行小时级 TOL 与当前 WAV；应用校验并归一化历史、预测当前频谱、对重叠波形块执行分离，并提供目标信号和残余海洋背景的试听与下载。页面同时绘制预测频谱，展示时长、延迟与 RTF。所有请求都停留在 localhost，不会把录音或历史发送给远程服务。

9 局限性

真实波形实验消除了代理背景限制，但注入目标仍为合成信号，且全部录音来自同一站点。训练录音只有 12 小时；10 分钟尺度仅留下 60 个独立下一窗样本，不足以训练灵活 GRU。在提出部署结论前，还需加入多站点、多季节、多训练种子，以及真实船舶、生物和声呐目标。

六类合成信号显著扩展了原生成器，但 JS 散度与频谱熵仍只是频谱摘要，不能表达语义类别、长时结构和录音设备效应。信号族结论必须在真实船舶、生物、声呐、天气和人为事件上复验，才能用于生产模型选择。

10 结论

FC-BSR 给出了从声景预测到声音分离的具体、抗泄漏路径及可用本地界面。FiLM 从三种匹配注入机制中由验证集选出。在连续真实背景上，四种子小时先验均显著改善分离；5 秒尺度绝对得分最高，配对增益为 +1.226 dB。学习动态只有在 5 秒尺度优于 persistence，因此当前证据更强地支持“使用时间相关背景条件”，而不是“必须使用复杂预测器”。在没有隔离声轨的真实标注事件上，FC-BSR 相对匹配 BS-RoFormer 进一步降低了残余事件概率，同时保持事件声轨证据，但区间外改动略有增加。因此预测先验改善的是语义移除，而非所有保真指标；部署结论仍需要多站点、多季节和更强部分真值或完整真值。

参考文献

[1] Douglas Gillespie, Marjolaine Caillat, and Jonathan Gordon. DCLDE 2013 workshop dataset, 2019.

[2] Emad M. Grais, Hagen Wierstorf, Daniel Ward, Russell D. Mason, and Mark D. Plumbley. Referenceless performance evaluation of audio source separation using deep neural networks. In *27th European Signal Processing Conference (EUSIPCO)*, 2019.

[3] Jianhua Lin. Divergence measures based on the shannon entropy. *IEEE Transactions on Information Theory*, 37(1):145–151, 1991.

[4] Wei-Tsung Lu, Ju-Chiang Wang, Qiuqiang Kong, and Yun-Ning Hung. Music source separation with band-split RoPE transformer. *arXiv preprint arXiv:2309.02612*, 2023.

[5] NOAA Office of National Marine Sanctuaries and U.S. Navy. SanctSound raw passive acoustic data. NOAA

National Centers for Environmental Information dataset, 2020.

[6] Emmanuel Vincent, Rémi Gribonval, and Cédric Févotte. Performance measurement in blind audio source separation. *IEEE Transactions on Audio, Speech, and Language Processing*, 14(4):1462–1469, 2006.

[7] Xueyang Xiao, Haohe Jin, Zeyu Chen, Andreas Gram, Gordon Wichern, and Jonathan Le Roux. A reference-free metric for language-queried audio source separation using contrastive language-audio pretraining. In *Proceedings of the Detection and Classification of Acoustic Scenes and Events Workshop (DCASE)*, 2024.