因果噪声预测条件下的海洋声音分离 BS-RoFormer

匿名

摘要

常规海洋声音分离器只能从当前混合信号中估计持续变化的背景。本文研究一个严格因果的问题：根据过去声景预测当前期望背景，并将预测结果作为 BS-RoFormer 的条件，能否改善目标声源分离。系统编码历史三分之一倍频程声级（TOL），预测当前背景频谱，并将预测潜表示或显式预测频谱注入 BS-RoFormer 的子带 token；预测损失与分离损失联合优化。实验采用部署级时间隔离、三组消融、配对 SI-SDR 统计、五档信号强度和实时因子评估。由于公开数据只含小时级频谱而非相位对齐原始音频，当前实验使用随机相位背景代理。训练 1500 步后，频谱条件模型达到 5.74 dB SI-SDR 提升（SI-SDRi）并可实时运行，但匹配的无条件基线达到 6.02 dB。因此系统通过工程可用性门槛，但“预测条件优于直接训练”的科学假设未在收敛实验中得到支持。

1 引言

被动声学背景会随航运、天气、生物活动和季节变化。只观察当前混合信号的分离器必须同时估计目标与背景。长时间声景预测提供了另一个严格因果的信息源：混合信号到达前，背景本应是什么样。本文假设该先验可能帮助分离器抑制可预测能量，同时保留意外出现的注入声源。

本文将 Band-Split RoPE Transformer（BS-RoFormer）[1] 与因果循环预测编码器结合。贡献包括：（1）可微的预测–分离联合模型；（2）无预测、潜表示条件和频谱条件三组匹配消融；（3）经泄漏审计的部署级划分；（4）同时报告分离质量、预测误差、统计不确定性、信号强度鲁棒性和计算可用性的评估协议；（5）可在本地试听和下载结果的前端。

2 数据与波形构造

我们使用 NOAA–Navy SanctSound 小时级 TOL 产品 [2]。MB03_01 与 MB03_02 用于训练，MB03_03 用于验证，MB03_04 为留出测试集。时刻 t 的样本只有在此前 H 小时及当前小时均有限且严格逐小时连续时才有效。归一化统计量仅由两个训练部署拟合。

公开 TOL 是聚合产品，无法确定波形相位。对当前频谱 S_t，我们在 FFT 频点上插值其 dB 包络，使用固定种子采样随机相位和类 Rayleigh 幅度抖动，逆 FFT 后归一化 RMS，得到背景代理 n_t。该代理保留粗粒度实测频谱包络，但不保留瞬态、相位或小时内事件，不能表述为恢复的现场原始音频。

注入信号 s_t 采用 MINUS 中的可控合成逻辑：谐波分音、带限噪声、起音/释音包络与低频幅度调制。每个样本确定性地重采样参数和信号背景比。混合信号为 $x_t = n_t + s_t$，并通过共同缩放避免削波。

3 方法

令 $S_{t-H:t-1} \in \mathbb{R}^{H\times F}$ 为归一化历史 TOL。GRU 产生

$$z_t = \mathrm{LN}(\mathrm{GRU}(S_{t-H:t-1})), \tag{1}$$

$$\widehat{S}_t = g_\theta(z_t). \tag{2}$$

编码器只读取截止 $t-1$ 的观测。潜表示方案令 $c_t = z_t$；频谱方案令 $c_t = \widehat{S}_t$；基线输入全零条件并删除预测器。

BS-RoFormer 将混合信号 STFT 频点变为子带 token $X \in \mathbb{R}^{B\times T\times K\times D}$。本文不把无结构向量拼到音频上，而是学习逐子带条件偏置：

$$\widetilde{X}_{:,\tau,k,:} = X_{:,\tau,k,:} + [\mathrm{Linear}(\mathrm{LN}(c_t))]_{k,:}. \tag{3}$$

条件 token 随后进入原始时间/频率 Transformer 和复数掩码估计器。这样每个时间帧共享预测先验，同时保留频率相关作用。

端到端目标为

$$\mathcal{L} = \mathcal{L}_{\text{wave}} + \tfrac{1}{2}\sum_r \mathcal{L}_{\text{complex STFT},r} + \lambda\|\widehat{S}_t - S_t\|_1, \tag{4}$$

条件模型取 $\lambda = 0.2$。预测和分离损失均可反向更新预测编码器，因此这是联合训练，而不是冻结特征导出。

4 实验协议

所有方案共享样本、合成种子、优化器日程、模型宽度、分离器核心初始权重和检查点规则。验证 SI-SDRi 最高的检查点仅在 MB03_04 上评估一次。SI-SDR 采用尺度不变投影形式，SI-SDRi 为输出 SI-SDR 减去混合信号 SI-SDR。我们还报告残余海洋背景 SI-SDR、预测 MAE、实时因子（RTF）、参数量和配对胜率。区间使用固定种子的逐样本配对 bootstrap。盲源分离评估背景见 Vincent 等 [3]。

表 1：匹配的 1500 步、256 个代理测试样本结果。

条件	SI-SDRi (dB)	相对基线 (dB)	预测 MAE (dB)	RTF
无条件 BS-RoFormer	6.02	0	–	.0023
预测频谱	5.74	-0.28	3.43	.0024

4.1 收敛训练与基线

实用模型含 234,848 个参数，训练 1500 步；每个训练部署取 4000 个样本，信号背景比从 $[-12, 12]$ dB 均匀采样。频谱条件模型达到 5.74 dB SI-SDRi（95% 区间 $[5.04, 6.47]$）、5.97 dB 残余海洋 SI-SDR 和 3.43 dB 预测 MAE。匹配的直接 BS-RoFormer 达到 6.02 dB SI-SDRi。条件模型相对基线的配对差为 -0.28 dB （$[-0.69, 0.14]$），逐样本胜率为 35.9%。早期 300 步实验曾出现 +0.39 dB 条件增益；该优势在匹配长训练后消失，说明短跑结果不能支持科学主张。

表 2：按注入信号强度分层（每档 128 个样本）。

输入 SNR (dB)	条件模型 SI-SDR (dB)	条件模型 SI-SDRi (dB)	基线 SI-SDRi (dB)
-12	-5.49	6.55	6.44
-6	0.32	6.32	7.05
0	5.75	5.73	6.55
+6	9.77	3.74	4.37
+12	11.89	-0.14	-0.26

在弱信号与等强度输入下，条件模型至少改善 5.73 dB。输入为 +12 dB 时，混合信号已由目标主导，因此 SI-SDRi 接近零，但绝对目标 SI-SDR 仍为 11.89 dB。由此，不同输入强度不应共用单一改善阈值，而应同时检查改善量和绝对输出质量。

5 实用性判据

工程门槛要求：总体 SI-SDRi 不低于 5 dB；输入 SNR 不高于 0 dB 时改善至少 3 dB；更强输入的绝对目标 SI-SDR 不低于 8 dB；前端 RTF 小于 1。条件模型通过全部四项。批量评估 RTF 为 0.0024；完整分块前端在 RTX 3060 上处理 10 秒 WAV 的 RTF 为 0.043。但科学假设只有在未见过的相位对齐录音上，条件模型相对无条件基线的配对 SI-SDRi 增益为正且 95% 区间排除零时才成立。当前长训练结果不满足这一要求。

6 本地应用

仓库包含约 1 MB 的检查点和不依赖前端框架的本地 Web 应用。用户上传最近 24 行小时级 TOL 与当前 WAV；应用校验并归一化历史、预测当前频谱、对重叠波形块执行分离，并提供目标信号和残余海洋背景的试听与下载。页面同时绘制预测频谱，展示时长、延迟与 RTF。所有请求都停留在 localhost，不会把录音或历史发送给远程服务。

7 局限性

小时级 TOL 删除了相位和小时内时间结构。随机相位代理可能使频谱先验过于直接，并低估真实海洋复杂度。因此当前实验只证明实现正确性和受控代理条件下的行为。决定性实验需要时间对齐的 MB03 原始水听器音频；历史特征不得跨越测试边界；留出波形与相同种子的目标混合；所有选择在 MB03_03 固定；MB03_04 只评估一次。届时还需报告多训练种子和按 SNR 分层的区间。

8 结论

FC-BSR 给出了从声景预测到声音分离的具体、抗泄漏路径及可用本地界面。频谱条件模型在宽强度范围的代理基准上达到声明的工程门槛，但没有超过匹配的长训练 BS-RoFormer 基线。因此，本仓库是可运行的原型和可证伪的研究结果，而不是预测条件已改善现场录音分离的证据。

参考文献

[1] Wei-Tsung Lu, Ju-Chiang Wang, Qiuqiang Kong, and Yun-Ning Hung. Music source separation with band-split RoPE transformer. *arXiv preprint arXiv:2309.02612*, 2023.

[2] NOAA Office of National Marine Sanctuaries and U.S. Navy. SanctSound raw passive acoustic data. NOAA National Centers for Environmental Information dataset, 2020.

[3] Emmanuel Vincent, Rémi Gribonval, and Cédric Févotte. Performance measurement in blind audio source separation. *IEEE Transactions on Audio, Speech, and Language Processing*, 14(4):1462–1469, 2006.