因果预测条件下的海洋声音分离 BS-RoFormer

匿名作者
匿名单位

***Abstract*—**本文研究：在混合声音到达之前，仅由历史声景因果预测的海洋背景，能否帮助分离突发声学事件。**FC-BSR** 从此前的三分之一倍频程谱预测当前背景，并通过特征拼接、特征线性调制（**FiLM**）或交叉注意力注入 **BS-RoFormer**。三级实验把机理选择与真实场景证据分开：在有精确合成声轨时，**FiLM** 相对无条件分离器提高 **0.34 dB SI-SDRi**；在 **42** 小时连续真实水听器背景与注入目标上，**5** 秒至 **10** 分钟的四种因果先验均有收益，**5** 秒窗提高 **1.226 dB**，但三个尺度的最佳预测仍是 **persistence**；在没有隔离声轨的 **1225** 个真实鲸声事件上，**FC-BSR** 相对匹配的 **BS-RoFormer** 将残余事件概率从**.523** 降至**.507**，同时区间外改动略有增加。结果支持预测条件的价值，但尚不支持无条件的保真度或部署结论。

***Index Terms*—**海洋声学，源分离，声景预测，**BS-RoFormer**，无参考评估

I. 引言

海洋背景随航运、天气、生物活动和季节变化 [1]。传统分离器需要从同一混合声音中同时推断目标与变化背景。本文改为提供一个严格因果的先验：只使用混合声音到达前的观测，估计此时应出现的背景频谱。科学问题写为

$$S_{t-H:t-1} \xrightarrow{P_\psi} \widehat{S}_t, \qquad x_t = N_t + \alpha s_t \xrightarrow{F_\phi(\cdot|\widehat{S}_t)} (\hat{s}_t, \hat{N}_t). \quad (1)$$

模型从不观察当前干净背景 N_t。

Conv-TasNet 与 DPRNN 等时域模型 [2], [3]、SepFormer 与 TF-GridNet 等注意力模型 [4], [5] 以及子带模型 [6], [7] 提供了强大的仅混合输入骨干；混合 Transformer [8] 与 MixIT [9] 分别扩展了架构和无隔离声轨训练。这些工作均未把下一时刻背景的预测作为条件。FiLM [10]、交叉注意力 [11] 和跨模态分离 [12] 给出三种候选接口；DeepAR、N-BEATS、DLinear 与 PatchTST 则覆盖递归、基展开、线性和分块预测 [13]–[16]。

本文贡献为：（1）FC-BSR，[1]一种带三种匹配条件消融的因果预测条件 BS-RoFormer；（2）从完整真值代理背景、真实背景到真实事件的防泄漏分层评估；（3）不同信号强度、信号分布和 5 秒、30 秒、1 分钟、10 分钟尺度的实验；（4）在真实事件上直接比较 FC-BSR 与无条件 BS-RoFormer 的无参考检验。

II. 方法

A. 背景预测与分离

历史三分之一倍频程声级（TOL）$S_{t-H:t-1} \in \mathbb{R}^{H\times F}$ 只用训练集统计量归一化。残差 GRU 预测

$$z_t = \mathrm{LN}(\mathrm{GRU}(S_{t-H:t-1})), \quad \widehat{S}_t = S_{t-1} + g_\psi(z_t). \quad (2)$$

残差零初始化精确表示 persistence；只有当验证 MAE 优于该基线时才保留学习式预测，符合点预测的规范比较 [17]。

[1]代码与复现实验说明：https://github.com/D-eval/ocean_noise_pred_splite。

BS-RoFormer 将混合 STFT 映射为子带 token X_k。在轴向 Transformer 前的相同位置比较

$$\begin{aligned} \text{拼接：}\ & \widetilde{X}_k = X_k + f([X_k; P_k(\widehat{S}_t)]), \\ \text{FiLM：}\ & \widetilde{X}_k = (1+\tanh\gamma_k)\odot X_k + \beta_k, \\ \text{交叉注意力：}\ & \widetilde{X} = X + \mathrm{Attn}(X, E(\widehat{S}_t), E(\widehat{S}_t)). \end{aligned} \quad (3)$$

残差分支从零开始，使各模型拥有相同的初始音频映射。损失由波形 L_1、多分辨率复数 STFT 损失组成；仅代理背景实验加入 $0.2\|\widehat{S}_t - S_t\|_1$。真实波形实验先按验证预测误差选出预测器并冻结，再训练分离器。

B. 数据与证据层级

第一层使用 NOAA–Navy SanctSound 小时级 TOL 产品 [18]。MB03 部署 01–02/03/04 分别为训练/验证/测试集。随机相位逆变换仅产生受控频谱代理，不能称为还原音频。目标包含谐波、啁啾、非谐波与 FM 音调、脉冲和带限噪声。分布位移用 Jensen–Shannon（JS）散度 [19]，另以频谱熵描述弥散程度。

第二层直接使用 42 小时连续 8-kHz 水听器 WAV，其中 12/6/24 小时用于训练/验证/测试。一秒周期图聚合为 23 个 TOL 频带和 5 秒、30 秒、1 分钟、10 分钟窗口。下一个真实背景波形 N_t 叠加合成目标，因此仍有精确参考；每种尺度都覆盖一小时因果历史。

第三层使用按日期隔离的 2-kHz DCLDE 2013 露脊鲸录音 [20]。强事件标注可支持检测 [21]，但不存在隔离的事件/背景声轨。仅在干净训练窗口中注入合成 upcall；1225 个未修改的真实阳性片段只用于测试。两种模型共享样本、随机种子、初始权重、2500 步预算与仅验证集选点规则。

C. 实验协议与指标

全部比较在波形层面严格配对：混合时刻、目标抽样、SNR、随机种子、分离器骨干初始权重、优化器日程和检查点规则均相同。部署 03 负责全部选型，部署 04 只评估一次。连续音频按时间划分，DCLDE 按录音日划分，重叠窗口不能跨集合。特征归一化只用训练录音拟合，历史编码器严格截止于 $t-1$。

有完整参考的两层报告 SI-SDR、相对输入混合的改善、残余背景 SI-SDR、预测 MAE、参数量和实时因子（RTF）。SI-SDR 采用尺度不变投影而非原始 BSS Eval 分解 [22], [23]。不确定性由测试片段上的固定种子配对 bootstrap 给出。多样性实验固定输入 SNR 为 0 dB，每个信号族取 128 个严格配对样本，避免强度混淆形状。本文同时报告方向性 $D_{\mathrm{KL}}(p\|q)$ 与有限对称的 JS 散度，但只把它们解释为频谱位移，而不是语义多样性。

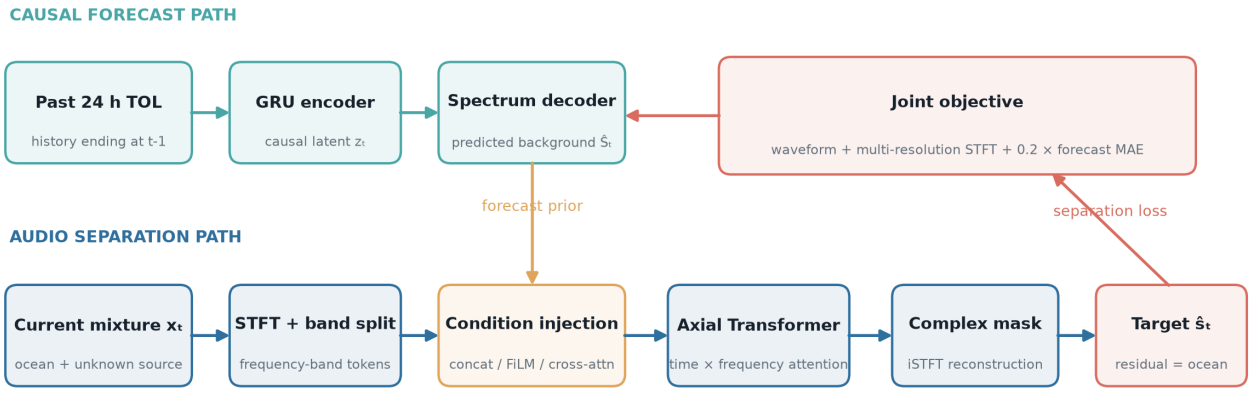


Fig. 1. FC-BSR 架构。因果历史预测当前背景频谱，先验通过拼接、FiLM 或交叉注意力进入同一个 BS-RoFormer 骨干；无条件基线移除蓝色预测路径。

TABLE I
匹配的条件注入消融（dB）。

注入方式	验证 SI-SDRi	测试 SI-SDRi	配对 Δ_0
无条件	4.96	5.00	0
拼接	5.17	5.30	+0.15
FiLM	**5.35**	**5.39**	**+0.34**
交叉注意力	4.99	5.11	+0.01

III. 实验与结果

A. 受控选型与信号分布

第一层各模型每个训练部署使用 4000 个样本、训练 2000 步，SNR 从 $[-12, 12]$ dB 均匀抽样。表 I 只按验证集选择 FiLM；其 0-dB 配对增益为 0.34 dB（95% bootstrap 区间 $[0.21, 0.48]$）。逐频带缩放与偏置可直接表达“此处是预期能量”；拼接需要压缩加倍特征，而交叉注意力需要从粗频谱中学习对齐。

在输入 SNR 为 $-12, -6, 0, +6, +12$ dB 时，FiLM 的 SI-SDRi 依次为 $7.30, 6.95, 5.81, 3.51, -0.10$ dB；+12 dB 时绝对 SI-SDR 仍为 11.94 dB。在 768 个严格配对、固定 0-dB 样本上，FiLM 将 5.36 提高到 5.70 dB。增益与 JS 位移相关性很弱（-0.085），但与频谱熵正相关（0.145），最高熵五分位增益 0.80 dB。因此 KL/JS 能扩大覆盖范围，却不能单独预测先验何时有效。图 2 展示弥散目标的历史、当前谱、混合与分离频谱。

分族结果支持上述解释：带限噪声增益 0.54 dB（$[0.19, 0.92]$），脉冲列 0.47 dB（$[0.16, 0.79]$），FM 目标 0.43 dB（$[0.08, 0.82]$）。相反，增益从最低 JS 五分位的 0.54 dB 降到最高五分位的 0.00 dB。更大散度扩展了测试覆盖，却不保证收益；与可预测海洋频带的重叠及源内弥散程度更可能解释条件先验何时有效。

B. 连续真实背景

预测器最多训练 2500 步，分离器训练 3000–5000 步。表 II 每种尺度含 1024 个配对留出片段。所有置信区间均不含零，但彼此重叠。只有 5 秒选择学习式 GRU（MAE

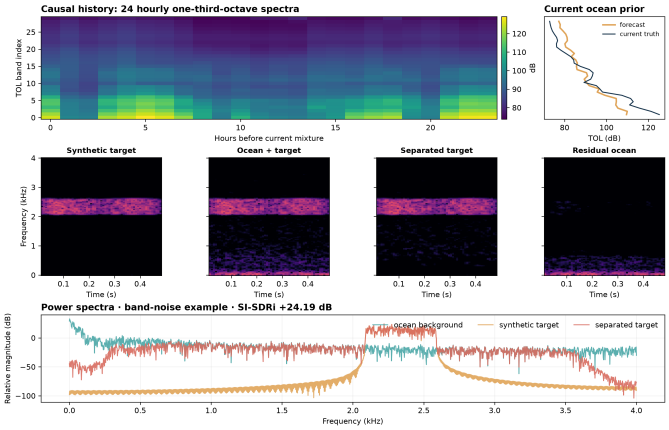


Fig. 2. 高熵目标示例：历史/预测频谱、混合与分离时频图及频谱叠加。

TABLE II
真实背景的完整参考结果。

窗口	预测器	条件模型	基线	增益 [95% 区间]
5 秒	GRU	29.753	28.527	1.226 [1.082,1.381]
30 秒	persistence	29.630	28.534	1.095 [0.935,1.265]
1 分钟	persistence	29.661	28.533	1.128 [0.971,1.298]
10 分钟	persistence	29.711	28.535	1.176 [1.036,1.326]

条件模型、基线与增益均为 SI-SDRi（dB）。

比 persistence 低 1.4%）；30 秒、1 分钟、10 分钟都选择 persistence。时间相关背景有用，但现有数据不能证明复杂动态预测普遍必要。

从 5 秒到 10 分钟的验证 MAE 依次为 1.366、0.782、0.687、1.371 dB。10 分钟训练集只有 60 个不同的下一窗口目标，因而预测器严重过拟合。四个分离器均通过五档 SNR 工程门槛，RTF 约为.0024。因此，正面结论是时间相关条件有价值，而不是已显著排定时间分辨率优劣，或证明 GRU 普遍胜过 persistence。

TABLE III
1225 个真实事件上的匹配比较。

方法	$p(\hat{N}) \downarrow$	$p(\hat{s}) \uparrow$	单调率 ↑	区间外 ↓
BS-RoFormer	.523	.901	.986	**.0956**
FC-BSR	**.507**	.901	.985	.1022

C. 没有分离真值的真实事件

由于没有隔离声轨，完整参考指标不可用。参考学习式无参考指标 [24], [25] 及语义音频嵌入 [26], [27]，我们训练、校准并冻结二分类器（测试 AUROC .9704）。令 $\hat{N} = x - \hat{s}$ 保证混合一致性，再将 $\hat{s}$ 从 -60 dB 逐级恢复到 0 dB，并要求事件概率单调恢复。Identity 与 all-to-event 对照排除平凡解，标注区间外相对变化检验背景保留。

分类器的平衡清单含 5292/2696/2676 个训练/验证/测试片段；确定 upcall 为阳性，阴性排除确定与可能 call 及其 2 秒边界。测试平均精度为.9738，F1 为.9196。每个合格目标只接收此前八个 8 秒、30 频带频谱。残差 GRU 将验证预测 MAE 从 2.081 降到 1.921 dB，随后冻结。在任何模型接触真实事件测试集前，BS-RoFormer 与 FC-BSR 的受控验证 SI-SDRi 分别为 13.871 与 13.925 dB。

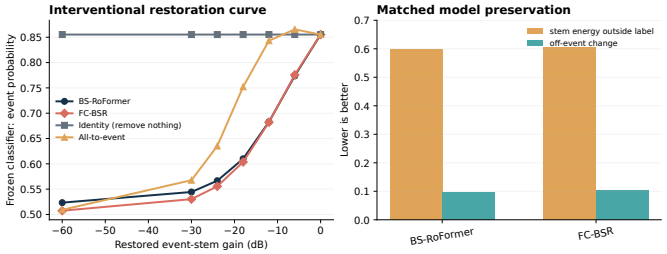


Fig. 3. 无参考恢复曲线（左）与背景保留审计（右）。FC-BSR 抑制事件更强，但区间外改动更多。

FC-BSR 将残余事件概率再降低.0160；按三个录音日均值配对 bootstrap 得 $[-.0210, -.0132]$。事件声轨概率与单调率在不确定性内不变，但区间外改动增加.00662 ($[.00331, .00781]$)。因此预测条件相对匹配 BS-RoFormer 改善了语义移除，同时付出小幅背景保留代价。

恢复增益集合为 $\{-60, -30, -24, -18, -12, -6, 0\}$ dB。Identity（$\hat{s} = 0$）保留原事件概率，all-to-event（$\hat{s} = x$）则破坏背景，说明任何单一分类器分数都不足以评估分离。事件声轨概率只变化 $-.00035$（$[-.00283, .00552]$），单调率变化 $-.00109$（$[-.00342, .00265]$）；但标注区间外能量增加.0101（$[.00310, .01574]$）。这些局部真值检验排除了明显的语义投机，却不能识别事件区间内的相位或波形失真。

IV. 讨论与结论

证据支持的是逐层嵌套结论：完整真值实验选择 FiLM；真实背景实验确认四种子小时尺度的因果先验均有效；真实事件实验说明它在无条件 BS-RoFormer 之上有语义收益。但学习式预测并非普遍更好，因为四个尺度中有三个选择 persistence；分类器指标也无法恢复缺失的波形保真真值。后续仍需多站点、多季节、更多 10 分钟训练目标、多随机种子，以及隔离声轨或更强的局部参考。

这一顺序也约束了解释。第一层可识别条件机制，但使用相位合成背景；第二层去掉该假设，同时保留合成目标与精确声轨；第三层去掉合成测试目标，却必然失去完整参考保真指标。跨层一致性强于任何单一结果，但各层指标不能互换，尤其不能把分类器事件移除当作 SI-SDR 的替代品。

模型通过实用门槛：总体 SI-SDRi 至少 5 dB，SNR ≤ 0 dB 时改善至少 3 dB，强信号绝对 SI-SDR 至少 8 dB，实时因子低于 1。本地前端可接收因果 TOL 历史与 WAV，显示预测结果，并试听/ 下载目标与残余背景；RTX 3060 上 10 秒分块处理 RTF 为.043。这说明系统已适合实验检查，但仍需明确区分工程可用与野外部署。

References

[1] J. L. Miksis-Olds, D. L. Bradley, and X. M. Niu, "Decadal trends in indian ocean ambient sound," *Journal of the Acoustical Society of America*, vol. 134, no. 5, pp. 3464–3475, 2013.

[2] Y. Luo and N. Mesgarani, "Conv-TasNet: Surpassing ideal time–frequency magnitude masking for speech separation," *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, vol. 27, no. 8, pp. 1256–1266, 2019.

[3] Y. Luo, Z. Chen, and T. Yoshioka, "Dual-path RNN: Efficient long sequence modeling for time-domain single-channel speech separation," in *Proc. IEEE ICASSP*, 2020, pp. 46–50.

[4] C. Subakan, M. Ravanelli, S. Cornell, M. Bronzi, and J. Zhong, "Attention is all you need in speech separation," in *Proc. IEEE ICASSP*, 2021, pp. 21–25.

[5] Z.-Q. Wang, S. Cornell, S. Choi, Y. Lee, B.-Y. Kim, and S. Watanabe, "TF-GridNet: Integrating full- and sub-band modeling for speech separation," in *Proc. IEEE ICASSP*, 2023, pp. 1–5.

[6] Y. Luo and J. Yu, "Music source separation with band-split RNN," *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, vol. 31, pp. 1893–1901, 2023.

[7] W.-T. Lu, J.-C. Wang, Q. Kong, and Y.-N. Hung, "Music source separation with band-split RoPE transformer," *arXiv preprint arXiv:2309.02612*, 2023. [Online]. Available: https://arxiv.org/abs/2309.02612

[8] S. Rouard, F. Massa, and A. Défossez, "Hybrid transformers for music source separation," in *Proc. IEEE ICASSP*, 2023, pp. 1–5.

[9] S. Wisdom, E. Tzinis, H. Erdogan, R. J. Weiss, K. Wilson, and J. R. Hershey, "Unsupervised sound separation using mixture invariant training," in *Advances in Neural Information Processing Systems*, vol. 33, 2020, pp. 3846–3857.

[10] E. Perez, F. Strub, H. de Vries, V. Dumoulin, and A. Courville, "FiLM: Visual reasoning with a general conditioning layer," in *Proc. AAAI Conference on Artificial Intelligence*, vol. 32, no. 1, 2018.

[11] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, "Attention is all you need," in *Advances in Neural Information Processing Systems*, vol. 30, 2017.

[12] H. Zhao, C. Gan, A. Rouditchenko, C. Vondrick, J. McDermott, and A. Torralba, "The sound of pixels," in *Proc. European Conference on Computer Vision*, 2018, pp. 570–586.

[13] D. Salinas, V. Flunkert, J. Gasthaus, and T. Januschowski, "DeepAR: Probabilistic forecasting with autoregressive recurrent networks," *International Journal of Forecasting*, vol. 36, no. 3, pp. 1181–1191, 2020.

[14] B. N. Oreshkin, D. Carpov, N. Chapados, and Y. Bengio, "N-BEATS: Neural basis expansion analysis for interpretable time series forecasting," in *International Conference on Learning Representations*, 2020.

[15] A. Zeng, M. Chen, L. Zhang, and Q. Xu, "Are transformers effective for time series forecasting?" in *Proc. AAAI Conference on Artificial Intelligence*, vol. 37, no. 9, 2023, pp. 11 121–11 128.

[16] Y. Nie, N. H. Nguyen, P. Sinthong, and J. Kalagnanam, "A time series is worth 64 words: Long-term forecasting with transformers," in *International Conference on Learning Representations*, 2023.

[17] T. Gneiting, "Making and evaluating point forecasts," *Journal of the American Statistical Association*, vol. 106, no. 494, pp. 746–762, 2011.

[18] NOAA Office of National Marine Sanctuaries and U.S. Navy, "SanctSound raw passive acoustic data," NOAA NCEI dataset, 2020.

[19] J. Lin, "Divergence measures based on the shannon entropy," *IEEE Transactions on Information Theory*, vol. 37, no. 1, pp. 145–151, 1991.

[20] D. Gillespie, M. Caillat, and J. Gordon, "DCLDE 2013 workshop dataset," 2019.

[21] Y. Shiu, K. J. Palmer, M. A. Roch, E. Fleishman, X. Liu, E.-M. Nosal, T. Helble, D. Cholewiak, D. Gillespie, and H. Klinck, "Deep neural networks for automated detection of marine mammal species," *Scientific Reports*, vol. 10, p. 607, 2020.

[22] E. Vincent, R. Gribonval, and C. Févotte, "Performance measurement in blind audio source separation," *IEEE Transactions on Audio, Speech, and Language Processing*, vol. 14, no. 4, pp. 1462–1469, 2006.

[23] J. Le Roux, S. Wisdom, H. Erdogan, and J. R. Hershey, "SDR—half-baked or well done?" in *Proc. IEEE ICASSP*, 2019, pp. 626–630.

[24] K. Kilgour, M. Zuluaga, D. Roblek, and M. Sharifi, "Fréchet audio distance: A reference-free metric for evaluating music enhancement algorithms," in *Proc. Interspeech*, 2019, pp. 2350–2354.

[25] E. M. Grais, H. Wierstorf, D. Ward, R. D. Mason, and M. D. Plumbley, "Referenceless performance evaluation of audio source separation using deep neural networks," in *Proc. European Signal Processing Conference*, 2019.

[26] Y. Wu, K. Chen, T. Zhang, Y. Hui, M. Nezhurina, T. Berg-Kirkpatrick, and S. Dubnov, "Large-scale contrastive language–audio pretraining with feature fusion and keyword-to-caption augmentation," in *Proc. IEEE ICASSP*, 2023, pp. 1–5.

[27] X. Xiao, H. Jin, Z. Chen, A. Gram, G. Wichern, and J. Le Roux, "A reference-free metric for language-queried audio source separation using contrastive language–audio pretraining," in *Proc. DCASE Workshop*, 2024.