# 因果噪声预测条件下的海洋声音分离 BS-RoFormer

匿名


## 摘要

常规海洋声音分离器只能从当前混合信号中估计持续变化的背景。本文研究一个严格因果的问题：根据过去声景预测当前期望背景，并将预测结果作为 BS-RoFormer 的条件，能否改善目标声源分离。系统编码历史三分之一倍频程声级（TOL），预测当前背景频谱，并将预测潜表示或显式预测频谱分别通过特征拼接、FiLM 调制和交叉注意力注入 BS-RoFormer 的子带 token；预测损失与分离损失联合优化。实验采用部署级时间隔离、配对 SI-SDR 统计、五档信号强度和实时因子评估。由于公开数据只含小时级频谱而非相位对齐原始音频，当前实验使用随机相位背景代理。本文进一步将目标生成器扩展到六类信号，并用 Jensen–Shannon（JS）散度、KL 散度和频谱熵度量分布变化。在 768 个广分布配对样本上，验证集选择 FiLM；其相对无条件分离器的 SI-SDR 提升（SI-SDRi）增加 0.34 dB （配对 95% 区间 $[0.21, 0.48]$）。拼接增加 0.15 dB，交叉注意力则与零不可区分。JS 散度不能单独预测收益，而最高频谱熵五分位提升 0.80 dB。该受控代理结果支持选择 FiLM，但不能替代现场录音验证。


## 1 引言

被动声学背景会随航运、天气、生物活动和季节变化。只观察当前混合信号的分离器必须同时估计目标与背景。长时间声景预测提供了另一个严格因果的信息源：混合信号到达前，背景本应是什么样。本文假设该先验可能帮助分离器抑制可预测能量，同时保留意外出现的注入声源。

本文将 Band-Split RoPE Transformer（BS-RoFormer）[2] 与因果循环预测编码器结合。贡献包括：（1）可微的预测–分离联合模型；（2）拼接、FiLM、交叉注意力与无预测基线的匹配消融；（3）经泄漏审计的部署级划分；（4）同时报告分离质量、预测误差、统计不确定性、信号强度鲁棒性和计算可用性的评估协议；（5）包含六类信号，并按频谱偏移、源–背景重叠及频谱熵配对分析的广分布生成器；（6）可在本地试听和下载结果的前端。

## 2 数据与波形构造

我们使用 NOAA–Navy SanctSound 小时级 TOL 产品 [3]。MB03_01 与 MB03_02 用于训练，MB03_03 用于验证，MB03_04 为留出测试集。时刻 $t$ 的样本只有在此前 $H$ 小时及当前小时均有限且严格逐小时连续时才有效。归一化统计量仅由两个训练部署拟合。

公开 TOL 是聚合产品，无法确定波形相位。对当前频谱 $S_t$，我们在 FFT 频点上插值其 dB 包络，使用固定种子采样随机相位和类 Rayleigh 幅度抖动，逆 FFT 后归一化 RMS，得到背景代理 $n_t$。该代理保留粗粒度实测频谱包络，但不保留瞬态、相位或小时内事件，不能表述为恢复的现场原始音频。

原始注入信号 $s_t$ 采用 MINUS 中的可控合成逻辑：谐波分音、带限噪声、起音/释音包络与低频幅度调制。广分布配置新增扫频、非谐波、多脉冲、调频与带限噪声，并放宽载频、调制、包络、瞬态及噪声占比范围。每个样本确定性地重采样信号族、参数和信号背景比。混合信号为 $x_t = n_t + s_t$，并通过共同缩放避免削波。

## 3 方法

令 $S_{t-H:t-1} \in \mathbb{R}^{H\times F}$ 为归一化历史 TOL。GRU 产生

$$z_t = \mathrm{LN}(\mathrm{GRU}(S_{t-H:t-1})), \tag{1}$$

$$\widehat{S}_t = g_\theta(z_t). \tag{2}$$

编码器只读取截止 $t-1$ 的观测。三种注入方案均令 $c_t = \widehat{S}_t$；基线删除预测器。

BS-RoFormer 将混合信号 STFT 频点变为子带 token $X \in \mathbb{R}^{B\times T\times K\times D}$。令 $P_k(c_t)$ 为逐子带投影，$E(c_t)$ 为预测频率箱 token 序列。我们在时间/频率 Transformer 之前比较三个残差注入算子：

$$\text{拼接：}\ \widetilde{X}_k = X_k + f([X_k; P_k(c_t)]), \tag{3}$$

$$\text{FiLM：}\ \widetilde{X}_k = (1 + \tanh\gamma_k(c_t)) \odot X_k + \beta_k(c_t), \tag{4}$$

$$\text{交叉注意力：}\ \widetilde{X} = X + \mathrm{Attn}(X, E(c_t), E(c_t)). \tag{5}$$

三条残差支路均初始化为零，使所有实验从相同音频映射开始。拼接先把局部特征宽度加倍再用 MLP 融合；FiLM 直接改变子带 token 的尺度与偏置；交叉注意力学习音频与预测频率箱之间的内容相关对齐。

端到端目标为

$$\mathcal{L} = \mathcal{L}_{\text{wave}} + \tfrac{1}{2}\sum_{r} \mathcal{L}_{\text{complex STFT},r} + \lambda \|\widehat{S}_t - S_t\|_1, \quad (6)$$

条件模型取 $\lambda = 0.2$。预测和分离损失均可反向更新预测编码器，因此这是联合训练，而不是冻结特征导出。

# 4 实验协议

所有方案共享样本、合成种子、优化器日程、模型宽度、分离器核心初始权重和检查点规则。验证 SI-SDRi 最高的检查点仅在 MB03_04 上评估一次。SI-SDR 采用尺度不变投影形式，SI-SDRi 为输出 SI-SDR 减去混合信号 SI-SDR。我们还报告残余海洋背景 SI-SDR、预测 MAE、实时因子（RTF）、参数量和配对胜率。区间使用固定种子的逐样本配对 bootstrap。盲源分离评估背景见 Vincent 等 [4]。

分布偏移计算先把波形功率汇聚到 $K = 64$ 个对数频率箱并归一化为 $p$，以原始窄谐波生成器 512 次采样的均值分布为 $q$。除方向性 $D_{\mathrm{KL}}(p\|q)$ 外，主指标采用有限且对称的 JS 散度 [1]：

$$D_{\mathrm{JS}}(p,q) = \tfrac{1}{2}D_{\mathrm{KL}}(p\|m) + \tfrac{1}{2}D_{\mathrm{KL}}(q\|m), \quad m = (p+q)/2. \quad (7)$$

由于“偏离旧生成器”不等于“信号更复杂”，还报告归一化频谱熵 $H(p)/\log_2 K$，以及源与海洋背景功率直方图交集 $\sum_k \min(p_k, n_k)$。

**表 1**：匹配的 2000 步广分布条件注入消融。

| 注入方式 | 验证 SI-SDRi (dB) | 测试 SI-SDRi (dB) | 配对 $\Delta_0$ (dB) | 参数量 (千) |
|---|---|---|---|---|
| 无条件 | 4.96 | 5.00 | 0 | 231 |
| 特征拼接 | 5.17 | 5.30 | +0.15 | 238 |
| FiLM | **5.35** | **5.39** | **+0.34** | 255 |
| 交叉注意力 | 4.99 | 5.11 | +0.01 | 220 |

## 4.1 条件注入消融与选型

每个训练部署使用 4000 个样本，所有模型训练 2000 步，SNR 从 $[-12, 12]$ dB 均匀采样。选型只依据 MB03_03：FiLM 验证 SI-SDRi 为 5.35 dB，高于拼接的 5.17 dB 和交叉注意力的 4.99 dB。普通 256 样本 MB03_04 测试上三者分别为 5.39、5.30 和 5.11 dB，无条件模型为 5.00 dB。因此测试集确认了选择，但没有参与选择。

固定 0 dB 时，FiLM 相对相同无条件输出增加 0.34 dB（$[0.21, 0.48]$），拼接增加 0.15 dB（$[0.02, 0.27]$），交叉注意力增加 0.01 dB（$[-0.08, 0.10]$）。FiLM 与任务结构匹配：背景频谱天然指出哪些子带特征应衰减、放大或平移；其浅层乘加调制保留音频证据。拼接必须重新学习压缩加倍后的特征，交叉注意力则要从粗粒度小时频谱中估计对齐关系，其额外自由度在当前数据量下没有得到回报。这是与结果一致的机制解释，而非因果证明。

**表 2**：按注入信号强度分层（每档 128 个样本）。

| 输入 SNR (dB) | 条件模型 SI-SDR (dB) | 条件模型 SI-SDRi (dB) | 基线 SI-SDRi (dB) |
|---|---|---|---|
| -12 | -4.63 | 7.30 | 7.32 |
| -6 | 1.00 | 6.95 | 6.78 |
| 0 | 5.85 | 5.81 | 5.40 |
| +6 | 9.55 | 3.51 | 2.94 |
| +12 | 11.94 | -0.10 | -0.70 |

在弱信号与等强度输入下，FiLM 至少改善 5.81 dB。输入为 +12 dB 时，混合信号已由目标主导，因此 SI-SDRi 接近零，但绝对目标 SI-SDR 仍为 11.94 dB。由此，不同输入强度不应共用单一改善阈值，而应同时检查改善量和绝对输出质量。

## 4.2 广分布信号实验

主分布实验固定输入 SNR 为 0 dB，每个信号族使用 128 个 MB03_04 留出样本，共 768 个；两个模型的海洋波形、源波形、时间戳和 SNR 完全配对。

全部样本上，基线为 5.36 dB，FiLM 为 5.70 dB，配对增益为 0.34 dB。条件增益与 JS 的相关系数为 $-0.085$；从最低 JS 五分位的 0.54 dB 降至最高五分位的 0.00 dB。因此，“与旧生成器距离越远，海洋先验越有用”的解释不成立。

频谱熵更有解释力。增益与熵的相关系数为 0.145；最高熵五分位提升 +0.80 dB（$[0.47, 1.17]$）。按信号族看，带限噪声提升 +0.54 dB（$[0.19, 0.92]$），脉冲列提升 0.47 dB（$[0.16, 0.79]$），调频信号提升 0.43 dB（$[0.08, 0.82]$）。FiLM 因而在多类信号上利用了先验，对弥散目标收益最大；原始 JS/KL 距离并非决定变量。

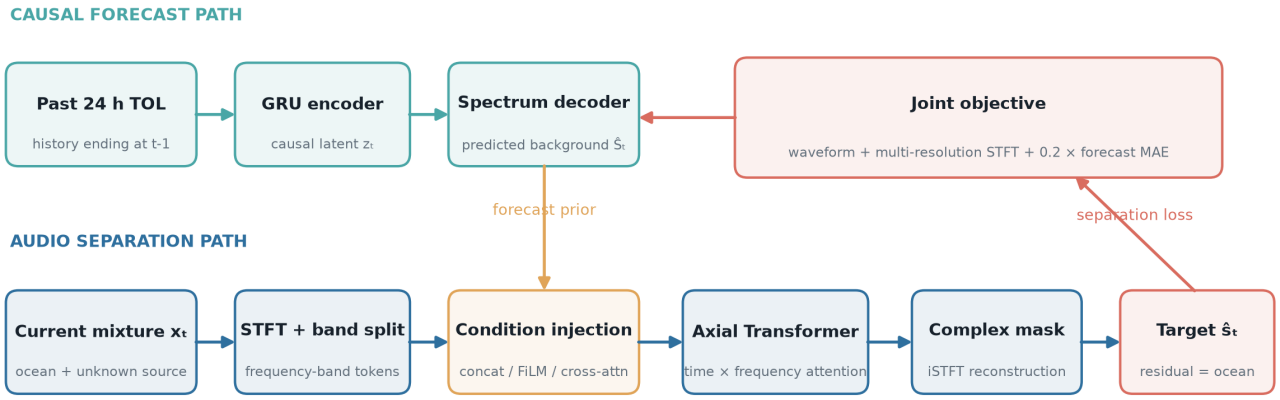



图 1: FC-BSR 架构。截止 $t-1$ 的历史 TOL 先预测当前海洋频谱，再通过拼接、FiLM 或交叉注意力注入 BS-RoFormer 子带 token。预测与分离损失联合训练；无条件基线删除预测路径。

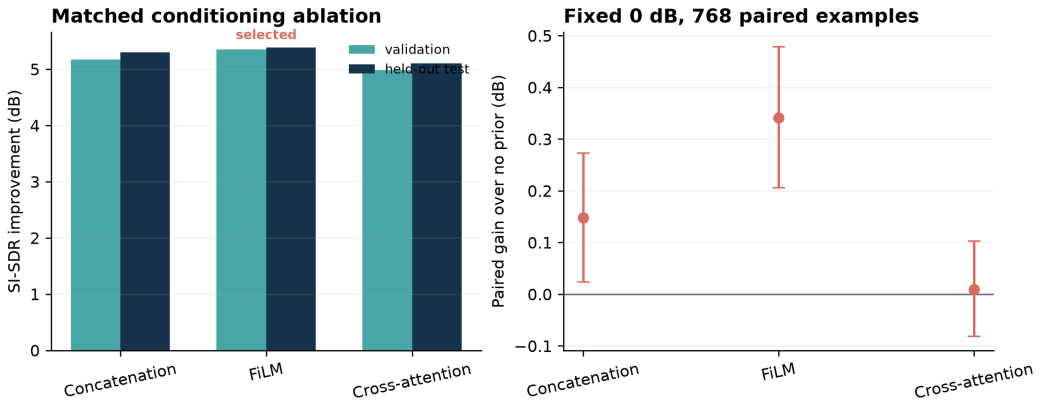



图 2: 匹配的条件注入消融。左图仅用 MB03_03 验证集选型；右图为 MB03_04 上固定 0 dB、768 个配对样本的相对无先验增益。FiLM 增益最大且区间排除零，交叉注意力则没有显著收益。

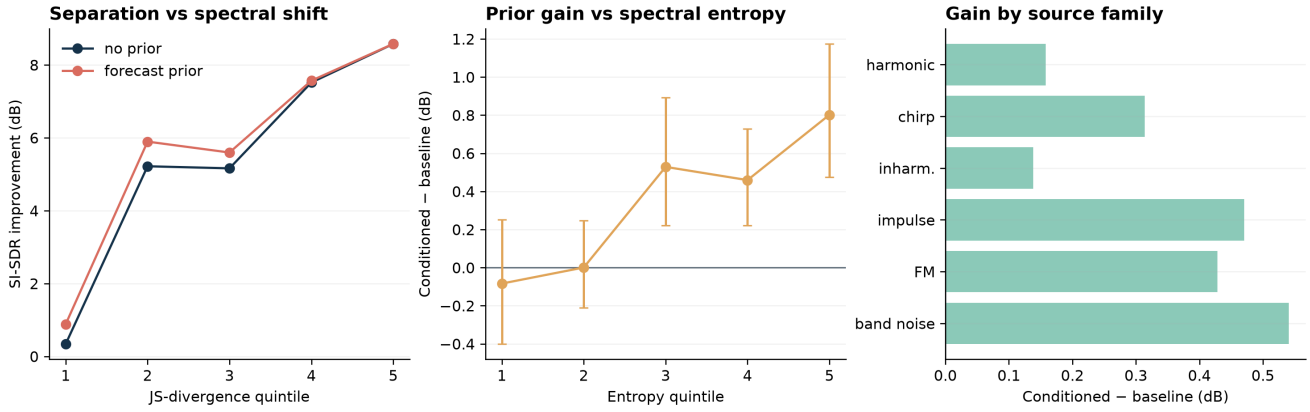



图 3: 0 dB 输入 SNR 下的广分布结果。左：随 JS 偏移五分位变化的 SI-SDRi；中：条件增益随频谱熵变化，误差线为配对 bootstrap 95% 区间；右：各信号族的 FiLM 增益，带限噪声、脉冲与调频信号收益最大。

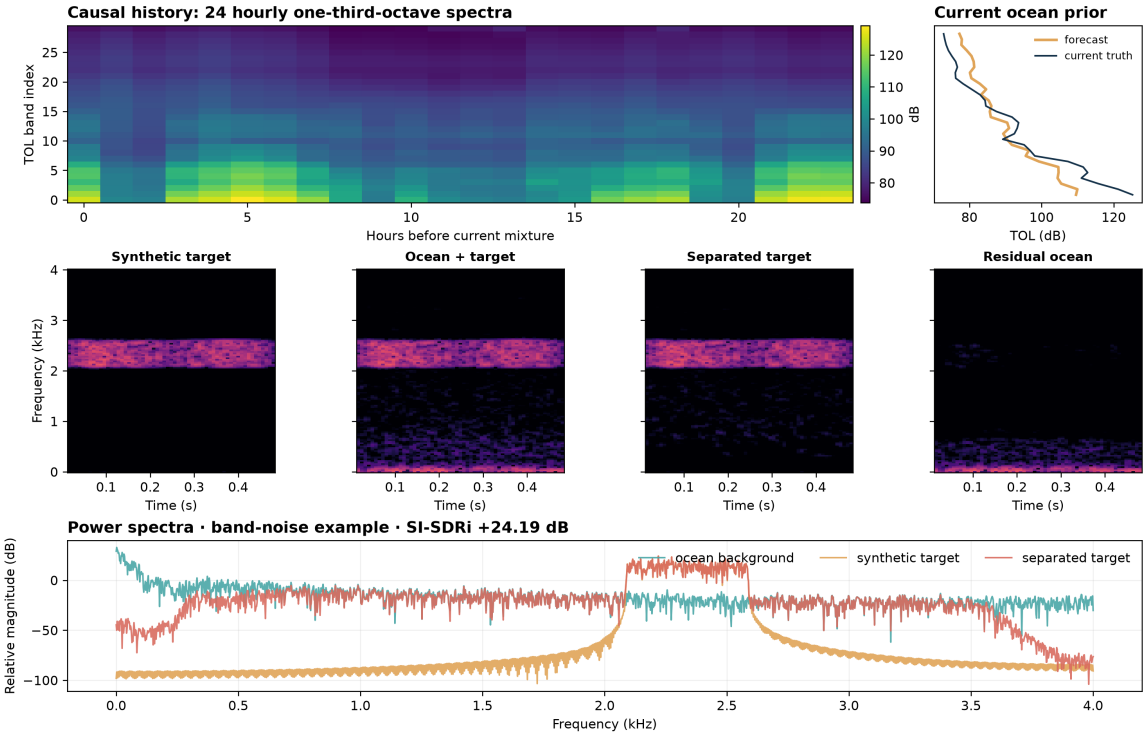



图 4: 一个有代表性的高熵带限噪声样本。上部为因果历史 TOL 与当前海洋频谱预测；中部为合成目标、混合、分离目标和残余海洋的时频图；下部叠加其功率谱。该例直观展示所选 FiLM 先验在保留弥散带目标的同时去除低频海洋能量。

# 5 实用性判据

工程门槛要求：总体 SI-SDRi 不低于 5 dB；输入 SNR 不高于 0 dB 时改善至少 3 dB；更强输入的绝对目标 SI-SDR 不低于 8 dB；前端 RTF 小于 1。FiLM 通过全部四项。批量评估 RTF 为 0.0040；完整分块前端在 RTX 3060 上处理 10 秒 WAV 的 RTF 为 0.043。但科学假设只有在未见过的相位对齐录音上，条件模型相对无条件基线的配对 SI-SDRi 增益为正且 95% 区间排除零时才成立。代理实验满足该条件，现场音频仍待验证。

# 6 本地应用

仓库包含验证集选出的约 1 MB FiLM 检查点和不依赖前端框架的本地 Web 应用。用户上传最近 24 行小时级 TOL 与当前 WAV；应用校验并归一化历史、预测当前频谱、对重叠波形块执行分离，并提供目标信号和残余海洋背景的试听与下载。页面同时绘制预测频谱，展示时长、延迟与 RTF。所有请求都停留在 localhost，不会把录音或历史发送给远程服务。

# 7 局限性

小时级 TOL 删除了相位和小时内时间结构。随机相位代理可能使频谱先验过于直接，并低估真实海洋复杂度。因此当前实验只证明实现正确性和受控代理条件下的行为。决定性实验需要时间对齐的 MB03 原始水听器音频：历史特征不得跨越测试边界；留出波形与相同种子的目标混合；所有选择在 MB03_03 固定；MB03_04 只评估一次。届时还需报告多训练种子和按 SNR 分层的区间。

六类合成信号显著扩展了原生成器，但 JS 散度与频谱熵仍只是频谱摘要，不能表达语义类别、长时结构和录音设备效应。信号族结论必须在真实船舶、生物、声呐、天气和人为事件上复验，才能用于生产模型选择。

# 8 结论

FC-BSR 给出了从声景预测到声音分离的具体、抗泄漏路径及可用本地界面。三种匹配注入机制中，FiLM 由验证集选出，并在受控广分布代理上取得显著的 0.34 dB 配对增益。其优势在高熵目标上最大，而 JS/KL 偏移本身不能预测收益。因此，本仓库是可运行原型和受控研究结果，而不是预测条件已经改善现场录音分离的证据。

# 参考文献

[1] Jianhua Lin. Divergence measures based on the shannon entropy. *IEEE Transactions on Information Theory*, 37(1):145–151, 1991.

[2] Wei-Tsung Lu, Ju-Chiang Wang, Qiuqiang Kong, and Yun-Ning Hung. Music source separation with band-split RoPE transformer. *arXiv preprint arXiv:2309.02612*, 2023.

[3] NOAA Office of National Marine Sanctuaries and U.S. Navy. SanctSound raw passive acoustic data. NOAA National Centers for Environmental Information dataset, 2020.

[4] Emmanuel Vincent, Rémi Gribonval, and Cédric Févotte. Performance measurement in blind audio source separation. *IEEE Transactions on Audio, Speech, and Language Processing*, 14(4):1462–1469, 2006.