因果预测条件下的海洋声音分离 BS-RoFormer

匿名作者
匿名单位

***Abstract*—**本文固定一个主模型设置：**GRU** 预测器、**FiLM** 条件注入、**BS-RoFormer** 分离器和 **5** 秒窗口。每个完全监督样本为 (H_t, N_t, s_t, x_t)：屏蔽已标注鲸声的连续 **12** 个先前 **5** 秒特征、标注干净的真实当前 **5** 秒海洋录音、合成海洋事件及其精确混合。现有录音提供 **146.4** 小时的干净当前背景，其中训练集有 **37.3** 小时可用于训练。预测器在 **5** 秒分辨率上训练，验证 **MAE** 从 **persistence** 的 **2.111** 降至 **1.926 dB**（**8.8%**）。在 **4,096** 个留出混合上的六路匹配实验中，真正的 **BS-RoFormer** 与 **Zero-FiLM** 均为 **9.631 dB SI-SDRi**，**GRU-Forecast FiLM** 为 **9.497 dB**，使用实际当前 **30** 维 $E(N_t)$ 的 **Oracle-FiLM** 为 **9.535 dB**。**Oracle** 相对 **BS-RoFormer** 为 -0.096 **dB**，按日期分块的 **95%** 区间 $[-0.238, 0.034]$；因此当前 **30** 维条件没有显示明确平均收益。另一个全波形 **Oracle** 校验在同一留出混合上学得 $x_t - N_t$，说明压缩频谱不能代表完整背景真值。其他注入方式仅作为消融。固定抄答案接口的信息阶梯显示：等宽 **128** 组仍有可靠收益，**64** 组则没有；**30** 个对数频带即使采用最细的测试时间网格，也没有得到可确认的收益。在没有隔离声轨的真实事件上，冻结分类器也未显示 **FC-BSR** 相比零条件 **FiLM** 有明确语义优势。本文支持标注干净背景上的完全监督分离，但现有 **30** 维预测条件与 **FiLM** 接口的分离增益尚未确立。

***Index Terms*—**海洋声学，源分离，声景预测，**BS-RoFormer**，无参考评估

I. 引言

海洋背景随航运、天气、生物活动和季节变化 [1]。仅使用混合声音的分离器必须从同一观测中同时推断突发事件与变化背景。本文改为使用此前声景提供严格因果先验：

$$\underbrace{S_{t-H:t-1}}_{H_t} \xrightarrow{\text{GRU}} \widehat{S}_t, \qquad x_t = N_t + s_t \xrightarrow[\widehat{S}_t]{\text{FiLM+BSR}} (\hat{N}_t, \hat{s}_t), \tag{1}$$

其中 H_t 屏蔽所有已标注事件及其保护区，N_t 是真实、标注干净的当前 5 秒录音；模型只观察 x_t, H_t，而 N_t, s_t 提供精确监督。

时域分离器 [2], [3]、注意力模型 [4], [5] 和子带系统 [6], [7] 提供了强大的仅混合输入骨干。混合 Transformer 与 MixIT 扩展了架构和监督方式 [8], [9]，但没有检验下一时刻背景预测。FiLM、交叉注意力与跨模态分离 [10]–[12] 启发了三种接口；递归、线性与分块预测模型则提供时间序列基线 [13]–[16]。

本文贡献为：（1）FC-BSR 的唯一主设置为 GRU+FiLM+BS-RoFormer、5 秒窗口；[1]（2）构造事件掩蔽历史和标注干净当前背景上的完全监督样本；（3）提出覆盖鲸声扫频与船噪过程的 13 类广分布信号生成器，主 DCLDE 实验使用其中 5 类鲸声和 2 类船噪；（4）在未修改真实鲸声事件上直接比较 FC-BSR 与零条件 FiLM。TOL、条件机制、时间尺度和未标注背景强度实验均作为消融，不混同于主结果。

[1]代码与复现实验说明：https://github.com/D-eval/ocean_noise_pred_splite。

II. 方法

A. 背景预测与条件分离

主设置的历史特征 $H_t \in \mathbb{R}^{12\times 30}$ 由当前窗前 12 个 5 秒块计算得到 30 维对数频带功率；已标注事件及两侧 2 秒保护区被排除，归一化统计量只从训练集估计。残差 GRU 预测

$$z_t = \text{LN}(\text{GRU}(H_t)), \quad \widehat{S}_t = S_{t-1} + g_\psi(z_t). \tag{2}$$

零初始化精确表示 persistence；只有验证 MAE 优于 persistence 时才保留学习式预测 [17]。

BS-RoFormer 将混合 STFT 映射为子带 token X_k。在轴向 Transformer 前的相同位置比较

$$\begin{aligned} \text{拼接：}\ & \widetilde{X}_k = X_k + f([X_k; P_k(\widehat{S}_t)]), \\ \text{FiLM：}\ & \widetilde{X}_k = (1 + \tanh\gamma_k) \odot X_k + \beta_k, \\ \text{交叉注意力：}\ & \widetilde{X} = X + \text{Attn}(X, E(\widehat{S}_t), E(\widehat{S}_t)). \end{aligned} \tag{3}$$

所有残差条件分支均从恒等映射开始。损失结合波形 L_1 与多分辨率复数 STFT；仅 TOL 代理实验加入 $0.2\|\widehat{S}_t - S_t\|_1$。真实波形实验在训练分离器前冻结预测器。

主数据域的信息审计固定骨干、混合样本、初始化和训练规则。真正无条件的 BS-RoFormer 绕过条件注入；Zero-FiLM 保留 FiLM 分支与同一冻结 GRU，但用 $c = 0$ 替换其输出。Shuffled-FiLM 将同一划分内的干净时窗索引错开半个周期，取得另一时窗的 $E(N_j)$；留出测试中该窗来自另一录音日。Persistence-FiLM 使用最后一个历史频谱 S_{t-1}，Forecast-FiLM 使用冻结 GRU 的预测。Oracle-FiLM 使用 $S_t^{\text{oracle}} = E(N_t)$，其中 N_t 是当前样本实际采用的干净背景波形，包含极少数混合峰值归一化后的幅度。本文明确称之为“30 频带 Oracle-FiLM”：E 丢失时间结构与相位，因此这一路既不是完整背景条件的上限，也不能限制更丰富表示下完美预测的价值。该条件仅在受控实验中可用。

B. 海洋感知合成信号分布

广分布生成器包含 13 类：谐波、线性啁啾、非谐波、脉冲列、调频音、带限噪声、鲸声上扫、下扫、拱形、S 形、脉冲包、船舶音调和船舶空化。鲸声代理由 1–3 个局部事件组成，随机改变时长、曲率、分音、渐入渐出与抖动。船舶音调和窄带空化分量以 0.8 概率采用 5–20 Hz 低频振荡器（LFO）音量包络；宽带分量不做该调制。训练 SNR 在 $[-18, 12]$ dB 均匀抽样。这些代理用于覆盖轮廓和调制样式，并不声称对应具体物种。

频谱位移同时用方向性 $D_{\text{KL}}(p\|q)$ 和有限对称 JS 散度 [19] 衡量，另报告频谱熵与信号–海洋频谱重叠。更大的 KL/JS 只代表覆盖范围更广，不等价于语义多样性。主 DCLDE 实验仅从其中 5 类鲸声和 2 类船噪抽样，六组模型使用同一目标分布。

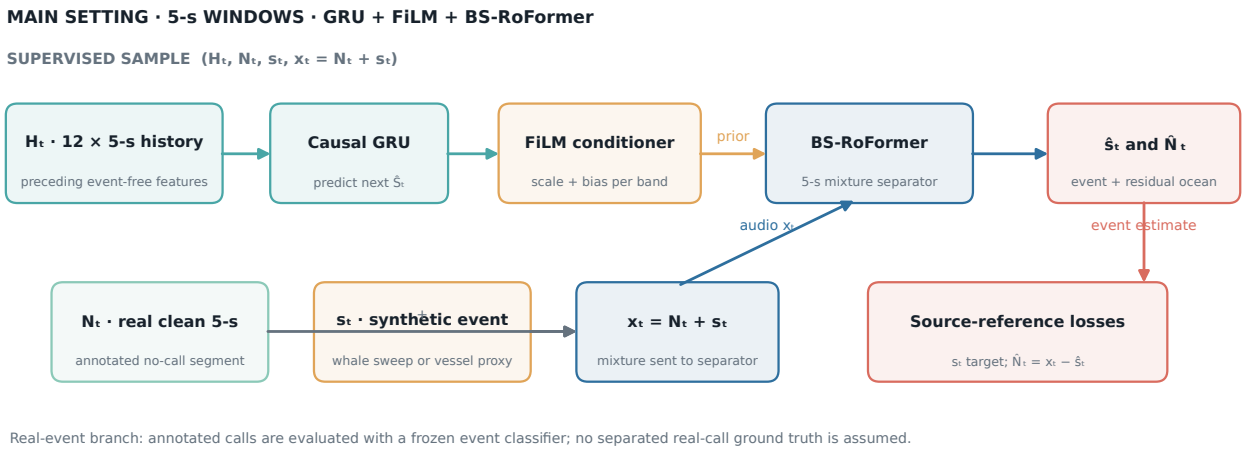


Fig. 1. FC-BSR 架构。严格早于当前时刻的声景特征预测当前背景频谱，并条件化同一个 BS-RoFormer 骨干；事件声轨使用合成真值监督，背景估计为混合减去事件估计。

C. 主数据构造与消融协议

主数据由按日期隔离的 2-kHz DCLDE 2013 录音及鲸声标注组成 [20], [21]。在 168 小时 WAV 中，移除已标注事件及两侧各 2 秒保护区后，得到 146.4 小时标注干净的 5 秒窗口。每个当前窗使用同一 WAV 中紧邻其前的 12 个 5 秒块作为历史；只有 12 块均在事件与保护区之外时，该当前窗才纳入样本。这样不做小时平均，也不跨 WAV 文件边界构造历史。筛选后共 94.5 小时符合条件，训练/验证/测试分别为 37.3/9.7/47.6 小时。每个当前背景 N_t 与上述 7 类海洋合成事件 s_t 相加得到 $x_t = N_t + s_t$。模型输入只有 x_t, H_t，而 N_t, s_t 是监督真值。主设置固定为 GRU+FiLM+BS-RoFormer、5 秒和 12 个先前 5 秒历史窗。

次级消融采用 NOAA–Navy SanctSound 小时级 TOL 产品 [18]。MB03 部署 01–02/03/04 分别用于训练/验证/测试。随机相位逆变换只产生受控频谱代理，不能视为恢复音频。条件机制、KL/JS 覆盖、预测时间尺度，以及 42 小时未标注连续 WAV 上的强度扫描均属于消融；后者缺乏事件标注，不能作为主干的干净背景证据。

全参考分离使用尺度不变投影的 SI-SDR 与 SI-SDRi [22], [23]。区间使用固定种子的配对 bootstrap；主测试按留出录音日分块。当前测试特征仅作监督目标，GRU 历史严格截止于 t 之前。

III. 实验与结果

A. 条件机制选择与信号多样性

表 I 只按验证集选择 FiLM。在 832 个固定 0-dB 配对样本（每族 64 个）上，它将 SI-SDRi 从 4.850 提高到 5.541 dB。逐频带缩放与偏置可以直接表达“此处为预期能量”；拼接需要压缩加倍特征，交叉注意力则必须在相同预算内从粗条件中学习对齐。

FiLM 在五类鲸声代理上的增益依次为 0.869、0.835、0.919、0.906 与 0.806 dB。船舶音调最难：尽管相对增益为 0.320 dB，条件模型的绝对 SI-SDRi 仍为 −8.295 dB。总体增益与 JS 的相关性很弱（$r = -.057$），与频谱熵也仅为 $r = .122$；因此提高散度能扩大覆盖，却不能预测先验何时有用。

TABLE I
匹配的 5 秒条件注入消融（dB）。

注入方式	验证 SI-SDRi	测试 SI-SDRi	配对 Δ_0
无条件	4.864	4.059	0
拼接	5.343	4.432	+0.623
FiLM	**5.419**	**4.468**	**+0.692**
交叉注意力	5.128	4.261	+0.331

B. 主结果：标注干净真实背景上的合成事件

主 FC-BSR 固定为 FiLM+5 秒 +GRU+BS-RoFormer，并使用上述事件掩蔽历史及标注干净的真实当前背景；训练集有 37.3 小时可用干净背景。旧两路结果把零条件 FiLM 检查点误称为无条件 BS-RoFormer；本实验将它按实际结构重新标注，在附上同一冻结 GRU 后确认波形输出完全一致，另行训练真正跳过条件注入的 BS-RoFormer。表 II 中的六路共用相同混合样本、骨干迁移初始化、优化预算、验证选点，并在三个留出录音日的 4,096 个样本上逐例核对 ID、SNR 与混合基准分数。图 3 展示这些样本按注入 SNR 分组后的曲线。

结构效应 Zero−BS-RoFormer 为 -0.0002 dB（95% 区间 $[-0.0068, 0.0088]$）。Forecast−BS-RoFormer 为 -0.134 dB（$[-0.327, 0.125]$），Oracle−BS-RoFormer 为 -0.096 dB（$[-0.238, 0.034]$）；Oracle−Forecast 仅为 $+0.039$ dB（$[-0.090, 0.155]$）。错时与 persistence 条件相对 Zero 也没有显示正的平均收益。Oracle 的验证 SI-SDRi 比 BS-RoFormer 高（11.372 对 10.946 dB），但没有形成明确的留出优势。三个测试录音日使小效应仍未确定；30 频带 Oracle 拥有更丰富的真实信息，然而独立优化的 FiLM 模型不必按信息量形成性能排序。

a) 全波形 *Oracle* 的抄答案校验。*:* 为检验 E 的信息损失能否解释 30 频带结果，我们冻结同一已训练 BS-

TABLE II
主域 DCLDE：4,096 个匹配的标注干净 5 秒背景与合成事件。数值为目标 SI-SDRi（dB）；方括号是按留出录音日配对 bootstrap 的 95% 区间。只有 30 频带 Oracle 使用 $E(N_t)$。

模型	验证	测试	相对 BSR Δ [95% 区间]	相对 Zero Δ [95% 区间]
BS-RoFormer	10.946	9.631	0	$+0.0002$ $[-0.009, 0.007]$
Zero-condition FiLM	10.967	9.631	-0.0002 $[-0.007, 0.009]$	0
Shuffled-condition FiLM	10.609	9.526	-0.105 $[-0.247, 0.020]$	-0.105 $[-0.256, 0.026]$
Persistence-condition FiLM	11.205	9.524	-0.107 $[-0.239, 0.083]$	-0.107 $[-0.232, 0.084]$
GRU-Forecast FiLM (FC-BSR)	11.213	9.497	-0.134 $[-0.327, 0.125]$	-0.134 $[-0.320, 0.125]$
30 频带 Oracle-FiLM, $E(N_t)$	11.372	9.535	-0.096 $[-0.238, 0.034]$	-0.095 $[-0.231, 0.035]$

TABLE III
与主实验相同的 4,096 个 DCLDE 测试混合上的全波形抄答案校验。目标 SI-SDRi 及相对冻结 BSR 按日期配对的差值（dB）。

冻结 BSR + 拟合融合头	SI-SDRi	Δ [95% 区间]
BSR；初始 $(1, 0, 0)$	9.631	0
全零波形	9.231	-0.400 $[-0.483, -0.269]$
错时背景波形	9.231	-0.400 $[-0.483, -0.269]$
当前实际 N_t 波形	80.755	$+71.124$ $[69.945, 72.081]$
解析式 $x_t - N_t$	80.755	$+71.124$ $[69.945, 72.081]$

TABLE IV
真实背景上的预测分辨率诊断。

步长	预测器	条件模型	基线	增益 [95% 区间]
5 秒	GRU	29.753	28.527	1.226 [1.082,1.381]
30 秒	persistence	29.630	28.534	1.095 [0.935,1.265]
1 分钟	persistence	29.661	28.533	1.128 [0.971,1.298]
10 分钟	persistence	29.711	28.535	1.176 [1.036,1.326]

条件模型、基线与增益均为目标 SI-SDRi（dB）。

RoFormer，在 8,192 个训练混合上拟合逐采样点三系数融合头：

$$\hat{s}_t = w_b \hat{s}_{\text{BSR}}(x_t) + w_x x_t + w_c c_t. \tag{4}$$

初始系数 $(1, 0, 0)$ 精确复现 BSR，用最小二乘求波形均方误差的全局最优解。同一结构分别输入全零、错时背景及真实当前背景波形；验证与测试各用 4,096 个样本。测试 ID、SNR、混合 SI-SDR 及冻结 BSR 输出均与表 II 逐例核对。当 $c_t = N_t$ 时，学得系数数值上等于 $(0, 1, -1)$，即精确抄得 $x_t - N_t = s_t$。测试波形最大绝对误差为 5.96×10^{-8}；80.755 dB 的有限 SI-SDRi 由指标数值底噪限制。零条件与错时条件均未改善 SI-SDRi（表 III）。此处是有意使用非因果真值、且接口不同的信息量和答案通路校验；它不是匹配架构的 FiLM 消融，也不证明 30 频带历史预测可以恢复相位对齐的当前背景波形。

b) Oracle 信息阶梯。*:* 我们固定冻结 BSR、三系数融合头、训练样本及 4,096 个匹配的测试混合，逐层压缩当前背景 N_t。在 2 kHz 音频上使用 512 点 Hann STFT（257 个频率 bin，帧步长 64 ms），将背景功率沿频率合并为 128/64/32 个等宽相邻组，或 128/64/48/30 个 20–950 Hz 对数频带；另沿时间合并为 0.25、1、5 秒。保留的幅度配合真实 N_t 相位或混合 x_t 相位做逆变换。边缘 bin 并入最近的对数带；名义 128 个对数带中，实际只有 95 个含 STFT bin。最粗的 30 频带/5 秒功率类似原始 $E(N_t)$，但数值定义并不完全相同。

图 2 显示这条固定答案通路在哪里失去留出收益。完整幅度改用混合相位，相对 BSR 仍提高 11.164 dB（日期分块区间 $[10.889, 11.594]$）。等宽 128 组仍提高 $+2.067$ dB（$[0.969, 3.386]$）；等宽 64 组为 -0.623 dB（$[-1.404, 0.259]$），可靠的正收益在这两级之间消失。对数 128 带已为 -0.529 dB （$[-1.257, 0.319]$），逐帧 30 带为 -0.672 dB（$[-1.323, 0.086]$）。即便逐帧 30 带保留真实背景相位，也仅提高 $+0.117$ dB（$[-0.671, 1.084]$）。相比之下，保留全部 257 个频率 bin、只把功率按 1 秒汇总并使用混合相位，仍提高 $+0.585$ dB（$[0.285, 1.132]$）；按整段 5 秒汇总则为 $+0.249$ dB （$[-0.044, 0.495]$）。因此在这一答案通路中，频率平均及其分带规则比单独汇总时间更容易使条件失效。这不构成信息论极限，也不是新增的 FiLM 消融。

C. 次级消融：预测时间尺度与未标注背景强度

以下实验来自 SanctSound 或未标注连续 WAV，不是干净背景主实验。时间尺度诊断固定相同留出样本；5 秒预测器的验证 MAE 为 1.366 dB，略优于 persistence 的 1.386 dB，其余尺度选择 persistence。这项结果仅说明该消融域中 5 秒特征的预测略有优势，不能替代主设置的留出全参考检验。

另一个未标注 SanctSound WAV 消融在 1152 个配对测试混合上比较零条件 FiLM、当前真值频谱 oracle、因果预测和错时条件。这里的 oracle 属于次级数据域；表 II 中的主域 30 频带 Oracle 使用标注干净 DCLDE 的实际 N_t 提取 $E(N_t)$。跨训练 SNR 平均后，零条件 FiLM 为 23.470 dB，Forecast-FC-BSR 为 22.871 dB （$\Delta = -0.599$，区间 $[-0.851, -0.346]$），oracle 平均值也更低。这暴露了简单分辨率诊断没有显示的条件化/容量影响。图 4 进一步表明：在 $-18, -15, -12, -9, -6$ dB，预测条件分别提高 0.728、0.643、0.525、0.366、0.157 dB；从 -3 dB 开始转为落后。错时条件对最弱目标也有收益，却随 SNR 上升迅速退化，因此不能把弱目标增益完全归因于预测的时间准确性；正则化或额外容量仍是可能解释。

D. 没有分离真值的真实事件

参考学习式无参考指标 [24], [25] 和语义音频嵌入 [26], [27]，我们训练、校准并冻结二分类器；测试 AUROC、AP 与 F1 分别为.9723、.9755、.9275。混合一致性要求 $\hat{N} = x - \hat{s}$。将 $\hat{s}$ 按 $\{-60, -30, -24, -18, -12, -6, 0\}$ dB 逐级恢复，检查事件概率是否单调回升；Identity 与 all-to-event 排除平凡解，标注区间外变化审计背景保留。

真实事件评估使用主设置同一冻结的 12 步事件掩蔽历史预测器。由于近期事件历史被排除，测试中有 103

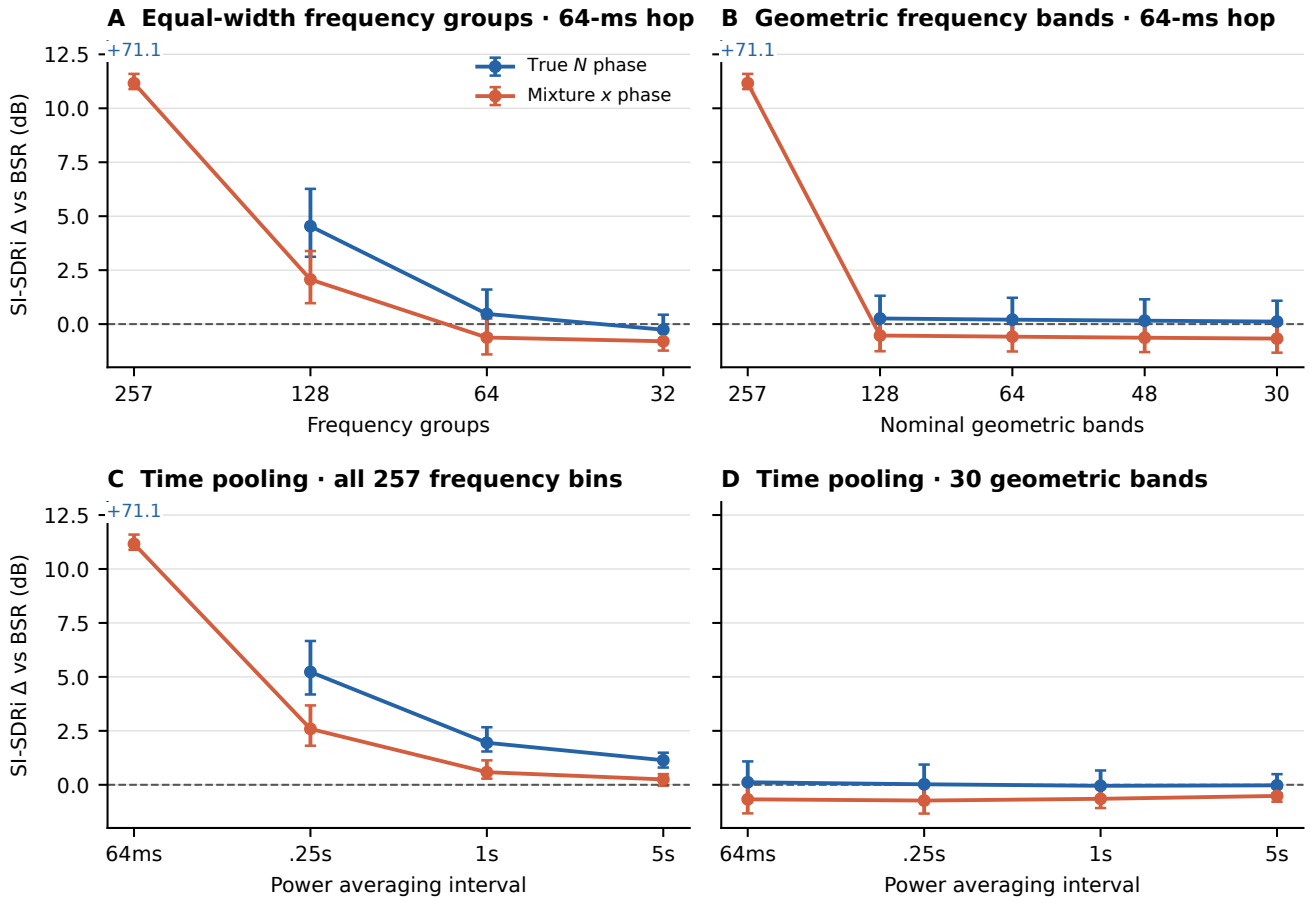


Fig. 2. 同一组 DCLDE 测试混合上的当前背景 Oracle 信息阶梯。每个点在训练混合上拟合相同结构的三系数答案头；误差棒为相对冻结 BSR 的 SI-SDRi 按日期配对的 95% 区间。完整分辨率且使用真实相位的 N_t 提高 71.1 dB，超出绘图范围；混合相位是独立的信息损失。阈值依赖分带方式和当前答案接口。

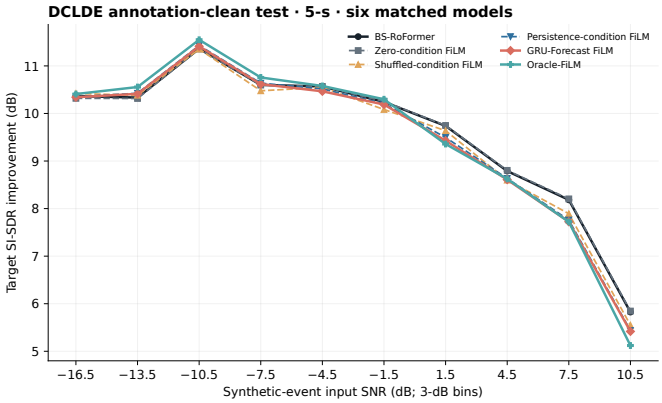


Fig. 3. 标注干净 DCLDE 背景上的主全参考实验：六路匹配模型按 3-dB 输入 SNR 分组的目标 SI-SDRi 均值。总体平均的日期分块区间见表 II。

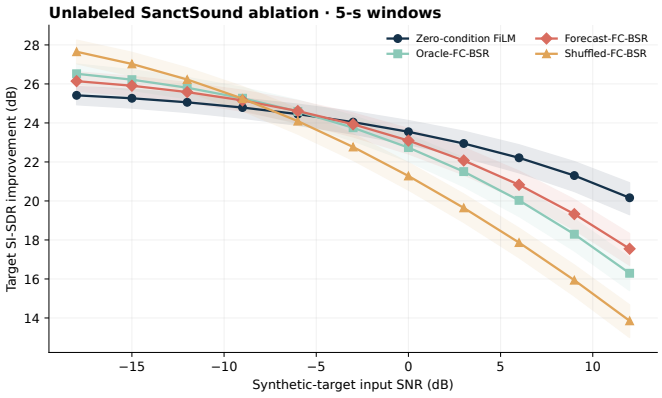


Fig. 4. 未标注 SanctSound WAV 消融：5 秒目标强度扫描。曲线为四种条件，阴影为配对 95% 区间；该图不是标注干净主实验。

个真实事件保留完整 60 秒历史。表 V 显示 FC-BSR 的残余事件概率和区间外改动呈下降趋势，事件声轨概率近似不变。按留出日期分块后，残余事件概率差 -0.0731 的 95% 区间为 $[-.2090, .0294]$，事件声轨概率差 $+.0022$ 的区间为 $[-.0180, .0304]$，单调率差 $+.0178$ 的区间为 $[-.0333, .0429]$，均包含零；区间外相对误差差 $-.0248$ 的

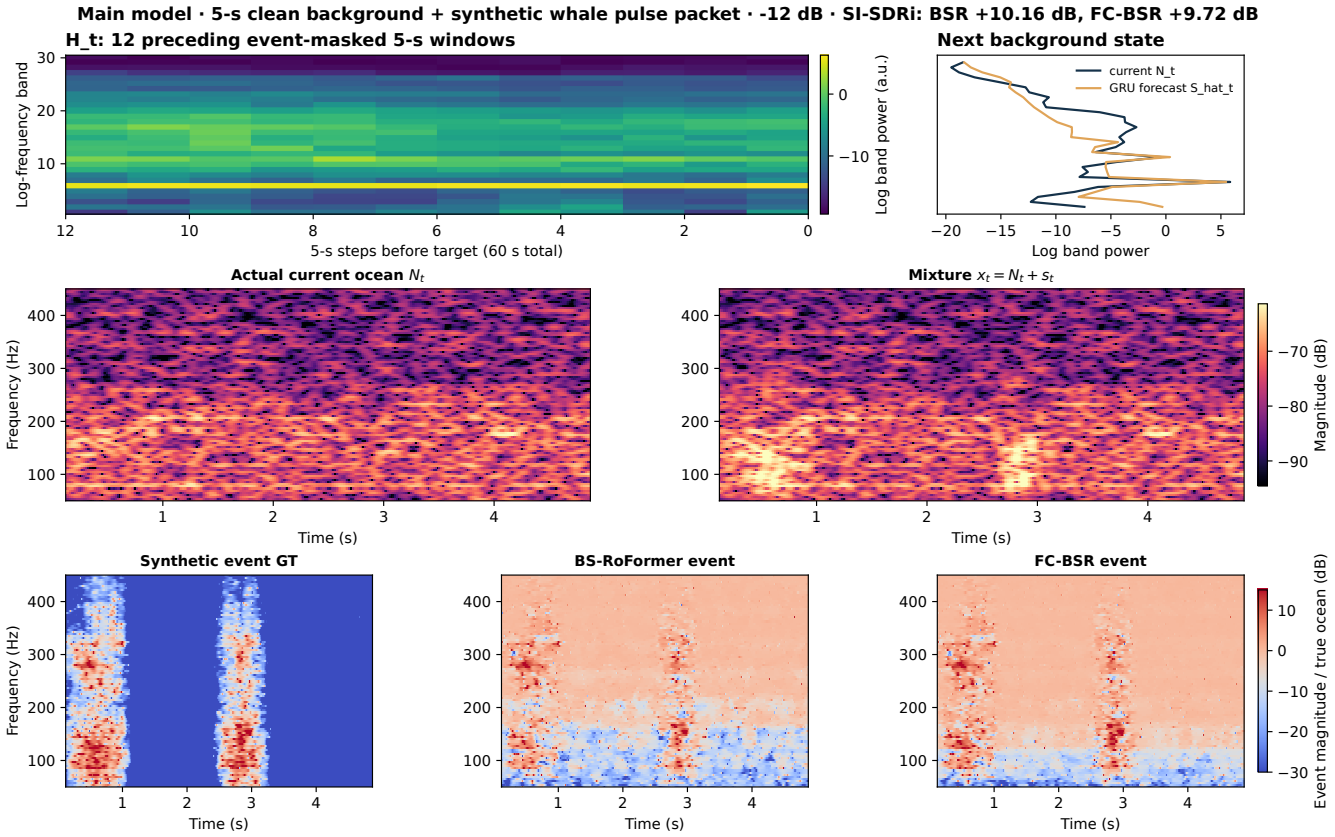


Fig. 5. 标注干净 DCLDE 背景中按组内中位数选择的鲸声脉冲包示例（−12 dB，5 秒）。海洋背景和混合声音共用绝对幅度色标；下排三张事件声轨图共用相对真实背景幅度的 dB 色标。两种估计均未彻底去除背景纹理；总体强度结果见图 3。

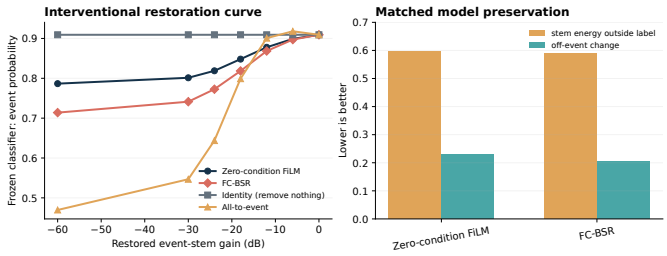


Fig. 6. 零条件 FiLM 与 FC-BSR 的无参考恢复曲线及背景保留审计。两种模型都进行了非平凡语义分离，但 FC-BSR 在真实事件上没有全面胜出。

区间为 $[-.0456, -.0018]$。因此该小样本提供有利但不确定的语义迹象，仍没有真实分离声轨真值。

IV. 讨论与结论

主域 30 频带 Oracle 只诊断当前接口：FiLM 即使得到当前实际干净波形的 $E(N_t)$，留出平均值仍未超过无条件 BS-RoFormer，且配对区间跨零。全波形抄答案校验则精确成功，因此这一负结果不能说明真实背景没有可用信息；30 频带压缩与 FiLM 注入各自的影响仍未分清。固定融合头的信息阶梯进一步显示：等宽 128 频组或全频 bin 的 1 秒功率汇总仍能产生确定的收益，等宽 64 组和 30 个对数频带则没有。然而原 FiLM 结果不能仅归因于这一断点，因为接口并不相同。Zero-FiLM 与无条件骨干几乎重合，Forecast 也没有超过 Zero 或 Shuffled 的明确证据。因此不能把预测误差单独认定为瓶颈；5 秒静态 30 维频带摘要与 FiLM 接口可能不足以对齐分离器的时频 token。FiLM 在频谱代理消融中仍是最好的接口，未标注 WAV 强度消融也显示弱目标收益，但两者都不能证明主域增益。未修改鲸声上的预测优势也不明确；主测试只有三个留出录音日，小效应或站点差异仍可能存在。

本地前端可用于实验检查：在已准备历史特征的 CPU 冒烟测试中，单个 5 秒块 RTF 为 0.014；界面可显示预测并试听、下载两条估计声轨，但这不等于野外部署。下一步值得检验的是当前混合声音相对预测背景的时频创新图，而非仅使用静态频带均值；还应覆盖更多站点和季节，为真实事件获取隔离声轨或更强局部参考。分类器恢复曲线是语义迁移证据，不能替代波形保真真值。

References

[1] J. L. Miksis-Olds, D. L. Bradley, and X. M. Niu, "Decadal trends in indian ocean ambient sound," *Journal of the Acoustical Society of America*, vol. 134, no. 5, pp. 3464–3475, 2013.

[2] Y. Luo and N. Mesgarani, "Conv-TasNet: Surpassing ideal time–frequency magnitude masking for speech separation," *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, vol. 27, no. 8, pp. 1256–1266, 2019.

[3] Y. Luo, Z. Chen, and T. Yoshioka, "Dual-path RNN: Efficient long sequence modeling for time-domain single-channel speech separation," in *Proc. IEEE ICASSP*, 2020, pp. 46–50.

TABLE V
103 个具有合格历史的真实事件上的无参考匹配比较。

方法	$p(x)$	$p(\hat{N})\downarrow$	$p(\hat{s})\uparrow$	单调率 ↑	区间外 ↓
零条件 FiLM	.909	.786	.900	.937	.230
FC-BSR	.909	.713	.902	.955	.206

[4] C. Subakan, M. Ravanelli, S. Cornell, M. Bronzi, and J. Zhong, "Attention is all you need in speech separation," in *Proc. IEEE ICASSP*, 2021, pp. 21–25.

[5] Z.-Q. Wang, S. Cornell, S. Choi, Y. Lee, B.-Y. Kim, and S. Watanabe, "TF-GridNet: Integrating full- and sub-band modeling for speech separation," in *Proc. IEEE ICASSP*, 2023, pp. 1–5.

[6] Y. Luo and J. Yu, "Music source separation with band-split RNN," *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, vol. 31, pp. 1893–1901, 2023.

[7] W.-T. Lu, J.-C. Wang, Q. Kong, and Y.-N. Hung, "Music source separation with band-split RoPE transformer," *arXiv preprint arXiv:2309.02612*, 2023. [Online]. Available: https://arxiv.org/abs/2309.02612

[8] S. Rouard, F. Massa, and A. Défossez, "Hybrid transformers for music source separation," in *Proc. IEEE ICASSP*, 2023, pp. 1–5.

[9] S. Wisdom, E. Tzinis, H. Erdogan, R. J. Weiss, K. Wilson, and J. R. Hershey, "Unsupervised sound separation using mixture invariant training," in *Advances in Neural Information Processing Systems*, vol. 33, 2020, pp. 3846–3857.

[10] E. Perez, F. Strub, H. de Vries, V. Dumoulin, and A. Courville, "FiLM: Visual reasoning with a general conditioning layer," in *Proc. AAAI Conference on Artificial Intelligence*, vol. 32, no. 1, 2018.

[11] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, "Attention is all you need," in *Advances in Neural Information Processing Systems*, vol. 30, 2017.

[12] H. Zhao, C. Gan, A. Rouditchenko, C. Vondrick, J. McDermott, and A. Torralba, "The sound of pixels," in *Proc. European Conference on Computer Vision*, 2018, pp. 570–586.

[13] D. Salinas, V. Flunkert, J. Gasthaus, and T. Januschowski, "DeepAR: Probabilistic forecasting with autoregressive recurrent networks," *International Journal of Forecasting*, vol. 36, no. 3, pp. 1181–1191, 2020.

[14] B. N. Oreshkin, D. Carpov, N. Chapados, and Y. Bengio, "N-BEATS: Neural basis expansion analysis for interpretable time series forecasting," in *International Conference on Learning Representations*, 2020.

[15] A. Zeng, M. Chen, L. Zhang, and Q. Xu, "Are transformers effective for time series forecasting?" in *Proc. AAAI Conference on Artificial Intelligence*, vol. 37, no. 9, 2023, pp. 11 121–11 128.

[16] Y. Nie, N. H. Nguyen, P. Sinthong, and J. Kalagnanam, "A time series is worth 64 words: Long-term forecasting with transformers," in *International Conference on Learning Representations*, 2023.

[17] T. Gneiting, "Making and evaluating point forecasts," *Journal of the American Statistical Association*, vol. 106, no. 494, pp. 746–762, 2011.

[18] NOAA Office of National Marine Sanctuaries and U.S. Navy, "Sanctsound raw passive acoustic data," NOAA NCEI dataset, 2020.

[19] J. Lin, "Divergence measures based on the shannon entropy," *IEEE Transactions on Information Theory*, vol. 37, no. 1, pp. 145–151, 1991.

[20] D. Gillespie, M. Caillat, and J. Gordon, "DCLDE 2013 workshop dataset," 2019.

[21] Y. Shiu, K. J. Palmer, M. A. Roch, E. Fleishman, X. Liu, E.-M. Nosal, T. Helble, D. Cholewiak, D. Gillespie, and H. Klinck, "Deep neural networks for automated detection of marine mammal species," *Scientific Reports*, vol. 10, p. 607, 2020.

[22] E. Vincent, R. Gribonval, and C. Févotte, "Performance measurement in blind audio source separation," *IEEE Transactions on Audio, Speech, and Language Processing*, vol. 14, no. 4, pp. 1462–1469, 2006.

[23] J. Le Roux, S. Wisdom, H. Erdogan, and J. R. Hershey, "SDR—half-baked or well done?" in *Proc. IEEE ICASSP*, 2019, pp. 626–630.

[24] K. Kilgour, M. Zuluaga, D. Roblek, and M. Sharifi, "Fréchet audio distance: A reference-free metric for evaluating music enhancement algorithms," in *Proc. Interspeech*, 2019, pp. 2350–2354.

[25] E. M. Grais, H. Wierstorf, D. Ward, R. D. Mason, and M. D. Plumbley, "Referenceless performance evaluation of audio source separation using deep neural networks," in *Proc. European Signal Processing Conference*, 2019.

[26] Y. Wu, K. Chen, T. Zhang, Y. Hui, M. Nezhurina, T. Berg-Kirkpatrick, and S. Dubnov, "Large-scale contrastive language–audio pretraining with feature fusion and keyword-to-caption augmentation," in *Proc. IEEE ICASSP*, 2023, pp. 1–5.

[27] X. Xiao, H. Jin, Z. Chen, A. Gram, G. Wichern, and J. Le Roux, "A reference-free metric for language-queried audio source separation using contrastive language–audio pretraining," in *Proc. DCASE Workshop*, 2024.