因果噪声预测条件下的海洋声音分离 BS-RoFormer

匿名

摘要

常规海洋声音分离器只能从当前混合信号中估计持续变化的背景。本文研究一个严格因果的问题：根据过去声景预测当前期望背景，并将预测结果作为 BS-RoFormer 的条件，能否改善目标声源分离。系统编码历史三分之一倍频程声级（TOL），预测当前背景频谱，并将预测潜表示或显式预测频谱分别通过特征拼接、FiLM 调制和交叉注意力注入 BS-RoFormer 的子带 token；预测损失与分离损失联合优化。实验采用部署级时间隔离、配对 SI-SDR 统计、五档信号强度和实时因子评估。六类信号代理实验在 768 个配对样本上选择 FiLM；其相对无条件分离器的 SI-SDR 提升（SI-SDRi）增加 0.34 dB，且 JS 散度不能单独预测收益。随后使用 42 小时连续真实水听器录音，在固定 1 小时历史下比较 5 秒、30 秒、1 分钟和 10 分钟预测窗；只有学习预测在验证集优于 persistence 时才采用。四种尺度在 1024 个留出真实背景片段上均取得显著配对增益，5 秒最佳，为 +1.226 dB（95% 区间 $[1.082, 1.381]$），实时因子为 0.0024。只有 5 秒尺度的学习预测优于 persistence，说明时间条件有用，但复杂动态预测并非总是必要。

1 引言

被动声学背景会随航运、天气、生物活动和季节变化。只观察当前混合信号的分离器必须同时估计目标与背景。长时间声景预测提供了另一个严格因果的信息源：混合信号到达前，背景本应是什么样。本文假设该先验可能帮助分离器抑制可预测能量，同时保留意外出现的注入声源。

本文将 Band-Split RoPE Transformer（BS-RoFormer）[2] 与因果循环预测编码器结合。贡献包括：（1）可微的预测–分离联合模型；（2）拼接、FiLM、交叉注意力与无预测基线的匹配消融；（3）经泄漏审计的部署级划分；（4）同时报告分离质量、预测误差、统计不确定性、信号强度鲁棒性和计算可用性的评估协议；（5）包含六类信号，并按频谱偏移、源–背景重叠及频谱熵配对分析的广分布生成器；（6）四种子小时分辨率的连续真实录音实验；（7）可在本地试听和下载结果的前端。

2 数据与波形构造

我们使用 NOAA–Navy SanctSound 小时级 TOL 产品 [3]。MB03_01 与 MB03_02 用于训练，MB03_03 用于验证，MB03_04 为留出测试集。时刻 t 的样本只有在此前 H 小时及当前小时均有限且严格逐小时连续时才有效。归一化统计量仅由两个训练部署拟合。

公开 TOL 是聚合产品，无法确定波形相位。对当前频谱 S_t，我们在 FFT 频点上插值其 dB 包络，使用固定种子采样随机相位和类 Rayleigh 幅度抖动，逆 FFT 后归一化 RMS，得到背景代理 n_t。该代理保留粗粒度实测频谱包络，但不保留瞬态、相位或小时内事件，不能表述为恢复的现场原始音频。

现场实验直接使用对应的连续 8 kHz SanctSound 水听器录音：MB03_01、02、03 各 6 小时，以及连续 24 小时的 MB03_04 测试日，共 42 小时。先对 1 秒 Hann 周期图在 25–4000 Hz 的 23 个三分之一倍频程积分，再平均为 5 秒特征，并在功率域聚合为 30 秒、1 分钟或 10 分钟。该实验不合成任何背景波形相位。

原始注入信号 s_t 采用 MINUS 中的可控合成逻辑：谐波分音、带限噪声、起音/释音包络与低频幅度调制。广分布配置新增扫频、非谐波、多脉冲、调频与带限噪声，并放宽载频、调制、包络、瞬态及噪声占比范围。每个样本确定性地重采样信号族、参数和信号背景比。混合信号为 $x_t = n_t + s_t$，并通过共同缩放避免削波。

3 方法

令 $S_{t-H:t-1} \in \mathbb{R}^{H\times F}$ 为归一化历史 TOL。GRU 产生

$$z_t = \mathrm{LN}(\mathrm{GRU}(S_{t-H:t-1})), \tag{1}$$

$$\widehat{S}_t = g_\theta(z_t). \tag{2}$$

编码器只读取截止 $t-1$ 的观测。三种注入方案均令 $c_t = \widehat{S}_t$；基线删除预测器。

BS-RoFormer 将混合信号 STFT 频点变为子带 token $X \in \mathbb{R}^{B\times T\times K\times D}$。令 $P_k(c_t)$ 为逐子带投影，$E(c_t)$ 为预测频率箱 token 序列。我们在时间/频率 Transformer 之前比较三个残差注入算子：

$$\text{拼接：}\ \widetilde{X}_k = X_k + f([X_k; P_k(c_t)]), \tag{3}$$

$$\text{FiLM：}\ \widetilde{X}_k = (1+\tanh\gamma_k(c_t))\odot X_k + \beta_k(c_t), \tag{4}$$

$$\text{交叉注意力：}\ \widetilde{X} = X + \mathrm{Attn}(X, E(c_t), E(c_t)). \tag{5}$$

三条残差支路均初始化为零，使所有实验从相同音频映射开始。拼接先把局部特征宽度加倍再用 MLP 融合；FiLM 直接改变子带 token 的尺度与偏置；交叉注意力学习音频与预测频率箱之间的内容相关对齐。

端到端目标为

$$\mathcal{L} = \mathcal{L}_{\text{wave}} + \tfrac{1}{2}\sum_r \mathcal{L}_{\text{complex STFT},r} + \lambda\|\widehat{S}_t - S_t\|_1, \tag{6}$$

条件模型取 $\lambda = 0.2$。预测和分离损失均可反向更新预测编码器，因此这是联合训练，而不是冻结特征导出。

4 实验协议

所有方案共享样本、合成种子、优化器日程、模型宽度、分离器核心初始权重和检查点规则。验证 SI-SDRi 最高的检查点仅在 MB03_04 上评估一次。SI-SDR 采用尺度不变投影形式，SI-SDRi 为输出 SI-SDR 减去混合信号 SI-SDR。我们还报告残余海洋背景 SI-SDR、预测 MAE、实时因子（RTF）、参数量和配对胜率。区间使用固定种子的逐样本配对 bootstrap。盲源分离评估背景见 Vincent 等 [4]。

分布偏移计算先把波形功率汇聚到 $K = 64$ 个对数频率箱并归一化为 p，以原始窄谐波生成器 512 次采样的均值分布为 q。除方向性 $D_{\mathrm{KL}}(p\|q)$ 外，主指标采用有限且对称的 JS 散度 [1]：

$$D_{\mathrm{JS}}(p,q) = \tfrac{1}{2}D_{\mathrm{KL}}(p\|m) + \tfrac{1}{2}D_{\mathrm{KL}}(q\|m), \quad m = (p+q)/2. \tag{7}$$

由于“偏离旧生成器”不等于“信号更复杂”，还报告归一化频谱熵 $H(p)/\log_2 K$，以及源与海洋背景功率直方图交集 $\sum_k \min(p_k, n_k)$。

表 1：匹配的 2000 步广分布条件注入消融。

注入方式	验证 SI-SDRi (dB)	测试 SI-SDRi (dB)	配对 Δ_0 (dB)	参数量 (千)
无条件	4.96	5.00	0	231
特征拼接	5.17	5.30	+0.15	238
FiLM	**5.35**	**5.39**	**+0.34**	255
交叉注意力	4.99	5.11	+0.01	220

4.1 条件注入消融与选型

每个训练部署使用 4000 个样本，所有模型训练 2000 步，SNR 从 $[-12, 12]$ dB 均匀采样。选型只依据 MB03_03：FiLM 验证 SI-SDRi 为 5.35 dB，高于拼接的 5.17 dB 和交叉注意力的 4.99 dB。普通 256 样本 MB03_04 测试上三者分别为 5.39、5.30 和 5.11 dB，无条件模型为 5.00 dB。因此测试集确认了选择，但没有参与选择。

固定 0 dB 时，FiLM 相对相同无条件输出增加 0.34 dB（$[0.21, 0.48]$），拼接增加 0.15 dB（$[0.02, 0.27]$），交叉注意力增加 0.01 dB（$[-0.08, 0.10]$）。FiLM 与任务结构匹配：背景频谱天然指出哪些子带特征应衰减、放大或平移；其浅层乘加调制保留音频证据。拼接必须重新学习压缩加倍后的特征，交叉注意力则要从粗粒度小时频谱中估计对齐关系，其额外自由度在当前数据量下没有得到回报。这是与结果一致的机制解释，而非因果证明。

表 2：按注入信号强度分层（每档 128 个样本）。

输入 SNR (dB)	条件模型 SI-SDR (dB)	条件模型 SI-SDRi (dB)	基线 SI-SDRi (dB)
-12	-4.63	7.30	7.32
-6	1.00	6.95	6.78
0	5.85	5.81	5.40
+6	9.55	3.51	2.94
+12	11.94	-0.10	-0.70

在弱信号与等强度输入下，FiLM 至少改善 5.81 dB。输入为 +12 dB 时，混合信号已由目标主导，因此 SI-SDRi 接近零，但绝对目标 SI-SDR 仍为 11.94 dB。由此，不同输入强度不应共用单一改善阈值，而应同时检查改善量和绝对输出质量。

4.2 广分布信号实验

主分布实验固定输入 SNR 为 0 dB，每个信号族使用 128 个 MB03_04 留出样本，共 768 个；两个模型的海洋波形、源波形、时间戳和 SNR 完全配对。

全部样本上，基线为 5.36 dB，FiLM 为 5.70 dB，配对增益为 0.34 dB。条件增益与 JS 的相关系数为 -0.085；从最低 JS 五分位的 0.54 dB 降至最高五分位的 0.00 dB。因此，“与旧生成器距离越远，海洋先验越有用”的解释不成立。

频谱熵更有解释力。增益与熵的相关系数为 0.145；最高熵五分位提升 +0.80 dB（$[0.47, 1.17]$）。按信号族看，带限噪声提升 +0.54 dB（$[0.19, 0.92]$），脉冲列提升 0.47 dB（$[0.16, 0.79]$），调频信号提升 0.43 dB（$[0.08, 0.82]$）。

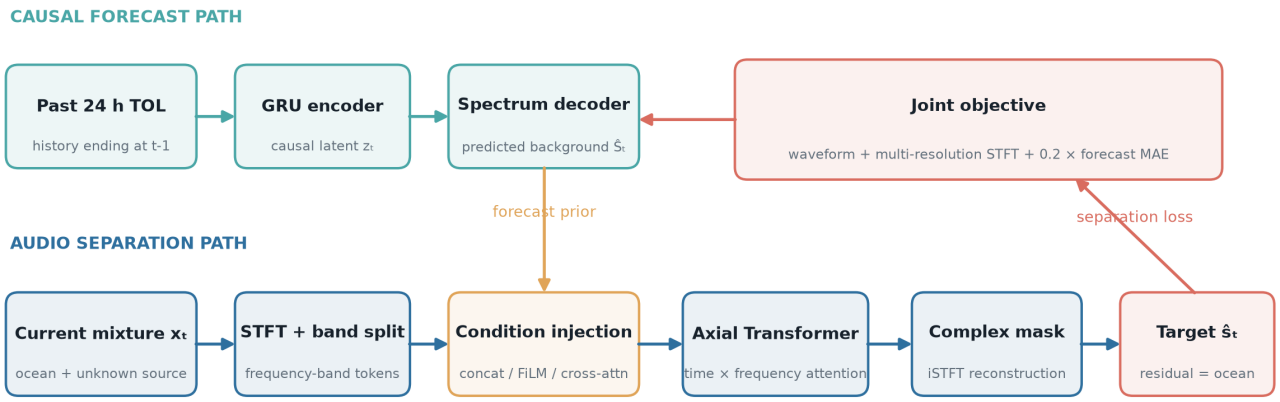


图 1: FC-BSR 架构。截止 $t-1$ 的历史 TOL 先预测当前海洋频谱，再通过拼接、FiLM 或交叉注意力注入 BS-RoFormer 子带 token。预测与分离损失联合训练；无条件基线删除预测路径。

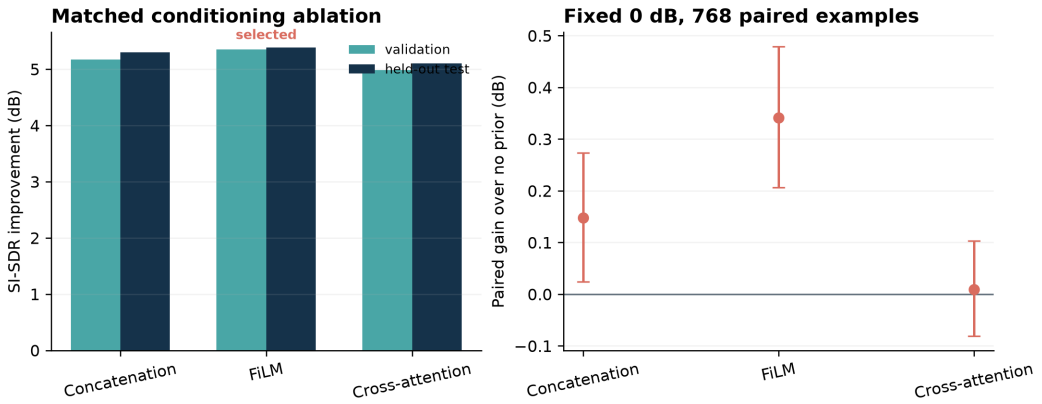


图 2: 匹配的条件注入消融。左图仅用 MB03_03 验证集选型；右图为 MB03_04 上固定 0 dB、768 个配对样本的相对无先验增益。FiLM 增益最大且区间排除零，交叉注意力则没有显著收益。

FiLM 因而在多类信号上利用了先验，对弥散目标收益最大；原始 JS/KL 距离并非决定变量。

5 子小时真实波形实验

子小时实验固定历史覆盖为 1 小时，对应 720、120、60 或 6 个因果历史步。对目标窗 t，模型只能读取 $S_{t-H:t-1}$，背景目标直接取真实波形 N_t。在该窗内注入广分布合成源，$x_t = N_t + \alpha s_t$，因此信号与噪声真值仍完全干净。四种分辨率共享绝对片段时刻与注入种子。

GRU 最多预训练 2500 步。由于短窗海洋频谱具有很强持续性，零残差初始化对应 step 0 的 persistence 预测；只有学习检查点降低 MB03_03 的预测 MAE 时才替换它。选中预测器后将其冻结，FiLM 分离器至少训练 3000 步、最多 5000 步，仅按 MB03_03 SI-SDRi 选择检查点，最后一次性在 MB03_04 评估。这样分离损失不能暗中破坏预测准确率。

四种条件模型均通过五档 SNR 工程门槛，RTF 均约为 0.0024。5 秒窗的绝对 SI-SDRi 与配对增益最高，但四组增益区间重叠，不能据此宣称分辨率排序具有显著性。更重要的负结论是：更复杂的预测不必然更有用。只有 5 秒验证 MAE 相对 persistence 改善 1.4%；10 分钟尺度仅有 60 个独立下一窗训练样本，GRU 明显过拟合。时间背景信息确实有用，但当前数据下多数信息由 persistence 即可提供。

6 实用性判据

工程门槛要求：总体 SI-SDRi 不低于 5 dB；输入 SNR 不高于 0 dB 时改善至少 3 dB；更强输入的绝对目

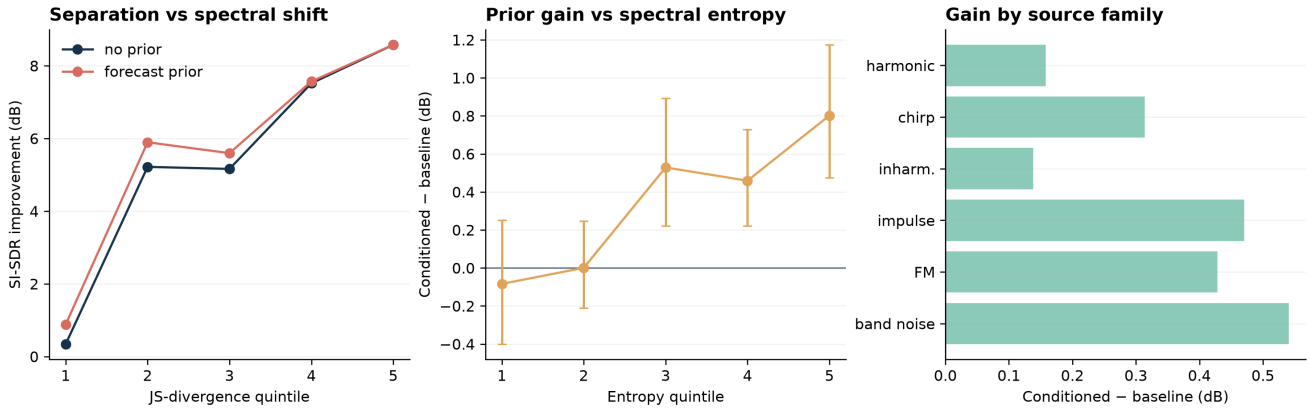


图 3: 0 dB 输入 SNR 下的广分布结果。左：随 JS 偏移五分位变化的 SI-SDRi；中：条件增益随频谱熵变化，误差线为配对 bootstrap 95% 区间；右：各信号族的 FiLM 增益，带限噪声、脉冲与调频信号收益最大。

表 3: 连续真实海洋录音上的子小时预测与分离。区间为 1024 个留出片段的配对 bootstrap 95% 区间。

窗口	历史步数	选中预测	验证 MAE (dB)	条件 SI-SDRi (dB)	基线 SI-SDRi (dB)	配对增益 (dB)	95% 区间 (dB)
5 秒	720	GRU，第 1600 步	1.366	**29.753**	28.527	**+1.226**	[1.082, 1.381]
30 秒	120	persistence	0.782	29.630	28.534	+1.095	[0.935, 1.265]
1 分钟	60	persistence	0.687	29.661	28.533	+1.128	[0.971, 1.298]
10 分钟	6	persistence	1.371	29.711	28.535	+1.176	[1.036, 1.326]

标 SI-SDR 不低于 8 dB；前端 RTF 小于 1。FiLM 通过全部四项。批量评估 RTF 为 0.0040；完整分块前端在 RTX 3060 上处理 10 秒 WAV 的 RTF 为 0.043。但科学假设只有在未见过的相位对齐录音上，条件模型相对无条件基线的配对 SI-SDRi 增益为正且 95% 区间排除零时才成立。代理实验满足该条件，现场音频仍待验证。

7 本地应用

仓库包含验证集选出的约 1 MB FiLM 检查点和不依赖前端框架的本地 Web 应用。用户上传最近 24 行小时级 TOL 与当前 WAV；应用校验并归一化历史、预测当前频谱、对重叠波形块执行分离，并提供目标信号和残余海洋背景的试听与下载。页面同时绘制预测频谱，展示时长、延迟与 RTF。所有请求都停留在 localhost，不会把录音或历史发送给远程服务。

8 局限性

真实波形实验消除了代理背景限制，但注入目标仍为合成信号，且全部录音来自同一站点。训练录音只有 12 小时；10 分钟尺度仅留下 60 个独立下一窗样本，不足以训练灵活 GRU。在提出部署结论前，还需加入多站点、多季节、多训练种子，以及真实船舶、生物和声呐目标。

六类合成信号显著扩展了原生成器，但 JS 散度与频谱熵仍只是频谱摘要，不能表达语义类别、长时结构和录音设备效应。信号族结论必须在真实船舶、生物、声呐、天气和人为事件上复验，才能用于生产模型选择。

9 结论

FC-BSR 给出了从声景预测到声音分离的具体、抗泄漏路径及可用本地界面。FiLM 从三种匹配注入机制中由验证集选出。在连续真实背景上，四种子小时先验均显著改善分离；5 秒尺度绝对得分最高，配对增益为 +1.226 dB。学习动态只有在 5 秒尺度优于 persistence，因此当前证据更强地支持“使用时间相关背景条件”，而不是“必须使用复杂预测器”。剩余关键问题是在多站点、多季节的真实目标事件上复验。

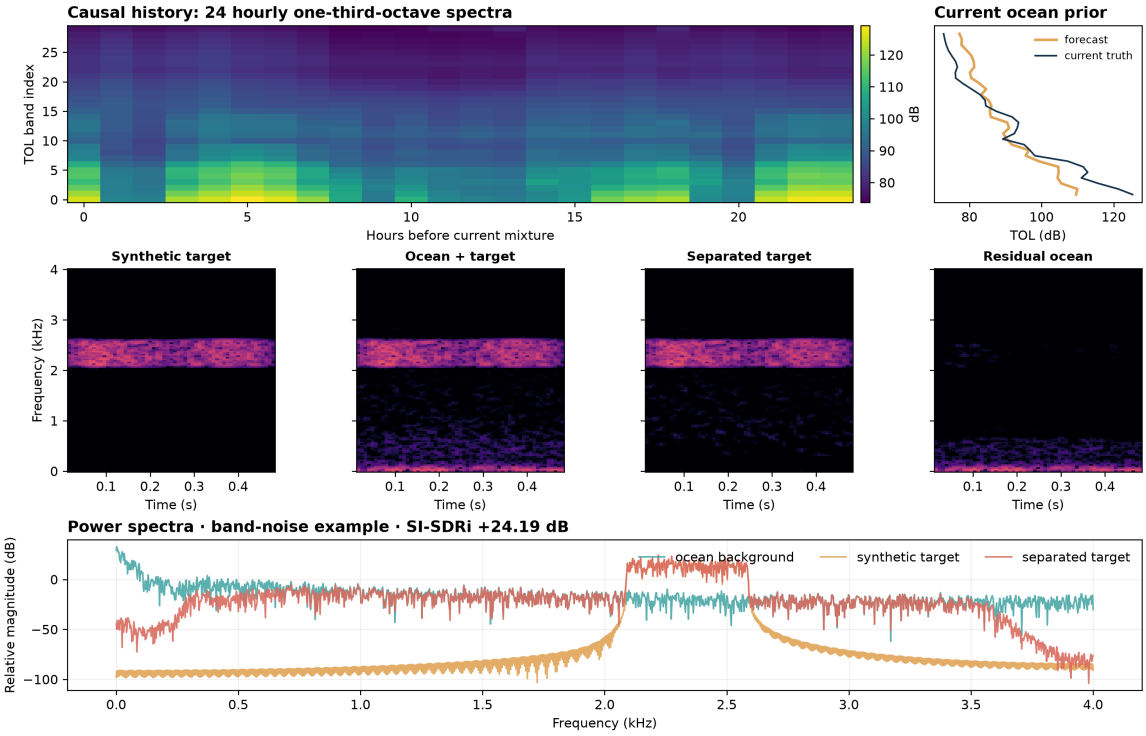


图 4: 一个有代表性的高熵带限噪声样本。上部为因果历史 TOL 与当前海洋频谱预测；中部为合成目标、混合、分离目标和残余海洋的时频图；下部叠加其功率谱。该例直观展示所选 FiLM 先验在保留弥散带目标的同时去除低频海洋能量。

参考文献

[1] Jianhua Lin. Divergence measures based on the shannon entropy. *IEEE Transactions on Information Theory*, 37(1):145–151, 1991.

[2] Wei-Tsung Lu, Ju-Chiang Wang, Qiuqiang Kong, and Yun-Ning Hung. Music source separation with band-split RoPE transformer. *arXiv preprint arXiv:2309.02612*, 2023.

[3] NOAA Office of National Marine Sanctuaries and U.S. Navy. SanctSound raw passive acoustic data. NOAA National Centers for Environmental Information dataset, 2020.

[4] Emmanuel Vincent, Rémi Gribonval, and Cédric Févotte. Performance measurement in blind audio source separation. *IEEE Transactions on Audio, Speech, and Language Processing*, 14(4):1462–1469, 2006.