因果预测条件下的海洋声音分离 BS-RoFormer

匿名作者
匿名单位

***Abstract*—**本文固定一个主模型设置：**GRU** 预测器、**FiLM** 条件注入、**BS-RoFormer** 分离器和 **5** 秒窗口。每个完全监督样本为 (H_t, N_t, s_t, x_t)：屏蔽已标注鲸声的连续 **12** 个先前 **5** 秒特征、标注干净的真实当前 **5** 秒海洋录音、合成海洋事件及其精确混合。现有录音提供 **146.4** 小时的干净当前背景，其中训练集有 **37.3** 小时可用于训练。预测器在 **5** 秒分辨率上训练，验证 **MAE** 从 **persistence** 的 **2.111** 降至 **1.926 dB**（**8.8%**）。在 **4,096** 个标注干净背景测试混合上，**FC-BSR** 的 **SI-SDRi** 比无条件模型低 **0.134 dB**，**95%** 区间跨零。其他条件注入方法只作为消融。在无法获得隔离声轨的真实事件上，冻结的事件分类器未显示 **FC-BSR** 相比匹配的无条件模型有明确语义优势。因此，本文支持在标注干净背景上的完全监督分离，但对预测先验能否改善未知真实事件保持谨慎。

***Index Terms*—**海洋声学，源分离，声景预测，**BS-RoFormer**，无参考评估

I. 引言

海洋背景随航运、天气、生物活动和季节变化 [1]。仅使用混合声音的分离器必须从同一观测中同时推断突发事件与变化背景。本文改为使用此前声景提供严格因果先验：

$$\underbrace{S_{t-H:t-1}}_{H_t} \xrightarrow{\text{GRU}} \widehat{S}_t, \qquad x_t = N_t + s_t \xrightarrow[\widehat{S}_t]{\text{FiLM+BSR}} (\hat{N}_t, \hat{s}_t), \tag{1}$$

其中 H_t 屏蔽所有已标注事件及其保护区，N_t 是真实、标注干净的当前 5 秒录音；模型只观察 x_t, H_t，而 N_t, s_t 提供精确监督。

时域分离器 [2], [3]、注意力模型 [4], [5] 和子带系统 [6], [7] 提供了强大的仅混合输入骨干。混合 Transformer 与 MixIT 扩展了架构和监督方式 [8], [9]，但没有检验下一时刻背景预测。FiLM、交叉注意力与跨模态分离 [10]–[12] 启发了三种接口；递归、线性与分块预测模型则提供时间序列基线 [13]–[16]。

本文贡献为：（1）FC-BSR 的唯一主设置为 GRU+FiLM+BS-RoFormer、5 秒窗口；[1]（2）构造事件掩蔽历史和标注干净当前背景上的完全监督样本；（3）提出覆盖鲸声扫频与船噪过程的 13 类海洋感知信号生成器；（4）在未修改真实鲸声事件上直接比较 FC-BSR 与 BS-RoFormer。TOL、条件机制、时间尺度和未标注背景强度实验均作为消融，不混同于主结果。

II. 方法

A. 背景预测与条件分离

主设置的历史特征 $H_t \in \mathbb{R}^{12\times 30}$ 由当前窗前 12 个 5 秒块计算得到 30 维对数频带功率；已标注事件及两侧 2 秒保护区被排除，归一化统计量只从训练集估计。残差 GRU 预测

$$z_t = \text{LN}(\text{GRU}(H_t)), \quad \widehat{S}_t = S_{t-1} + g_\psi(z_t). \tag{2}$$

[1]代码与复现实验说明：https://github.com/D-eval/ocean_noise_pred_splite。

零初始化精确表示 persistence；只有验证 MAE 优于 persistence 时才保留学习式预测 [17]。

BS-RoFormer 将混合 STFT 映射为子带 token X_k。在轴向 Transformer 前的相同位置比较

$$\begin{aligned} \text{拼接：}\ & \widetilde{X}_k = X_k + f([X_k; P_k(\widehat{S}_t)]), \\ \text{FiLM：}\ & \widetilde{X}_k = (1 + \tanh\gamma_k) \odot X_k + \beta_k, \\ \text{交叉注意力：}\ & \widetilde{X} = X + \text{Attn}(X, E(\widehat{S}_t), E(\widehat{S}_t)). \end{aligned} \tag{3}$$

所有残差条件分支均从恒等映射开始。损失结合波形 L_1 与多分辨率复数 STFT；仅 TOL 代理实验加入 $0.2\|\widehat{S}_t - S_t\|_1$。真实波形实验在训练分离器前冻结预测器。

B. 海洋感知合成信号分布

生成器包含 13 类：谐波、线性啁啾、非谐波、脉冲列、调频音、带限噪声、鲸声上扫、下扫、拱形、S 形、脉冲包、船舶音调和船舶空化。鲸声代理由 1–3 个局部事件组成，随机改变时长、曲率、分音、渐入渐出与抖动。船舶音调和窄带空化分量以 0.8 概率采用 5–20 Hz 低频振荡器（LFO）音量包络；宽带分量不做该调制。训练 SNR 在 $[-18, 12]$ dB 均匀抽样。这些代理用于覆盖轮廓和调制样式，并不声称对应具体物种。

频谱位移同时用方向性 $D_{\text{KL}}(p\|q)$ 和有限对称 JS 散度 [19] 衡量，另报告频谱熵与信号–海洋频谱重叠。更大的 KL/JS 只代表覆盖范围更广，不等价于语义多样性。

C. 主数据构造与消融协议

主数据由按日期隔离的 2-kHz DCLDE 2013 录音及鲸声标注组成 [20], [21]。在 168 小时 WAV 中，移除已标注事件及两侧各 2 秒保护区后，得到 146.4 小时标注干净的 5 秒窗口。每个当前窗使用同一 WAV 中紧邻其前的 12 个 5 秒块作为历史；只有 12 块均在事件与保护区之外时，该当前窗才纳入样本。这样不做小时平均，也不跨 WAV 文件边界构造历史。筛选后共 94.5 小时符合条件，训练/验证/测试分别为 37.3/9.7/47.6 小时。每个当前背景 N_t 与 13 类合成事件 s_t 相加得到 $x_t = N_t + s_t$。模型输入只有 x_t, H_t，而 N_t, s_t 是监督真值。主设置固定为 GRU+FiLM+BS-RoFormer、5 秒和 12 个先前 5 秒历史窗。

次级消融采用 NOAA–Navy SanctSound 小时级 TOL 产品 [18]。MB03 部署 01–02/03/04 分别用于训练/验证/测试。随机相位逆变换只产生受控频谱代理，不能视为恢复音频。条件机制、KL/JS 覆盖、预测时间尺度，以及 42 小时未标注连续 WAV 上的强度扫描均属于消融；后者缺乏事件标注，不能作为主干的干净背景证据。

全参考分离使用尺度不变投影的 SI-SDR 与 SI-SDRi [22], [23]。区间使用固定种子的配对 bootstrap；主测试按留出录音日分块。当前测试特征仅作监督目标，GRU 历史严格截止于 t 之前。

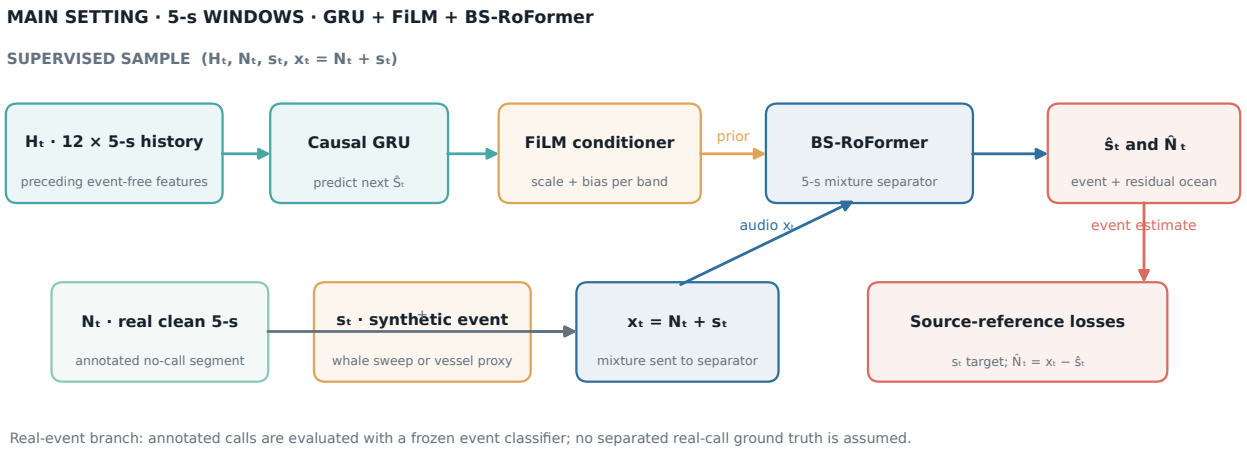


Fig. 1. FC-BSR 架构。严格早于当前时刻的声景特征预测当前背景频谱，并条件化同一个 BS-RoFormer 骨干；事件声轨使用合成真值监督，背景估计为混合减去事件估计。

TABLE I
匹配的 5 秒条件注入消融（dB）。

注入方式	验证 SI-SDRi	测试 SI-SDRi	配对 Δ_0
无条件	4.864	4.059	0
拼接	5.343	4.432	+0.623
FiLM	**5.419**	**4.468**	**+0.692**
交叉注意力	5.128	4.261	+0.331

TABLE II
主实验：留出日期的干净真实背景与合成事件全参考测试（dB）。

模型	SI-SDRi	目标 SI-SDR	背景 SI-SDR
BS-RoFormer	9.631	6.479	10.061
FC-BSR（GRU+FiLM）	9.497	6.345	10.155

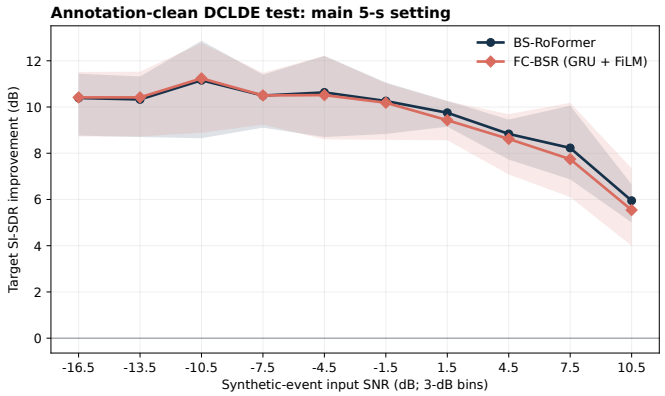


Fig. 2. 标注干净 DCLDE 背景上的主全参考实验。横轴为合成事件强度，纵轴为目标 SI-SDRi；比较匹配的 BS-RoFormer 与 FC-BSR 主设置，区间按录音日期分块。

III. 实验与结果

A. 条件机制选择与信号多样性

表 I 只按验证集选择 FiLM。在 832 个固定 0-dB 配对样本（每族 64 个）上，它将 SI-SDRi 从 4.850 提高到 5.541 dB。逐频带缩放与偏置可以直接表达“此处为预期能量”；拼接需要压缩加倍特征，交叉注意力则必须在相同预算内从粗条件中学习对齐。

FiLM 在五类鲸声代理上的增益依次为 0.869、0.835、0.919、0.906 与 0.806 dB。船舶音调最难：尽管相对增益为 0.320 dB，条件模型的绝对 SI-SDRi 仍为 -8.295 dB。总体增益与 JS 的相关性很弱（$r = -.057$），与频谱熵也仅为 $r = .122$；因此提高散度能扩大覆盖，却不能预测先验何时有用。

B. 主结果：标注干净真实背景上的合成事件

主 FC-BSR 固定为 FiLM+5 秒 +GRU+BS-RoFormer，并使用上述事件掩蔽历史及标注干净的真实当前背景；训练集有 37.3 小时可用干净背景。表 II 在按日期留出的测试集上比较它与无条件 BS-RoFormer。两者共享相同的干净背景、合成事件分布、训练初始化、优化预算和验证选点；仅 FC-BSR 接收 GRU 预测条件。测试事件由生成器独立抽样，因而目标声轨和背景声轨均有精确真值。图 2 按注入 SNR 分层展示配对 SI-SDRi，所有点均来自相同的留出干净背景与主设置。4,096 个配对样本上，FC-BSR 的 SI-SDRi 为 9.497 dB，略低于无条件 BS-RoFormer 的 9.631 dB；配对差为 -0.134 dB，按留出日期分块的 95% 区间为 $[-0.320, 0.125]$，因此全局平均差异不能与零区分。

C. 次级消融：预测时间尺度与未标注背景强度

以下实验来自 SanctSound 或未标注连续 WAV，不是干净背景主实验。时间尺度诊断固定相同留出样本；5 秒预测器的验证 MAE 为 1.366 dB，略优于 persistence 的 1.386 dB，其余尺度选择 persistence。这项结果仅说明该消融域中 5 秒特征的预测略有优势，不能替代主设置的留出全参考检验。

TABLE III
真实背景上的预测分辨率诊断。

步长	预测器	条件模型	基线	增益 [95% 区间]
5 秒	GRU	29.753	28.527	1.226 [1.082,1.381]
30 秒	persistence	29.630	28.534	1.095 [0.935,1.265]
1 分钟	persistence	29.661	28.533	1.128 [0.971,1.298]
10 分钟	persistence	29.711	28.535	1.176 [1.036,1.326]

条件模型、基线与增益均为目标 SI-SDRi（dB）。

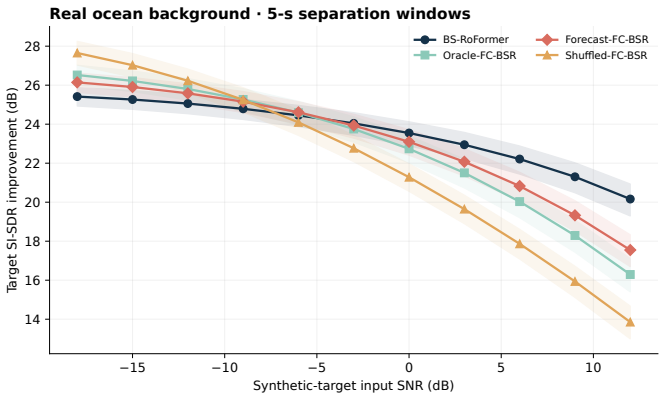


Fig. 3. 未标注 SanctSound WAV 消融：5 秒目标强度扫描。曲线为四种条件，阴影为配对 95% 区间；该图不是标注干净主实验。

另一个未标注 WAV 消融在 1152 个配对测试混合上比较 BS-RoFormer、当前真值频谱 oracle、因果预测和错时条件。跨训练 SNR 平均后，基线为 23.470 dB，Forecast-FC-BSR 为 22.871 dB（$\Delta = -0.599$，区间 $[-0.851, -0.346]$），oracle 平均值也更低。这暴露了简单分辨率诊断没有显示的条件化/容量影响。图 3 进一步表明：在 $-18, -15, -12, -9, -6$ dB，预测条件分别提高 0.728、0.643、0.525、0.366、0.157 dB；从 -3 dB 开始转为落后。错时条件对最弱目标也有收益，却随 SNR 上升迅速退化，因此不能把弱目标增益完全归因于预测的时间准确性；正则化或额外容量仍是可能解释。

D. 没有分离真值的真实事件

参考学习式无参考指标 [24], [25] 和语义音频嵌入 [26], [27]，我们训练、校准并冻结二分类器；测试 AUROC、AP 与 F1 分别为.9723、.9755、.9275。混合一致性要求 $\hat{N} = x - \hat{s}$。将 $\hat{s}$ 按 $\{-60, -30, -24, -18, -12, -6, 0\}$ dB 逐级恢复，检查事件概率是否单调回升；Identity 与 all-to-event 排除平凡解，标注区间外变化审计背景保留。

真实事件评估使用主设置同一冻结的 12 步事件掩蔽历史预测器。由于近期事件历史被排除，测试中有 103 个真实事件保留完整 60 秒历史。表 IV 显示 FC-BSR 的残余事件概率和区间外改动呈下降趋势，事件声轨概率近似不变。按留出日期分块后，残余事件概率差 -0.0731 的 95% 区间为 $[-.2090, .0294]$，事件声轨概率差 $+.0022$ 的区间为 $[-.0180, .0304]$，单调率差 $+.0178$ 的区间为 $[-.0333, .0429]$，均包含零；区间外相对误差差 $-.0248$ 的区间为 $[-.0456, -.0018]$。因此该小样本提供有利但不确定的语义迹象，仍没有真实分离声轨真值。

IV. 讨论与结论

证据支持的结论比初始假设更窄：在标注干净主测试中，FC-BSR 没有提高平均 SI-SDRi，且 95% 区间跨零。FiLM 是受控真值下最佳的条件接口；未标注 WAV 的次级强度消融中，先验对弱目标有帮助，但该观察不能替代标注干净主实验。其收益也并不普遍：信号增强后增益反转，oracle 也未改善该消融的平均值，且未修改鲸声上没有显示预测条件优势尚不确定。四种预测分辨率中还有三种由 persistence 获胜。这些负对照很关键：它们区分了“背景信息存在价值”与“当前架构总能利用该信息”。

本地前端可用于实验检查：在已准备历史特征的 CPU 冒烟测试中，单个 5 秒块 RTF 为 0.014；界面可显示预测并试听、下载两条估计声轨，但这不等于野外部署。后续应根据预测不确定性选择性启用条件，覆盖多站点、多季节，并为真实事件获取隔离声轨或更强局部参考。分类器恢复曲线是语义迁移证据，不能替代波形保真真值。

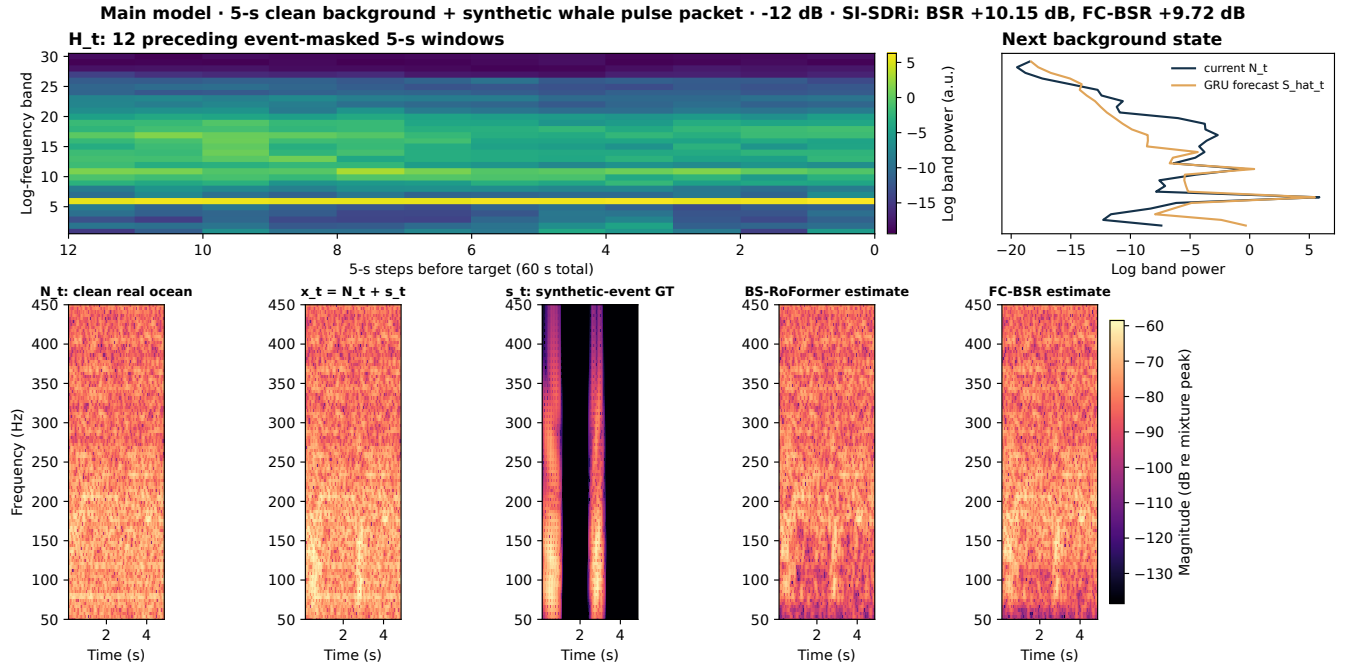


Fig. 4. 标注干净 DCLDE 背景中按组内中位数选择的鲸声脉冲包示例（−12 dB，5 秒）。所有频谱共用以混合峰值为参照的色标；总体强度结果见图 2。

TABLE IV
103 个具有合格历史的真实事件上的无参考匹配比较。

方法	$p(x)$	$p(\hat{N})\downarrow$	$p(\hat{s})\uparrow$	单调率 ↑	区间外 ↓
BS-RoFormer	.909	.786	.900	.937	.230
FC-BSR	.909	.713	.902	.955	.206

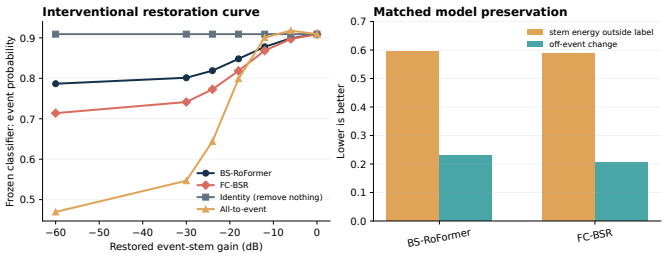


Fig. 5. 无参考恢复曲线与背景保留审计。两种模型都进行了非平凡语义分离，但 FC-BSR 在真实事件上没有全面胜出。

References

[1] J. L. Miksis-Olds, D. L. Bradley, and X. M. Niu, "Decadal trends in indian ocean ambient sound," *Journal of the Acoustical Society of America*, vol. 134, no. 5, pp. 3464–3475, 2013.

[2] Y. Luo and N. Mesgarani, "Conv-TasNet: Surpassing ideal time–frequency magnitude masking for speech separation," *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, vol. 27, no. 8, pp. 1256–1266, 2019.

[3] Y. Luo, Z. Chen, and T. Yoshioka, "Dual-path RNN: Efficient long sequence modeling for time-domain single-channel speech separation," in *Proc. IEEE ICASSP*, 2020, pp. 46–50.

[4] C. Subakan, M. Ravanelli, S. Cornell, M. Bronzi, and J. Zhong, "Attention is all you need in speech separation," in *Proc. IEEE ICASSP*, 2021, pp. 21–25.

[5] Z.-Q. Wang, S. Cornell, S. Choi, Y. Lee, B.-Y. Kim, and S. Watanabe, "TF-GridNet: Integrating full- and sub-band modeling for speech separation," in *Proc. IEEE ICASSP*, 2023, pp. 1–5.

[6] Y. Luo and J. Yu, "Music source separation with band-split RNN," *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, vol. 31, pp. 1893–1901, 2023.

[7] W.-T. Lu, J.-C. Wang, Q. Kong, and Y.-N. Hung, "Music source separation with band-split RoPE transformer," *arXiv preprint arXiv:2309.02612*, 2023. [Online]. Available: https://arxiv.org/abs/2309.02612

[8] S. Rouard, F. Massa, and A. Défossez, "Hybrid transformers for music source separation," in *Proc. IEEE ICASSP*, 2023, pp. 1–5.

[9] S. Wisdom, E. Tzinis, H. Erdogan, R. J. Weiss, K. Wilson, and J. R. Hershey, "Unsupervised sound separation using mixture invariant training," in *Advances in Neural Information Processing Systems*, vol. 33, 2020, pp. 3846–3857.

[10] E. Perez, F. Strub, H. de Vries, V. Dumoulin, and A. Courville, "FiLM: Visual reasoning with a general conditioning layer," in *Proc. AAAI Conference on Artificial Intelligence*, vol. 32, no. 1, 2018.

[11] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, "Attention is all you need," in *Advances in Neural Information Processing Systems*, vol. 30, 2017.

[12] H. Zhao, C. Gan, A. Rouditchenko, C. Vondrick, J. McDermott, and A. Torralba, "The sound of pixels," in *Proc. European Conference on Computer Vision*, 2018, pp. 570–586.

[13] D. Salinas, V. Flunkert, J. Gasthaus, and T. Januschowski, "DeepAR: Probabilistic forecasting with autoregressive recurrent networks," *International Journal of Forecasting*, vol. 36, no. 3, pp. 1181–1191, 2020.

[14] B. N. Oreshkin, D. Carpov, N. Chapados, and Y. Bengio, "N-BEATS: Neural basis expansion analysis for interpretable time series forecasting," in *International Conference on Learning Representations*, 2020.

[15] A. Zeng, M. Chen, L. Zhang, and Q. Xu, "Are transformers effective for time series forecasting?" in *Proc. AAAI Conference on Artificial Intelligence*, vol. 37, no. 9, 2023, pp. 11 121–11 128.

[16] Y. Nie, N. H. Nguyen, P. Sinthong, and J. Kalagnanam, "A time series is worth 64 words: Long-term forecasting with transformers," in *International Conference on Learning Representations*, 2023.

[17] T. Gneiting, "Making and evaluating point forecasts," *Journal of the American Statistical Association*, vol. 106, no. 494, pp. 746–762, 2011.

[18] NOAA Office of National Marine Sanctuaries and U.S. Navy, "SanctSound raw passive acoustic data," NOAA NCEI dataset, 2020.

[19] J. Lin, "Divergence measures based on the shannon entropy," *IEEE Transactions on Information Theory*, vol. 37, no. 1, pp. 145–151, 1991.

[20] D. Gillespie, M. Caillat, and J. Gordon, "DCLDE 2013 workshop dataset," 2019.

[21] Y. Shiu, K. J. Palmer, M. A. Roch, E. Fleishman, X. Liu, E.-M. Nosal, T. Helble, D. Cholewiak, D. Gillespie, and H. Klinck, "Deep neural networks for automated detection of marine mammal species," *Scientific Reports*, vol. 10, p. 607, 2020.

[22] E. Vincent, R. Gribonval, and C. Févotte, "Performance measurement in blind audio source separation," *IEEE Transactions on Audio, Speech, and Language Processing*, vol. 14, no. 4, pp. 1462–1469, 2006.

[23] J. Le Roux, S. Wisdom, H. Erdogan, and J. R. Hershey, "SDR—half-baked or well done?" in *Proc. IEEE ICASSP*, 2019, pp. 626–630.

[24] K. Kilgour, M. Zuluaga, D. Roblek, and M. Sharifi, "Fréchet audio distance: A reference-free metric for evaluating music enhancement algorithms," in *Proc. Interspeech*, 2019, pp. 2350–2354.

[25] E. M. Grais, H. Wierstorf, D. Ward, R. D. Mason, and M. D. Plumbley, "Referenceless performance evaluation of audio source separation using deep neural networks," in *Proc. European Signal Processing Conference*, 2019.

[26] Y. Wu, K. Chen, T. Zhang, Y. Hui, M. Nezhurina, T. Berg-Kirkpatrick, and S. Dubnov, "Large-scale contrastive language–audio pretraining with feature fusion and keyword-to-caption augmentation," in *Proc. IEEE ICASSP*, 2023, pp. 1–5.

[27] X. Xiao, H. Jin, Z. Chen, A. Gram, G. Wichern, and J. Le Roux, "A reference-free metric for language-queried audio source separation using contrastive language–audio pretraining," in *Proc. DCASE Workshop*, 2024.