高分辨率因果背景先验驱动的海洋声音分离

匿名作者
匿名单位

***Abstract*—本文检验从过去海洋声景得到的因果背景先验能否改善下一段 5 秒事件分离。DCLDE 主实验把标注干净的真实海洋背景与合成目标混合，因而具有精确声轨真值。前期 30 频带 FiLM 未奏效；信息阶梯引出保留时间维的 128 频组背景图、显式“混合减背景”创新图及 BS-RoFormer 残差适配器。在 4,096 个匹配测试混合上，三个分离器种子的平均目标 SI-SDRi 为：过去 60 秒 Persistence 13.912 dB，固定均值 Zero 11.511 dB，错日 Shuffled 11.767 dB，普通 BS-RoFormer 9.635 dB。Persistence 比 Zero 和 Shuffled 分别稳定提高 $2.400 \pm .237$ 与 $2.145 \pm .181$ dB，九个种子与日期组合均为正；学习式 GRU 没有跨种子稳定优于 Persistence（差值 $+.017 \pm .036$ dB）。单种子的当前真实背景 Oracle 达 16.767 dB。在此前未使用的圣劳伦斯湾新站点 373 个真实标注鲸声上，正确历史比错文件背景降低了冻结检测器对背景声轨的事件响应，却轻微损害事件声轨响应与区间外背景保留。由于没有真实隔离鲸声，这些指标只能说明部分迁移。**

***Index Terms*—海洋声学，源分离，因果背景先验，BS-RoFormer，无参考评估**

I. 引言

海洋背景随航运、天气、生物活动和季节变化 [1]。仅使用混合声音的分离器必须从同一观测中同时推断突发事件与变化背景。本文从历史声景提取严格因果的高分辨率先验：

$$\begin{aligned} & x_t = N_t + s_t, \qquad \widehat{B}_t = P(H_t), \\ & \widehat{R}_t = \log|X_t| - \widehat{B}_t, \\ & [X_t, \widehat{B}_t, \widehat{R}_t] \xrightarrow{\text{Residual+BSR}} (\hat{s}_t, \hat{N}_t), \end{aligned} \tag{1}$$

其中 H_t 屏蔽所有已标注事件及其保护区，N_t 是真实、标注干净的当前 5 秒录音；模型只观察 x_t, H_t，而 N_t, s_t 提供精确监督。X_t 为当前混合 STFT，$\widehat{B}_t$ 是因果背景对数幅度图，P 可直接沿用上一窗，也可为学习式预测器。旧 30 频带 FiLM 在留出集失效，促使我们通过信息阶梯选择 128 个频率组和显式残差接口（图 1）。

时域分离器 [2], [3]、注意力模型 [4], [5] 和子带系统 [6], [7] 提供了强大的仅混合输入骨干。混合 Transformer 与 MixIT 扩展了架构和监督方式 [8], [9]，但没有检验下一时刻背景预测。FiLM、交叉注意力与跨模态分离 [10]–[12] 启发了三种接口；递归、线性与分块预测模型则提供时间序列基线 [13]–[16]。

本文贡献形成一条连续证据链：（1）信息阶梯解释粗条件的失败；（2）事件掩蔽的真实干净背景历史、128 频组显式创新与残差接口；[1] （3）Zero、Shuffled、Persistence、Forecast、Oracle 匹配对照及三个分离器种子；（4）未使用站点的冻结模型评估。真实事件适配实验用于分析迁移局限，不替代具有精确声轨的主实验。

[1]代码与复现实验说明：https://github.com/D-eval/ocean_noise_pred_splite。

II. 方法

A. 高分辨率因果残差分离器

主历史 $H_t \in \mathbb{R}^{12\times79\times128}$ 包含严格早于当前的 12 张 5 秒对数幅度图。在 2 kHz 录音上以 512 点 Hann STFT 和 128 点帧移计算，每窗保留 79 帧、128 个等宽频组。标注事件窗被掩蔽，只在过去 60 秒内部用邻近干净窗填补。主因果参考是直接沿用最后一张图，即 $\widehat{B}_t = B_{t-1}$。比较分支使用轻量残差 GRU：每张图压成四个时间块，处理 12 步后预测未来 79×128 图；零初始化解码器从 Persistence 起步。GRU 只在训练日干净背景上训练，按验证背景图 MAE 选点，并在分离器训练前冻结。

在同一网格上计算 $\widehat{R}_t = \log|X_t| - \widehat{B}_t$。将 $[\widehat{B}_t, \widehat{R}_t]$ 对齐 BSR 帧网格，经零初始化的残差投影加到由混合声音得到的子带 token，再进入轴向注意力。因此所有条件分离器在训练前与同一个迁移初始化的普通 BSR 波形映射完全一致。用合成事件的精确声轨计算波形和多分辨率 STFT 损失。图 1 区分了训练真值与实际推理输入。

B. 前期 *30* 频带 *FiLM* 设计

前期模型将当前窗之前的 12 个干净 5 秒片段各压成 30 个对数功率频带，用残差 GRU 预测下一窗摘要，再以 FiLM 缩放、平移 BS-RoFormer 子带特征。匹配对照把预测替换为零、错日摘要、上一窗摘要或当前真实背景的 $E(N_t)$。最后一种称为 *30* 频带 *Oracle-FiLM*，但 E 已丢失窗内时间结构和相位，不能作为丰富背景表示的上界。本文只保留它解释后文的信息阶梯。

C. 海洋感知合成信号分布

广分布生成器包含 13 类：谐波、线性啁啾、非谐波、脉冲列、调频音、带限噪声、鲸声上扫、下扫、拱形、S 形、脉冲包、船舶音调和船舶空化。鲸声代理由 1–3 个局部事件组成，随机改变时长、曲率、分音、渐入渐出与抖动。船舶音调和窄带空化分量以 0.8 概率采用 5–20 Hz 低频振荡器（LFO）音量包络；宽带分量不做该调制。训练 SNR 在 $[-18, 12]$ dB 均匀抽样。这些代理用于覆盖轮廓和调制样式，并不声称对应具体物种。

频谱位移同时用方向性 $D_{\mathrm{KL}}(p\|q)$ 和有限对称 JS 散度 [17] 衡量，另报告频谱熵与信号–海洋频谱重叠。更大的 KL/JS 只代表覆盖范围更广，不等价于语义多样性。主 DCLDE 实验仅从其中 5 类鲸声和 2 类船噪抽样，六组模型使用同一目标分布。

D. 主数据构造与消融协议

主数据由按日期隔离的 2-kHz DCLDE 2013 录音及鲸声标注组成 [18], [19]。在 168 小时 WAV 中，移除已标注事件及两侧各 2 秒保护区后，得到 146.4 小时标注干净的 5 秒窗口。每个当前窗使用同一 WAV 中紧邻其前的 12 个 5 秒块构造高分辨率历史。标注事件及两侧 2 秒保护区被

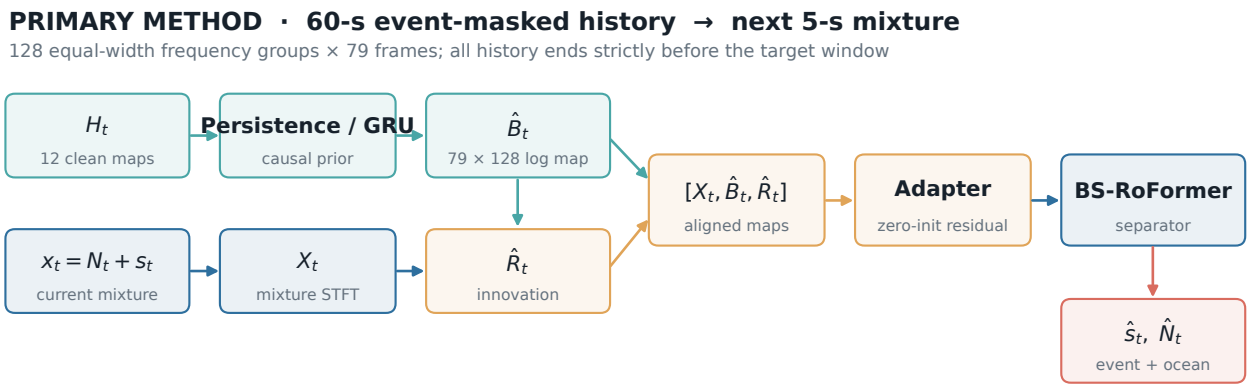


Fig. 1. 128 频组因果残差主架构。事件掩蔽的过去 60 秒历史通过 Persistence 或 GRU 提供未来 5 秒背景图；显式创新为 $\hat{R}_t = \log|X_t| - \hat{B}_t$。Zero、错日 Shuffled、Persistence、Forecast 和当前背景 Oracle 共用同一残差适配器。只有 Oracle 在输入端使用当前干净背景。

TABLE I
匹配的 5 秒条件注入消融（dB）。

注入方式	验证 SI-SDRi	测试 SI-SDRi	配对 Δ_0
无条件	4.864	4.059	0
拼接	5.343	4.432	+0.623
FiLM	**5.419**	**4.468**	**+0.692**
交叉注意力	5.128	4.261	+0.331

TABLE II
前期 30 频带 FiLM 审计：同一 4,096 个 DCLDE 混合上的测试目标 SI-SDRi（dB）；Oracle 只读取 $E(N_t)$。

条件	测试 SI-SDRi
BS-RoFormer / Zero-FiLM	9.631 / 9.631
Shuffled / Persistence-FiLM	9.526 / 9.524
GRU-Forecast / Oracle-FiLM	9.497 / 9.535

屏蔽；68,075 个合格当前窗中有 235 个历史仅缺一块，由过去 60 秒内部最近的干净块填补。历史不跨 WAV 边界，也不读取当前窗。筛选后共 94.5 小时符合条件，训练/验证/测试分别为 37.3/9.7/47.6 小时。每个当前背景 N_t 与上述 7 类海洋合成事件 s_t 相加得到 $x_t = N_t + s_t$。模型输入只有 x_t, H_t，而 N_t, s_t 是监督真值。主设置固定为 128 组逐帧残差接口、5 秒目标窗和过去 60 秒历史。

次级消融采用 NOAA–Navy SanctSound 小时级 TOL 产品 [20]。MB03 部署 01–02/03/04 分别用于训练/验证/测试。随机相位逆变换只产生受控频谱代理，不能视为恢复音频。条件机制、KL/JS 覆盖、预测时间尺度，以及 42 小时未标注连续 WAV 上的强度扫描均属于消融；后者缺乏事件标注，不能作为主干的干净背景证据。

全参考分离使用尺度不变投影的 SI-SDR 与 SI-SDRi [21], [22]。区间使用固定种子的配对 bootstrap；主测试按留出录音日分块。当前测试特征仅作监督目标，GRU 历史严格截止于 t 之前。

III. 实验与结果

A. 前期条件机制选择与信号多样性

前期 30 频带方案按验证集选择 FiLM。表 I 在 832 个固定 0-dB 配对样本（每族 64 个）上比较各接口，它将 SI-SDRi 从 4.850 提高到 5.541 dB。逐频带缩放与偏置可以直接表达“此处为预期能量”；拼接需要压缩加倍特征，交叉注意力则必须在相同预算内从粗条件中学习对齐。

FiLM 在五类鲸声代理上的增益依次为 0.869、0.835、0.919、0.906 与 0.806 dB。船舶音调最难：尽管相对增益为 0.320 dB，条件模型的绝对 SI-SDRi 仍为 −8.295 dB。总体增益与 JS 的相关性很弱（$r = -.057$），与频谱熵也仅为 $r = .122$；因此提高散度能扩大覆盖，却不能预测先验何时有用。

B. 前期 30 频带诊断

我们纠正前期误将 Zero-FiLM 标成无条件 BSR 的问题，保留原检查点作为 Zero-FiLM，并另训真正绕过注入器的 BS-RoFormer。六路 30 频带模型共用相同混合、骨干初值、训练与选点规则，在三个留出日的 4,096 个混合上比较。没有一路优于 BSR（表 II）；当前背景 Oracle 也只看到压缩后的 $E(N_t)$，得 9.535 dB，对比 BSR 的 9.631 dB。GRU 虽在验证集把频谱 MAE 从 persistence 的 2.111 降至 1.926 dB，仍未带来分离收益。

a) 全波形抄答案校验。: 冻结同一 BSR，在它的输出、混合及条件波形上拟合三系数融合头。当条件为实际 N_t，学得 $\hat{s}_t = x_t - N_t$，测试 SI-SDRi 达到数值精度限制的 80.755 dB；零波形和错时波形均为 9.231 dB。这是非因果的答案通路校验，不能证明 30 频带 FiLM 或因果预测有效。

b) Oracle 信息阶梯。: 我们固定冻结 BSR、三系数融合头、训练样本及 4,096 个匹配的测试混合，逐层压缩当前背景 N_t。在 2 kHz 音频上使用 512 点 Hann STFT（257 个频率 bin，帧步长 64 ms），将背景功率沿频率合并为

128/64/32 个等宽相邻组，或 128/64/48/30 个 20–950 Hz 对数频带；另沿时间合并为 0.25、1、5 秒。保留的幅度配合真实 N_t 相位或混合 x_t 相位做逆变换。边缘 bin 并入最近的对数带；名义 128 个对数带中，实际只有 95 个含 STFT bin。最粗的 30 频带/5 秒功率类似原始 $E(N_t)$，但数值定义并不完全相同。

图 2 显示这条固定答案通路在哪里失去留出收益。完整幅度改用混合相位，相对 BSR 仍提高 11.164 dB（日期分块区间 $[10.889, 11.594]$）。等宽 128 组仍提高 $+2.067$ dB（$[0.969, 3.386]$）；等宽 64 组为 -0.623 dB（$[-1.404, 0.259]$），可靠的正收益在这两级之间消失。对数 128 带已为 -0.529 dB （$[-1.257, 0.319]$），逐帧 30 带为 -0.672 dB（$[-1.323, 0.086]$）。即便逐帧 30 带保留真实背景相位，也仅提高 $+0.117$ dB（$[-0.671, 1.084]$）。相比之下，保留全部 257 个频率 bin、只把功率按 1 秒汇总并使用混合相位，仍提高 $+0.585$ dB（$[0.285, 1.132]$）；按整段 5 秒汇总则为 $+0.249$ dB （$[-0.044, 0.495]$）。因此在这一答案通路中，频率平均及其分带规则比单独汇总时间更容易使条件失效。这不构成信息论极限，也不是新增的 FiLM 消融。

C. 主实验：*128* 组逐帧残差条件

a) 训练后的高分辨率 *Oracle* 残差分离器。*:* 我们进一步在真正的 BS-RoFormer 中检验这一表示，而不是只使用冻结的线性抄答案头。当前实际背景 N_t 与混合 x_t 经 512 点、128 点帧移的 STFT，按 128 个等宽频率组取平均功率，形成保留时间维的 $\log|B_t|$；显式创新图在同一网格上定义为 $R_t = \log|X_t| - \log|B_t|$。将这两张图插值到 BSR 的帧网格后，通过零初始化线性投影加到由混合声音得到的子带 token，再送入轴向注意力。这是残差形式的 $[X_t, B_t, R_t]$ 输入，没有使用 FiLM 或预测器；训练前输出与普通 BSR 完全相同（最大波形差值为零）。

两种模型使用相同的按日期隔离 DCLDE 混合、骨干迁移初值、种子、批次顺序、6,000 次更新、AdamW/余弦日程、损失和验证最高分选点规则。原 BSR 选中第 5,300 步，新模型选中第 6,000 步。在 4,096 个匹配测试样本上，普通 BSR 的目标 SI-SDRi 为 9.631 dB，Oracle-Residual-BSR 为 16.767 dB；配对增益 $+7.136$ dB，按录音日分块的 95% 区间为 $[6.970, 7.282]$，三个留出日均为正。因此高分辨率当前背景与显式创新接口的组合在这个受控实验中确实有用。部署时无法获得真实 N_t；这项双模型可行性比较也没有单独排除新增适配器参数量的影响。

b) 因果高分辨率残差条件。*:* 随后将当前背景的 Oracle 图换成严格由过去 60 秒得到的两种条件。历史由 12 个 5 秒窗组成，每窗均为 79×128 的对数幅度图。与事件标注重叠的窗被掩蔽；若某个位置缺失，只从这 60 秒内选择距离最近的无事件窗填入。68,075 个合格当前窗中有 235 个受到这种填补影响。Persistence 直接使用最后一个干净历史图；轻量 GRU 先将每张图汇聚为四个时间块，处理 12 个历史步，再解码对 Persistence 的残差修正，输出完整的未来 79×128 背景对数幅度图；预测时不读取当前波形。预测器在训练日的干净背景上更新 3,000 次，按验证集对数幅度 MAE 选点并冻结。GRU 的验证 MAE 为 0.5456，Persistence 为 0.5518，相对下降 1.12%。在留出测试日上，对应的背景图 MAE 分别为 0.5308 和 0.5386。

对每种背景条件图 B，计算 $R = \log|X_t| - B$，将 $[X_t, B, R]$ 送入与 Oracle 完全相同的残差适配器。Zero 在每帧重复训练集固定的逐频组平均对数背景；Shuffled 使用另一录音日的标注干净 B_j：训练和测试各自在本划分内抽样；验证集仅有一天，因此从训练日取错误背景。Persistence 使用最后一个干净历史图，Forecast 使用冻结 GRU 输出。四路分离器共享迁移 BSR 骨干和零初始化适配器，初始波形输出与普通 BSR 完全相同；合成目标、训练样本顺序、6,000 次更新、优化器、损失、验证最高分选点规则、留出混合均相同。四路只改变条件图 B 的来源。

TABLE III
4,096 个干净背景 DCLDE 混合上的匹配测试。五路残差模型共用相同的 128 频组适配器；Zero 使用训练集固定均值，Shuffled 使用另一录音日背景。只有 Oracle 使用当前真值。数值为目标 SI-SDRi 均值（dB）。

条件	SI-SDRi	相对 BSR 增益
BSR（仅混合）	9.631	—
Zero-Residual	12.156	+2.525
Shuffled-Residual	11.944	+2.313
Persistence-Residual	14.295	+4.664
GRU-Forecast-Residual	14.351	+4.720
Oracle-Residual	16.767	+7.136

表 III 分开了接口与背景信息的作用。Zero 比普通 BSR 高 $+2.525$ dB（按录音日配对的 95% 区间 $[2.262, 2.701]$），Shuffled 高 $+2.313$ dB（$[2.027, 2.905]$），因此不能把因果模型相对 BSR 的全部提升归因于正确历史。Zero 与 BSR 的差异同时包含新增适配器和创新通路中的当前混合对数谱，尚不能单独量化参数量的作用。固定适配器后，Persistence 比 Zero 高 $+2.138$ dB（$[1.775, 2.377]$），比错日 Shuffled 高 $+2.351$ dB （$[1.571, 2.661]$）；三个测试日均为正。这表明与当前时刻相关的历史背景确实提供了超出结构和任意背景图的信息。在原始这个种子上，Forecast 相对 Persistence 仅提高 $+0.056$ dB（$[0.036, 0.074]$），三个测试日同向；后面的表 IV 表明这点微小的 GRU 增益并不跨训练种子稳定。该种子上的 Forecast 恢复了 Oracle 相对 BSR 增益的 66.1%，与 Oracle 仍差 2.416 dB （$[2.114, 2.640]$）。

D. 固定混合上的三个分离器随机种子

原有结果作为第一个种子，再以两个新种子分别重训 BSR、Zero、Shuffled、Persistence 与 Forecast。五路模型在每个种子下采用相同的骨干迁移初始化、训练混合、6,000 次更新、4,096 个验证混合、每 100 步验证一次和最佳验证选点规则。所有模型最后测试同一批固定的 4,096 个混合；比较前逐例检查编号、强度与混合 SI-SDR 完全匹配。背景 GRU 始终使用先前选定并冻结的同一个检查点，因此本实验估计的是分离器训练种子敏感性，不涵盖预测器重新训练的方差。

正确历史在三个种子及每个种子的三个测试日上都高于两种匹配对照。它相比 Zero 高 $2.400 \pm .237$ dB，相比错日 Shuffled 高 $2.145 \pm .181$ dB，因此历史信息的主结论跨分离器初始化仍成立。Forecast 只在三个种子中的两个高于 Persistence，平均差为 $+.017 \pm .036$ dB，不能支持学习式 GRU 稳定提高分离性能。原种子按日期配对的正区间只描述该已训练模型的条件结果，不能代表跨训练种子的误差范围。

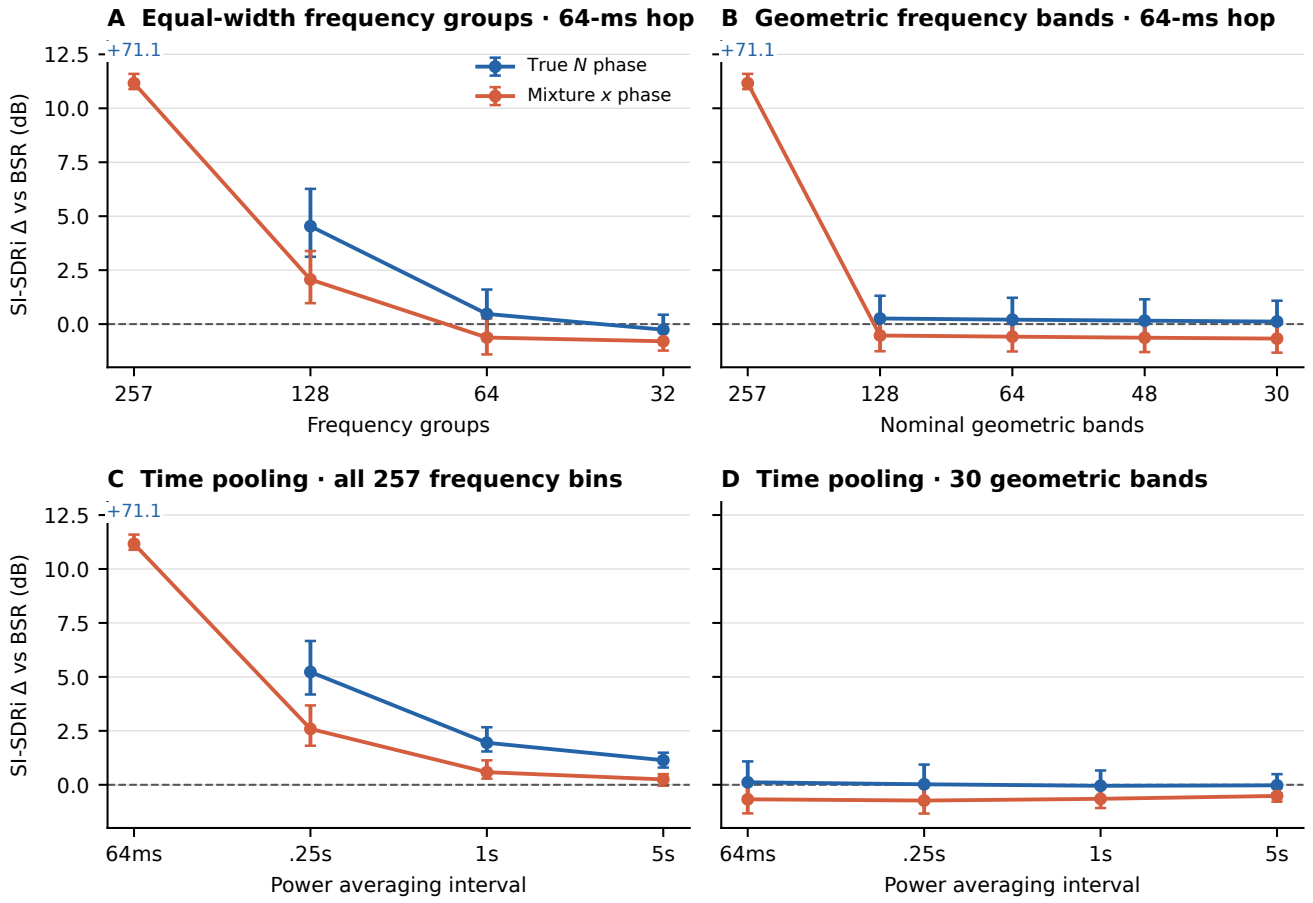


Fig. 2. 同一组 DCLDE 测试混合上的当前背景 Oracle 信息阶梯。每个点在训练混合上拟合相同结构的三系数答案头；误差棒为相对冻结 BSR 的 SI-SDRi 按日期配对的 95% 区间。完整分辨率且使用真实相位的 N_t 提高 71.1 dB，超出绘图范围；混合相位是独立的信息损失。阈值依赖分带方式和当前答案接口。

E. 次级消融：预测时间尺度与未标注背景强度

以下实验来自 SanctSound 或未标注连续 WAV，不是干净背景主实验。时间尺度诊断固定相同留出样本；5 秒预测器的验证 MAE 为 1.366 dB，略优于 persistence 的 1.386 dB，其余尺度选择 persistence。这项结果仅说明该消融域中 5 秒特征的预测略有优势，不能替代主设置的留出全参考检验。

另一个未标注 SanctSound WAV 消融在 1152 个配对测试混合上比较零条件 FiLM、当前真值频谱 oracle、因果预测和错时条件。这里的 oracle 属于次级数据域；表 II 中的主域 30 频带 Oracle 使用标注干净 DCLDE 的实际 N_t 提取 $E(N_t)$。跨训练 SNR 平均后，零条件 FiLM 为 23.470 dB，Forecast-FC-BSR 为 22.871 dB （$\Delta = -0.599$，区间 $[-0.851, -0.346]$），oracle 平均值也更低。这暴露了简单分辨率诊断没有显示的条件化/容量影响。图 3 进一步表明：在 $-18, -15, -12, -9, -6$ dB，预测条件分别提高 0.728、0.643、0.525、0.366、0.157 dB；从 -3 dB 开始转为落后。错时条件对最弱目标也有收益，却随 SNR 上升迅速退化，因此不能把弱目标增益完全归因于预测的时间准确性；正则化或额外容量仍是可能解释。

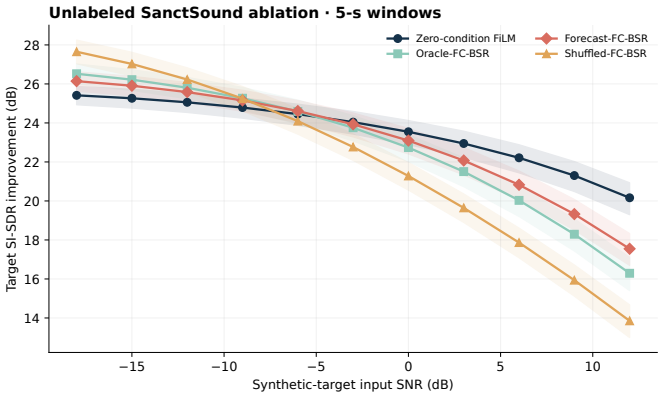


Fig. 3. 未标注 SanctSound WAV 消融：5 秒目标强度扫描。曲线为四种条件，阴影为配对 95% 区间；该图不是标注干净主实验。

IV. 探索性真实事件诊断

以下实验用于检查外推与失败模式，不能代替有精确声轨的 DCLDE 主测试。后续目标校准与弱监督变体反复使

TABLE IV
同一批 4,096 个 DCLDE 混合上的三个分离器种子。前五行是目标 SI-SDRi（dB），后三行是逐样本配对差（dB）；末列为跨种子均值 ± 样本标准差。Oracle 只有原始单种子上界 16.767 dB，未参与重复训练。

方法或配对差	种子 1	种子 2	种子 3	均值 ± 标准差
BS-RoFormer	9.631	9.662	9.613	9.635 ± .025
Zero-Residual	12.156	10.824	11.553	11.511 ± .667
Shuffled-Residual	11.944	11.355	12.002	11.767 ± .358
Persistence-Residual	14.295	13.425	14.015	13.912 ± .444
GRU-Forecast-Residual	14.351	13.431	14.002	13.928 ± .465
Persistence − Zero	+2.138	+2.601	+2.461	+2.400 ± .237
Persistence − Shuffled	+2.351	+2.070	+2.013	+2.145 ± .181
Forecast − Persistence	+.056	+.005	−.012	+.017 ± .036

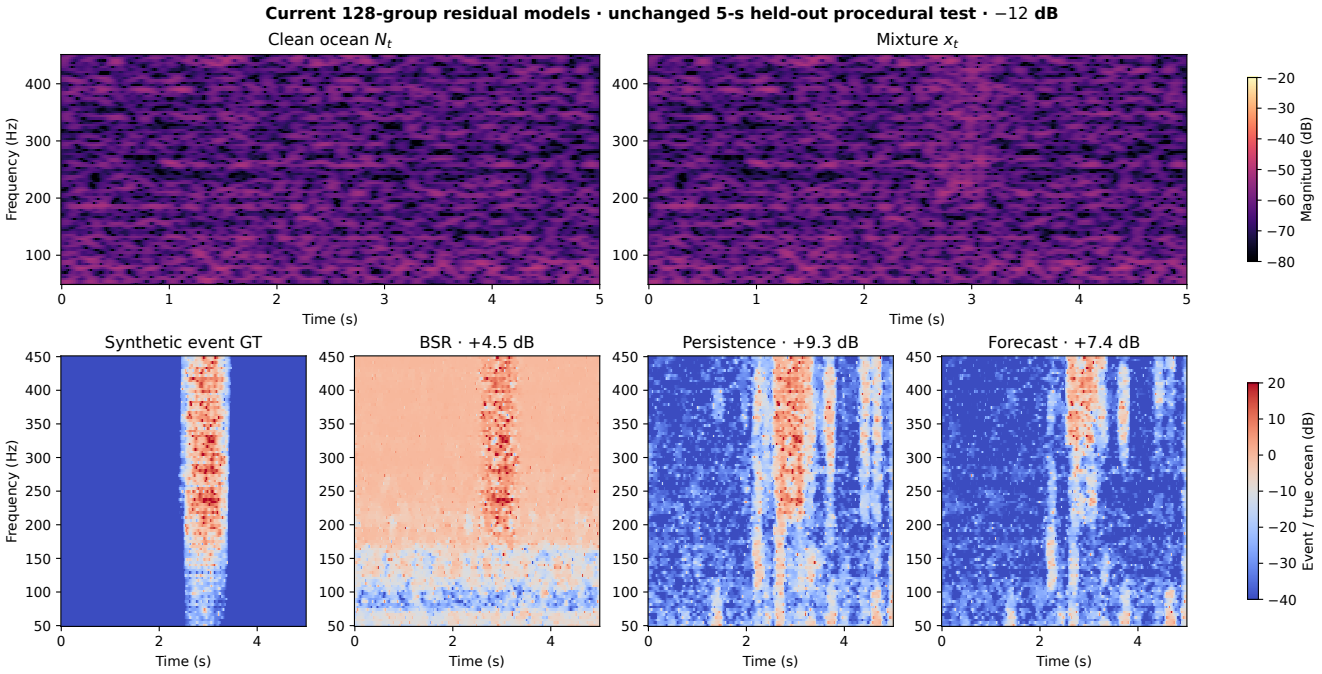


Fig. 4. 当前 128 组残差分离器在未改动的留出程序合成鲸声脉冲包上的结果（−12 dB，5 秒）：从 96 个固定样本中按三种模型 SI-SDRi 的联合中位数选例。海洋背景与混合声音共用绝对幅度色标；下排事件声轨共用相对真实背景幅度的 dB 色标。与普通 BSR 相比，Persistence 和 Forecast 明显压低非目标海洋成分，但仍存在局部竖向伪影。对全部 96 个样本，真值目标缺失的时频格点上，BSR、Persistence、Forecast 的事件声轨相对海洋背景对比度中位数分别为 −1.37、−31.44、−36.46 dB。该受控合成指标不能代表真实鲸声的隔离保真度。

TABLE V
真实背景上的预测分辨率诊断。

步长	预测器	条件模型	基线	增益 [95% 区间]
5 秒	GRU	29.753	28.527	1.226 [1.082,1.381]
30 秒	persistence	29.630	28.534	1.095 [0.935,1.265]
1 分钟	persistence	29.661	28.533	1.128 [0.971,1.298]
10 分钟	persistence	29.711	28.535	1.176 [1.036,1.326]

条件模型、基线与增益均为目标 SI-SDRi（dB）。

用同一批 103 个真实鲸声，因此其比较属于探索性分析；独立新站点检验见第 V 节。

A. 冻结模型的代理指标

参考学习式无参考指标 [23], [24] 和语义音频嵌入 [25], [26]，我们训练、校准并冻结二分类器；测试 AUROC、AP 与 F1 分别为.9723、.9755、.9275。混合一致性要求 $\hat{N} = x - \hat{s}$。将 $\hat{s}$ 按 $\{-60, -30, -24, -18, -12, -6, 0\}$ dB 逐级恢复，检查事件概率是否单调回升；Identity 与 all-to-event 排除平凡解，标注区间外变化审计背景保留。

本次直接评估冻结的四个 128 频组残差模型，样本与前期 FiLM 审计的 103 个测试鲸声完全相同。每段历史只包含同一 WAV 中严格早于当前的 12 张标注干净背景图；6 段各缺 1 张，在过去 60 秒内部用最近干净窗填补。Zero 使用训练均值，Shuffled 使用另一测试日的干净背景，Persistence 使用最后一张历史图，Forecast 将历史送入冻结 GRU；条件均不读取当前鲸声。表 VI 与图 5 给出结果。

相对 Zero，Persistence 使 $p(\hat{N})$ 下降 .0624（按日配对 95% 区间 $[-.0682, -.0547]$），$p(\hat{s})$ 上升 .0469（$[.0198, .1006]$），区间外变化下降 .0255（$[-.0386, -.0077]$）；Forecast 与 Zero 比较也同向，$p(\hat{N})$ 差为 −.0531，区间外变化差为 −.0260。但错日 Shuffled 的 $p(\hat{N})$ 比两种因果条件更低、$p(\hat{s})$ 更高：Persistence 减 Shuffled 分别为 +.0471（$[.0317, .0706]$）与

$-.0606$（$[-.0731, -.0404]$）。Persistence 的区间外改动则显著更小，差为 $-.0408$（$[-.0519, -.0320]$）。四路单调率都接近饱和，区分力很弱。因此分类器概率没有重现受控全参考实验的排序：它可能奖励更激进的事件提取，而因果条件更好地保留了事件区间外音频。真实隔离声轨仍不可得。

B. 分类器底噪与合成目标覆盖

为解释较高的 $p(\hat{N})$，我们先把标注干净的测试音频送入同一冻结分类器，并截成与分离输出相同的 9,984 个采样点。按测试日比例抽取的 4,096 个干净窗平均事件概率为 .153；与 103 个真实事件同 WAV、紧邻事件之前的干净窗为 .176；两组中位数均为 .093。真实混合平均为 .909，四路分离背景的 .781–.891 显著高于干净对照；逐例减去同 WAV 干净对照后的平均差为 .606–.715。该差距说明分类器底噪不能独自解释高响应，但不能换算为泄漏的鲸声能量；分离伪影或漏标事件也可能触发分类器。

我们在每个配对干净窗上按训练时的五种鲸声类型与 $[-18, 12]$ dB 强度范围合成 32 条混合，共 3,296 条，其平均事件概率为 .407。覆盖代理指标取冻结分类器倒数第二层的 64 维激活，并从有事件片段中减去同 WAV 的干净背景激活，按合成样本方差逐维缩放。真实事件之间留一最近邻的中位距离为 .233。若在全部 3,296 条合成样本中搜索，真实到合成的中位距离为 .262，但候选数过多。每轮每个真实事件只取一条合成样本，凑成等量的 103 条；重复 32 轮后，中位最近邻距离为 .483，是真实到真实距离的 2.08 倍。超过真实最近邻距离第 95 百分位阈值的事件比例中位数为 51.5%；使用全部合成样本时只有 3.9%。因此合成样本在等量、分类器依赖的表征中对真实事件的覆盖较稀疏，值得改进目标采样；但没有真实隔离鲸声，真实背景相对前一干净窗的变化也进入该嵌入差；此指标或检测概率都不能单独确定分离背景高响应的物理原因。

C. 训练日目标校准与覆盖验收

我们只用三个训练日拟合目标形态。2798 个标注事件窗中，2616 个在同一 WAV 内找到前后干净参考且具有足够声学超额。对局部背景对数谱插值后，取标注时段及 40–950 Hz 内混合减背景的正超额，平滑成软掩码，并使用混合相位逆变换，得到伪鲸声轨；它不是隔离真值。训练事件提供时长、频率界与轨迹、扫频斜率和曲率、带宽、谐波数与衰减、振幅包络、频率抖动、脉冲间隔和事件数。经验程序合成路线对同一个真实鲸声轮廓联合样本作轻微扰动，同时保留原有的船舶音调与空化噪声；船噪占程序路线的 $4/7$，使总鲸声/船噪比例在期望上与旧训练池一致。另一条路线随机化伪真实声轨的时刻与相位。两路各占新目标池的一半。留出分类器不参与参数拟合或样本筛选。

在相同的 103 个真实事件、32 轮每轮等量候选协议下，新池每轮均包含约一半经验程序目标和一半伪真实目标。真实到目标的中位最近邻距离从 .483 降至 .322；超过真实近邻第 95 百分位阈值的比例中位数从 51.5% 降至 3.4%，32 轮距离均改善，达到预设训练验收条件。冻结分类器对新混合的平均响应从 .407 升至 .647，但这只是外部诊断，不能充当优化目标或声轨保真的证据。

D. 目标池修订后的分离

我们用相同迁移初始化与验证选点规则，各训练 Persistence 与 Forecast 残差分离器 6000 步；背景 GRU 与事件分类器始终冻结。表 VII 与原版严格配对。在同一批真实鲸声上，新 Persistence 的 $p(\hat{N})$ 降低 .1766（按录音日配对 95% 区间 $[-.1920, -.1479]$），$p(\hat{s})$ 提高 .0668（$[.0414, .1166]$）；新 Forecast 的两项变化分别为 $-.1129$ 和 $+.0527$。但区间外改动分别增加 .0215（$[.0151, .0324]$）和 .0068（$[.0002, .0132]$）。新 Persistence 的事件提取更强，新 Forecast 更好地保留标注区间外音频。对完全不变的旧合成测试，SI-SDRi 分别下降 2.100 与 2.620 dB。目标池修订后，冻结 GRU 也没有胜过 Persistence。保留船噪避免了中间鲸声专用池在船舶音调上的严重退化，但旧鲸声代理分数并未保持。新 $p(\hat{N})$ 仍明显高于配对干净背景的 .176。没有真实隔离声轨，这些结果说明目标分布改变了分类器响应，不能证明真实分离波形全面改善。

为单独检查优化程度，我们固定小训练集：相同损失和骨干下，128 个旧程序目标在 3000 步内的训练 SI-SDRi 从 13.85 升至 17.20 dB；128 个经验目标在 20000 步内从 10.57 升至 15.56 dB，末端 SI-SDRi 已明显趋缓；目标缺失区的事件/海洋对比度中位数却从 -32.85 降至 -60.68 dB。这表明受控混合的剩余误差不能简单归结为背景泄漏。随后从原本较强的 Persistence 权重出发，以原学习率的十分之一依次使用 0%、25%、50% 伪真实目标。训练日伪声轨按 80/20 划分，旧程序与留出经验目标各有固定验证套。联合验证选择 25% 阶段的第 6500 步：两套 SI-SDRi 从 16.26/11.12 升至 16.44/11.84 dB。再单独训练 50% 阶段 4000 步虽使目标缺失区更暗，联合 SI-SDRi 却下降。选中模型在不变旧合成测试上为 14.421 dB，但真实鲸声的 $p(\hat{N})/p(\hat{s}) = .819/.823$，没有保住 50/50 模型的 .652/.916。因此延长训练能提高小集拟合并避免旧域遗忘，却不能独自解决真实目标取舍。在固定的 128 个训练混合上，小权重 SI-SDR 附加项比原损失多得 .40 dB；但按相同初始化训练完整数据的 50% 阶段 4000 步，两套验证集的联合分数未超过起点，因此保留原损失。当前受控泄漏审计也不支持继续强化目标缺失区惩罚。

E. 真实标注鲸声的弱监督微调

我们从经验目标池 Persistence 权重出发，每步混合两个训练日有真值的程序/伪真实样本和两个训练日真实标注事件。具有合格因果干净历史的真实事件共 180 段；47 段验证日事件负责选权重，103 段测试事件在选定权重前完全封存。另以训练日 onset/offset 标注训练逐帧扩张卷积检测器 C_A，其验证日逐帧平均精度为 .901。C_A 与最终冻结的整段评估分类器 C_B 架构及训练目标均不同；C_B 和测试日事件均不进入弱监督或选点。

真实混合 x 的背景直接定义为 $\hat{N} = x - \hat{s}$，保证混合一致。在事件标注帧内，弱损失分别降低 $C_A(\hat{N})$、提高 $C_A(\hat{s})$；区间外则惩罚事件声轨相对混合音的 RMS。有真值的一半仍用原多分辨率谱损失。弱损失乘以 0.1，避免检测器损失数值压过有真值监督。验证日以背景检测响应最小为选点目标，同时要求事件响应、区间外改动和旧合成验证 SI-SDRi 满足预先固定的界限。3000 步中选中第 250 步；之后的模型未能保持旧合成验证性能。

在独立 C_B 和同一批 103 个测试鲸声上，$p(\hat{N})$ 从 .652 降到 .408（按录音日配对差的 95% 区间 $[-.365, -.093]$），$p(\hat{s})$ 从 .916 升至 .978（$[.044, .072]$）。区间外相对改动从 .058 到 .061，差值区间 $[-.004, .008]$ 包含零。配对干净背景的平均检测概率是 .176；逐事件干净归一化 logit 残留

TABLE VI
同一批 103 个真实鲸声上的冻结 128 频组残差模型比较。四路使用相同混合声音；没有真实分离声轨。区间外指标为标注外背景相对改动。

方法	$p(x)$	$p(\hat{N})\downarrow$	$p(\hat{s})\uparrow$	单调率 ↑	区间外 ↓
Zero-Residual	.909	.891	.802	.990	.062
Shuffled-Residual	.909	.781	.910	.989	.078
Persistence-Residual	.909	.829	.849	.992	.037
GRU-Forecast-Residual	.909	.838	.842	.989	.036

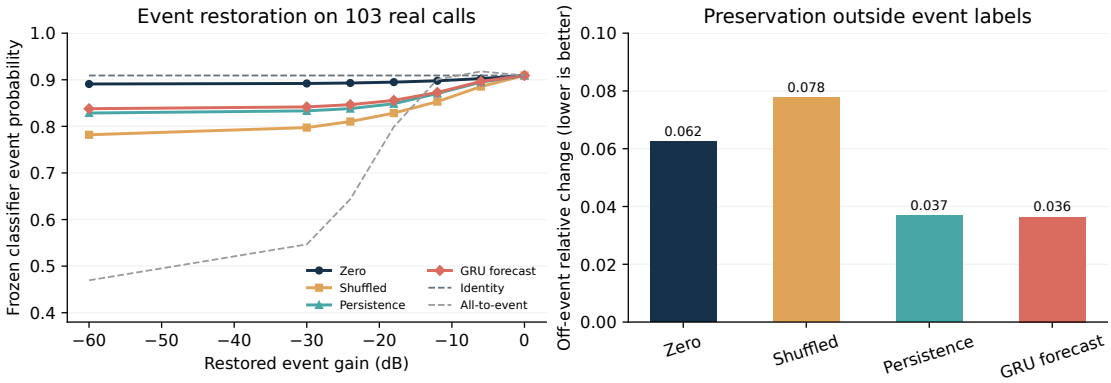


Fig. 5. 四路匹配残差模型的冻结分类器恢复曲线与区间外保留。Identity 和 all-to-event 为平凡解对照。错日 Shuffled 的事件概率更强，但对标注事件区间外音频的改动大于两种因果条件。

TABLE VII
目标池修订后同一批真实事件上的冻结评估，以及完全不变的旧合成测试 SI-SDRi。课程阶段按两套独立验证集选点；128 频组接口与背景预测器均固定。

条件	训练目标	旧合成 SI-SDRi (dB)	真实 $p(\hat{N})\downarrow$	真实 $p(\hat{s})\uparrow$	区间外 ↓
Persistence	原程序目标	14.295	.829	.849	.037
Persistence	50/50 经验目标	12.195	.652	.916	.058
Persistence	50/50 加真实弱监督	10.323	.408	.978	.061
Persistence	冻结主干加配对干净教师	12.156	.461	.960	.064
Persistence	课程微调（25% 伪真实）	14.421	.819	.823	.037
GRU Forecast	原程序目标	14.351	.838	.842	.036
GRU Forecast	50/50 经验目标	11.731	.725	.895	.043

量 $\operatorname{logit} p(\hat{N}) - \operatorname{logit} p(N_{\text{clean,matched}})$ 的平均值从 3.606 降至 1.389。然而，不变的 4096 个旧合成测试混合上，SI-SDRi 从 12.195 降到 10.323 dB。独立检测器支持真实事件标注带来部分迁移收益，但离干净背景响应仍有距离，也不能证明无真值真实声轨的波形保真。

为减轻遗忘，我们冻结频带编码与注意力表示，只更新残差投影及 mask 输出头；原 50/50 Persistence 模型作为冻结教师。有真值样本仍使用谱损失，同时增加学生与教师两条声轨的 L_1 一致性；真实背景的训练检测器响应则对齐同一 WAV 中紧邻事件之前的标注干净 5 秒窗，不再强制对齐零。事件保留与区间外惩罚照旧。具体损失为 $L = L_{\text{GT}} + .01L_{\text{real}} + .1L_{\text{teacher}}$，$L_{\text{real}} = .25L_{\text{match}} + .1L_{\text{event}} + 2L_{\text{off}}$；$L_{\text{match}}$ 是仅在标注帧计算的训练检测器 logit 平滑 L_1 损失。共 414658 个参数中 99774 个表示参数冻结；选中权重的 241 个冻结状态张量与教师逐位相同。验证日选择第 900 步。进一步加大教师权重并未带来有意义的验证日配对干净响应差改善，故没有进入真实测试审计。

在重复使用的 103 段测试事件上，独立 C_B 给出 $p(\hat{N})/p(\hat{s}) = .461/.960$；微调前为 $.652/.916$，全网弱监督后为 $.408/.978$。区间外改动为 .064，高于原版 .058，三个日期的配对差均为正。完全不变的旧合成测试 SI-SDRi 为 12.156 dB，仅比 50/50 教师低 .038 dB，却比全网弱监督高 1.833 dB。干净归一化 logit 残留量为 1.917（教师 3.606，全网弱监督 1.389）。这是一种更保守的取舍，但尚未达到 .25–.30 的背景事件概率，也未接近干净背景的 .176 响应。由于同一测试事件队列已用于上一轮报告，本次复核属于后续探索性比较，不能视作新封存测试。

V. 独立新站点检验

A. 新站点真实事件的一次性评估

在打开新测试数据之前，我们冻结原始种子的 BSR、四个原始残差条件模型、两个 50/50 目标池模型、仅微调适配器的弱监督模型、背景 GRU 和评价检测器。新数据为圣劳伦斯湾 2015–2017 年的连续录音和鲸声中心时刻标注；这些录音从未参与 DCLDE 目标参数校准、弱监督训练或模型选点 [27], [28]。为了限制下载量并排除按结果挑样本，我们根据 50 个连续文件名的 SHA-256 排序，预先固定第 13–28 个文件。前 12 个文件的首次审计发现：输入漏掉了 DCLDE 训练时采用的“每个 5 秒片段去均值”，

因此前批结果不纳入确认性结论；模型权重、超参数和检测器均未改变。最终未评估过的 16 个文件约 8 小时，共有 386 个标注调用，其中 373 个满足完整因果历史。原始 WAV 从 32,768 Hz 重采样到 2 kHz，并与 DCLDE 一样逐段去均值；历史中若有鲸声中心落入窗口及两侧 2 秒保护区，就用过去 60 秒内最近的标注阴性窗口替代。由于无法获得每个文件的准确录制日期，Shuffled 使用另一个所选文件。GSL 只给调用中心时刻，不给起止点，因此我们将中心前后各 1.5 秒设为事件区间代理。这比 DCLDE 精确的起止标注弱；同文件的标注阴性背景也不是隔离背景真值。检测器换站点后概率未必保持原有校准，因此我们做同文件内的配对比较，并报告当地标注阴性窗口的检测器底噪。中心时刻代理下的区间外改动与 DCLDE 精确起止标注下的数值不能直接对比。

表 VIII 显示一个明确但有条件的新站点效应。Persistence 比 Shuffled 的背景事件概率低 .064，逐事件或逐文件等权均约为这一数值；文件分块的配对 95% 区间为 $[-.124, -.013]$。与此同时，逐文件等权的事件声轨响应低 .009（$[-.013, -.004]$），区间外相对改动高 .016（$[.007, .027]$）。Forecast 与 Persistence 在新站点几乎持平。两种因果条件比 Zero 更能压低背景声轨检测响应，但中心区间外的相对 RMS 改动约 .54，且 $p(\hat{N}) = .361$ 仍高于当地标注阴性背景的 .193。50/50 目标池和弱监督模型在此站点也没有形成明确的多指标优势。因此，正确历史在新站点确实改善了相对错文件条件的背景检测响应，却同时损害事件保留和背景保留；仅凭较低的 $p(\hat{N})$ 不能宣称真实声轨被稳健分离。外部站点评估只使用一个冻结分离器种子；上面的三种子复核只覆盖 DCLDE 受控混合。

VI. 讨论与结论

主域 30 频带 Oracle 只诊断当前接口：FiLM 即使得到当前实际干净波形的 $E(N_t)$，留出平均值仍未超过无条件 BS-RoFormer，且配对区间跨零。全波形抄答案校验则精确成功，因此这一负结果不能说明真实背景没有可用信息；30 频带压缩与 FiLM 注入各自的影响仍未分清。固定融合头的信息阶梯进一步显示：等宽 128 频组或全频 bin 的 1 秒功率汇总仍能产生确定的收益，等宽 64 组和 30 个对数频带则没有。然而原 FiLM 结果不能仅归因于这一断点，因为接口并不相同。训练后的 128 组 Oracle-Residual-BSR 在留出混合上提高 $+7.136$ dB，说明真实高分辨率背景与显式创新可以帮助 BSR 骨干。将当前背景真值换成过去 60 秒的 Persistence 或冻结 GRU 预测后，相对 BSR 仍分别有 $+4.664$ 和 $+4.720$ dB 增益。固定均值 Zero 与错日 Shuffled 也分别提高 $+2.525$ 和 $+2.313$ dB，说明扩大输入接口解释了部分相对 BSR 的收益。固定这个接口后，原始种子中 Persistence 比 Zero 高 $+2.138$ dB、比 Shuffled 高 $+2.351$ dB；三种子重复后分别为 $2.400 \pm .237$ 和 $2.145 \pm .181$ dB，九个种子与日期组合全部同向：正确历史确有价值。原始 $+0.056$ dB 的 GRU 优势跨种子缩为 $+.017 \pm .036$ dB，其中一个种子方向相反，因此不能认为学习式预测稳定胜过短时 Persistence。原始种子距 Oracle 还有 2.416 dB。Zero 对照仍无法区分参数容量与创新通路提供当前混合对数谱的作用。前期 Zero-FiLM 与无条件骨干几乎重合，旧 30 频带摘要与 FiLM 接口可能不足以对齐分离器的时频 token；它的真实事件对照只属于前期实验。三个留出录音日和合成目标监督仍限制主域外推。原有真实鲸声审计呈现检测与保留权衡：因果条件比 Zero 改善两项事件概率，但错日 Shuffled 在分类器概率上又胜出，同时明显损害区间外保留。这些概率尚不能替代真实隔离声轨的分离质量。干净对照排除了“分类器普遍底噪过高”作为 $p(\hat{N})$ 的唯一解释；等量嵌入距离显示分类器空间内的合成到真实目标覆盖缺口。训练日目标采样明显缩小了该覆盖缺口，并改善真实事件的两项分类器概率；但区间外改动增加、旧合成域 SI-SDRi 下降，故不是全面分离提升。独立检测器引导的真实事件弱监督进一步降低背景事件响应，保留较高的事件声轨响应，区间外改动近似持平；但不变旧合成测试又损失 1.872 dB。冻结表示并增加教师一致性几乎消除了这项受控域损失，却换来较弱的真实事件抑制和轻微上升的区间外改动。因此分类概率改善仍不等于波形层面的全面增益。新站点 GSL 的冻结测试提供了独立外推检查：正确历史相对错文件条件压低背景声轨事件响应，却轻微损害事件声轨响应和区间外背景保留，因此不能宣称全面真实域优势。跨站点评价检测器可能失准，GSL 又仅提供事件中心而非精确起止，现有证据仍不能将目标失配与分离伪影、标注不确定性完全分开。

既有 30 频带 FiLM 前端可用于实验检查：在已准备历史特征的 CPU 冒烟测试中，单个 5 秒块 RTF 为 0.014；界面可显示预测并试听、下载两条估计声轨，但尚未部署新的 128 组残差模型，也不等于野外部署。后续应在目标域适配时更好地保留背景，为真实事件获取隔离声轨或更强局部参考。分类器恢复曲线是语义迁移证据，不能替代波形保真真值。

References

[1] J. L. Miksis-Olds, D. L. Bradley, and X. M. Niu, “Decadal trends in indian ocean ambient sound,” *Journal of the Acoustical Society of America*, vol. 134, no. 5, pp. 3464–3475, 2013.

[2] Y. Luo and N. Mesgarani, “Conv-TasNet: Surpassing ideal time–frequency magnitude masking for speech separation,” *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, vol. 27, no. 8, pp. 1256–1266, 2019.

[3] Y. Luo, Z. Chen, and T. Yoshioka, “Dual-path RNN: Efficient long sequence modeling for time-domain single-channel speech separation,” in *Proc. IEEE ICASSP*, 2020, pp. 46–50.

[4] C. Subakan, M. Ravanelli, S. Cornell, M. Bronzi, and J. Zhong, “Attention is all you need in speech separation,” in *Proc. IEEE ICASSP*, 2021, pp. 21–25.

[5] Z.-Q. Wang, S. Cornell, S. Choi, Y. Lee, B.-Y. Kim, and S. Watanabe, “TF-GridNet: Integrating full- and sub-band modeling for speech separation,” in *Proc. IEEE ICASSP*, 2023, pp. 1–5.

[6] Y. Luo and J. Yu, “Music source separation with band-split RNN,” *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, vol. 31, pp. 1893–1901, 2023.

[7] W.-T. Lu, J.-C. Wang, Q. Kong, and Y.-N. Hung, “Music source separation with band-split RoPE transformer,” *arXiv preprint arXiv:2309.02612*, 2023. [Online]. Available: https://arxiv.org/abs/2309.02612

[8] S. Rouard, F. Massa, and A. Défossez, “Hybrid transformers for music source separation,” in *Proc. IEEE ICASSP*, 2023, pp. 1–5.

[9] S. Wisdom, E. Tzinis, H. Erdogan, R. J. Weiss, K. Wilson, and J. R. Hershey, “Unsupervised sound separation using mixture invariant training,” in *Advances in Neural Information Processing Systems*, vol. 33, 2020, pp. 3846–3857.

[10] E. Perez, F. Strub, H. de Vries, V. Dumoulin, and A. Courville, “FiLM: Visual reasoning with a general conditioning layer,” in *Proc. AAAI Conference on Artificial Intelligence*, vol. 32, no. 1, 2018.

[11] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, “Attention is all you need,” in *Advances in Neural Information Processing Systems*, vol. 30, 2017.

[12] H. Zhao, C. Gan, A. Rouditchenko, C. Vondrick, J. McDermott, and A. Torralba, “The sound of pixels,” in *Proc. European Conference on Computer Vision*, 2018, pp. 570–586.

TABLE VIII
新站点 GSL 的一次性冻结模型评估：13 个含事件文件中的 373 个鲸声调用。冻结的 DCLDE 检测器对混合的平均响应为 $p(x) = .907$，对先前同文件标注阴性窗口为 $p(N_{\text{ann.}-\text{neg.}}) = .193$。事件区间由中心时刻近似构造，且无真实隔离声轨，因此以下数值是语义与保留度代理。

冻结分离器	$p(\hat{N}) \downarrow$	$p(\hat{s}) \uparrow$	恢复单调率 ↑	区间外改动 ↓
BS-RoFormer	.688	.931	.970	.489
Zero-Residual	.894	.631	.993	.126
Shuffled-Residual	.425	.936	.964	.528
Persistence-Residual	.361	.927	.955	.543
GRU-Forecast-Residual	.361	.927	.954	.543
50/50 Persistence	.439	.915	.954	.557
50/50 GRU Forecast	.447	.912	.952	.569
冻结主干弱监督 Persistence	.439	.915	.955	.557

[13] D. Salinas, V. Flunkert, J. Gasthaus, and T. Januschowski, "DeepAR: Probabilistic forecasting with autoregressive recurrent networks," *International Journal of Forecasting*, vol. 36, no. 3, pp. 1181–1191, 2020.

[14] B. N. Oreshkin, D. Carpov, N. Chapados, and Y. Bengio, "N-BEATS: Neural basis expansion analysis for interpretable time series forecasting," in *International Conference on Learning Representations*, 2020.

[15] A. Zeng, M. Chen, L. Zhang, and Q. Xu, "Are transformers effective for time series forecasting?" in *Proc. AAAI Conference on Artificial Intelligence*, vol. 37, no. 9, 2023, pp. 11 121–11 128.

[16] Y. Nie, N. H. Nguyen, P. Sinthong, and J. Kalagnanam, "A time series is worth 64 words: Long-term forecasting with transformers," in *International Conference on Learning Representations*, 2023.

[17] J. Lin, "Divergence measures based on the shannon entropy," *IEEE Transactions on Information Theory*, vol. 37, no. 1, pp. 145–151, 1991.

[18] D. Gillespie, M. Caillat, and J. Gordon, "DCLDE 2013 workshop dataset," 2019.

[19] Y. Shiu, K. J. Palmer, M. A. Roch, E. Fleishman, X. Liu, E.-M. Nosal, T. Helble, D. Cholewiak, D. Gillespie, and H. Klinck, "Deep neural networks for automated detection of marine mammal species," *Scientific Reports*, vol. 10, p. 607, 2020.

[20] NOAA Office of National Marine Sanctuaries and U.S. Navy, "SanctSound raw passive acoustic data," NOAA NCEI dataset, 2020.

[21] E. Vincent, R. Gribonval, and C. Févotte, "Performance measurement in blind audio source separation," *IEEE Transactions on Audio, Speech, and Language Processing*, vol. 14, no. 4, pp. 1462–1469, 2006.

[22] J. Le Roux, S. Wisdom, H. Erdogan, and J. R. Hershey, "SDR—half-baked or well done?" in *Proc. IEEE ICASSP*, 2019, pp. 626–630.

[23] K. Kilgour, M. Zuluaga, D. Roblek, and M. Sharifi, "Fréchet audio distance: A reference-free metric for evaluating music enhancement algorithms," in *Proc. Interspeech*, 2019, pp. 2350–2354.

[24] E. M. Grais, H. Wierstorf, D. Ward, R. D. Mason, and M. D. Plumbley, "Referenceless performance evaluation of audio source separation using deep neural networks," in *Proc. European Signal Processing Conference*, 2019.

[25] Y. Wu, K. Chen, T. Zhang, Y. Hui, M. Nezhurina, T. Berg-Kirkpatrick, and S. Dubnov, "Large-scale contrastive language–audio pretraining with feature fusion and keyword-to-caption augmentation," in *Proc. IEEE ICASSP*, 2023, pp. 1–5.

[26] X. Xiao, H. Jin, Z. Chen, A. Gram, G. Wichern, and J. Le Roux, "A reference-free metric for language-queried audio source separation using contrastive language–audio pretraining," in *Proc. DCASE Workshop*, 2024.

[27] O. S. Kirsebom, F. Frazao, Y. Simard, N. Roy, S. Matwin, and S. Giard, "Acoustic recordings of north atlantic right whale upcalls in the gulf of st. lawrence," 2020.

[28] ——, "Performance of a deep neural network at detecting north atlantic right whale upcalls," *Journal of the Acoustical Society of America*, vol. 147, no. 4, pp. 2636–2646, 2020.