因果预测条件下的海洋声音分离 BS-RoFormer

匿名作者
匿名单位

***Abstract*—**本文检验：仅由此前海洋录音因果预测得到的背景频谱，能否帮助分离下一个 **5** 秒窗口中的声学事件。**FC-BSR** 通过特征拼接、特征线性调制（**FiLM**）或交叉注意力把预测结果注入 **BS-RoFormer**。在包含 **13** 类信号的受控实验中，**FiLM** 在固定 **0-dB** 输入 **SNR** 下将 **SI-SDR** 改善量（**SI-SDRi**）提高 **0.692 dB**（**95%** 配对 **bootstrap** 区间 $[0.542, 0.847]$）。但在 **42** 小时连续真实水听器背景上，条件收益取决于信号强度：-18 与 -12 **dB** 时分别优于无条件模型 **0.728** 与 **0.525 dB**，在约 -4 **dB** 以上则转为落后。在没有隔离声轨的 **1276** 个真实鲸声事件上，**FC-BSR** 略微提高事件声轨概率，却未降低残余事件概率或区间外改动。因此，预测先验在受控和弱目标场景中有用，但尚未证明其能改善未知真实事件。

***Index Terms*—**海洋声学，源分离，声景预测，**BS-RoFormer**，无参考评估

I. 引言

海洋背景随航运、天气、生物活动和季节变化 [1]。仅使用混合声音的分离器必须从同一观测中同时推断突发事件与变化背景。本文改为使用此前声景提供严格因果先验：

$$S_{t-H:t-1} \xrightarrow{P_\psi} \widehat{S}_t, \qquad x_t = N_t + \alpha s_t \xrightarrow{F_\phi(\cdot|\widehat{S}_t)} (\hat{s}_t, \hat{N}_t), \quad (1)$$

其中分离器从不观察当前干净背景 N_t。

时域分离器 [2], [3]、注意力模型 [4], [5] 和子带系统 [6], [7] 提供了强大的仅混合输入骨干。混合 Transformer 与 MixIT 扩展了架构和监督方式 [8], [9]，但没有检验下一时刻背景预测。FiLM、交叉注意力与跨模态分离 [10]–[12] 启发了三种接口；递归、线性与分块预测模型则提供时间序列基线 [13]–[16]。

本文贡献为：（1）FC-BSR，[1]以及严格匹配的拼接、FiLM 与交叉注意力消融；（2）包含鲸声扫频和船噪过程的 13 类海洋感知信号生成器；（3）在 5 秒真实背景上比较基线、oracle、预测和错时条件的信号强度扫描；（4）在未修改鲸声事件上直接比较 FC-BSR 与 BS-RoFormer。三级证据刻意分开合成真值与真实语义迁移。

II. 方法

A. 背景预测与条件分离

历史三分之一倍频程声级（TOL）$S_{t-H:t-1} \in \mathbb{R}^{H\times F}$ 只用训练集统计量归一化。残差 GRU 预测

$$z_t = \mathrm{LN}(\mathrm{GRU}(S_{t-H:t-1})), \quad \widehat{S}_t = S_{t-1} + g_\psi(z_t). \quad (2)$$

零初始化精确表示 persistence；只有验证 MAE 优于 persistence 时才保留学习式预测 [17]。

[1]代码与复现实验说明：https://github.com/D-eval/ocean_noise_pred_splite。

BS-RoFormer 将混合 STFT 映射为子带 token X_k。在轴向 Transformer 前的相同位置比较

$$\begin{aligned} \text{拼接：}\ \widetilde{X}_k &= X_k + f([X_k; P_k(\widehat{S}_t)]), \\ \text{FiLM：}\ \widetilde{X}_k &= (1 + \tanh\gamma_k) \odot X_k + \beta_k, \\ \text{交叉注意力：}\ \widetilde{X} &= X + \mathrm{Attn}(X, E(\widehat{S}_t), E(\widehat{S}_t)). \end{aligned} \quad (3)$$

所有残差条件分支均从恒等映射开始。损失结合波形 L_1 与多分辨率复数 STFT；仅 TOL 代理实验加入 $0.2\|\widehat{S}_t - S_t\|_1$。真实波形实验在训练分离器前冻结预测器。

B. 海洋感知合成信号分布

生成器包含 13 类：谐波、线性啁啾、非谐波、脉冲列、调频音、带限噪声、鲸声上扫、下扫、拱形、S 形、脉冲包、船舶音调和船舶空化。鲸声代理由 1–3 个局部事件组成，随机改变时长、曲率、分音、渐入渐出与抖动。船舶音调和窄带空化分量以 0.8 概率采用 5–20 Hz 低频振荡器（LFO）音量包络；宽带分量不做该调制。训练 SNR 在 $[-12, 12]$ dB 均匀抽样。这些代理用于覆盖轮廓和调制样式，并不声称对应具体物种。

频谱位移同时用方向性 $D_{\mathrm{KL}}(p\|q)$ 和有限对称 JS 散度 [19] 衡量，另报告频谱熵与信号–海洋频谱重叠。更大的 KL/JS 只代表覆盖范围更广，不等价于语义多样性。

C. 证据层级与实验协议

第一层使用 NOAA–Navy SanctSound 小时级 TOL 产品 [18]。MB03 部署 01–02/03/04 分别作为训练/验证/测试集。随机相位逆变换只产生受控频谱代理，不能称为恢复音频。所有波形为 5 秒；每个训练部署使用 4000 个样本，共训练 2500 步。

第二层使用 42 小时连续 8-kHz 水听器 WAV，其中 12/6/24 小时用于训练/验证/测试。当前真实干净波形 N_t 与合成目标直接混合。主实验使用 5 秒混合、2500 步训练，并在 -18 至 $+12$ dB 的 11 档 SNR 上测试。单独的预测分辨率诊断固定一小时历史，将步长设为 5 秒、30 秒、1 分钟或 10 分钟；其后的实验全部恢复为 5 秒波形。

第三层使用按日期隔离的 2-kHz DCLDE 2013 露脊鲸录音 [20]。事件标注可支持检测 [21]，但不存在隔离声轨。仅向标注干净的训练片段注入上述代理，测试 1276 个未修改的真实阳性事件。两种模型共享样本、种子、骨干初始化、2500 步预算和仅验证集选点。

前两层使用尺度不变投影的 SI-SDR 与 SI-SDRi [22], [23]。全部不确定性区间来自固定种子的配对 bootstrap；连续片段按录音小时分块，真实事件按留出日期分块。当前测试频谱只可用于监督或 oracle 对照，因果历史严格截止于 t 之前。

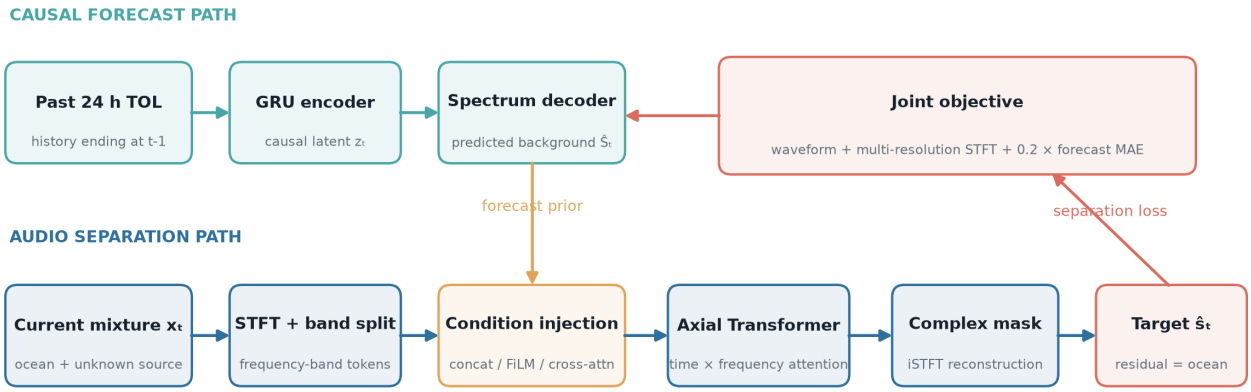


Fig. 1. FC-BSR 架构。严格早于当前时刻的声景特征预测当前背景频谱，并条件化同一个 BS-RoFormer 骨干；移除蓝色路径即得到参数匹配的无条件基线。

TABLE I
匹配的 5 秒条件注入消融（dB）。

注入方式	验证 SI-SDRi	测试 SI-SDRi	配对 Δ_0
无条件	4.864	4.059	0
拼接	5.343	4.432	+0.623
FiLM	**5.419**	**4.468**	**+0.692**
交叉注意力	5.128	4.261	+0.331

TABLE II
真实背景上的预测分辨率诊断。

步长	预测器	条件模型	基线	增益 [95% 区间]
5 秒	GRU	29.753	28.527	1.226 [1.082,1.381]
30 秒	persistence	29.630	28.534	1.095 [0.935,1.265]
1 分钟	persistence	29.661	28.533	1.128 [0.971,1.298]
10 分钟	persistence	29.711	28.535	1.176 [1.036,1.326]

条件模型、基线与增益均为目标 SI-SDRi（dB）。

III. 实验与结果

A. 条件机制选择与信号多样性

表 I 只按验证集选择 FiLM。在 832 个固定 0-dB 配对样本（每族 64 个）上，它将 SI-SDRi 从 4.850 提高到 5.541 dB。逐频带缩放与偏置可以直接表达“此处为预期能量”；拼接需要压缩加倍特征，交叉注意力则必须在相同预算内从粗条件中学习对齐。

FiLM 在五类鲸声代理上的增益依次为 0.869、0.835、0.919、0.906 与 0.806 dB。船舶音调最难：尽管相对增益为 0.320 dB，条件模型的绝对 SI-SDRi 仍为 -8.295 dB。总体增益与 JS 的相关性很弱（$r = -.057$），与频谱熵也仅为 $r = .122$；因此提高散度能扩大覆盖，却不能预测先验何时有用。

B. 真实背景：时间尺度与目标强度

表 II 的分辨率诊断对各模型使用相同留出样本。只有 5 秒预测器在验证集优于 persistence（MAE 1.366 对 1.386 dB）；其他尺度均选择 persistence。四种条件分离器均优于匹配基线，但区间彼此重叠，故不能据此判定最佳时间尺度。

更困难的固定 5 秒实验在 1152 个配对测试混合上比较 BS-RoFormer、当前真值频谱 oracle、因果预测和错时条件。跨训练 SNR 平均后，基线为 23.470 dB，Forecast-FC-BSR 为 22.871 dB（$\Delta = -0.599$，区间 $[-0.851, -0.346]$），oracle 平均值也更低。这暴露了简单分辨率诊断没有显示的条件化/容量影响。图 2 进一步表明：在 $-18, -15, -12, -9, -6$ dB，预测条件分别提高 0.728、0.643、0.525、0.366、0.157

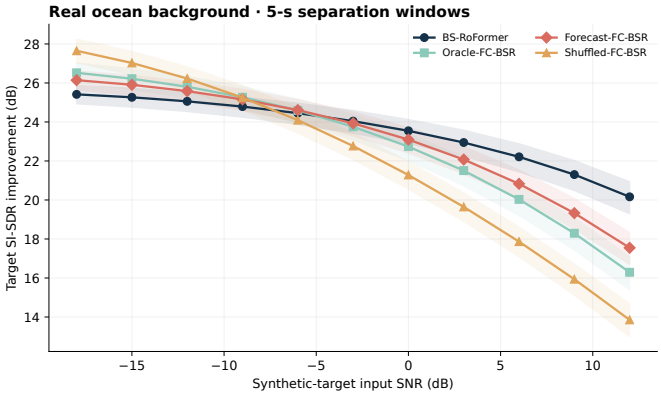


Fig. 2. 5 秒真实海洋背景上的目标强度扫描。四条曲线对应全部模型条件，阴影为配对 95% 区间。

dB；从 -3 dB 开始转为落后。错时条件对最弱目标也有收益，却随 SNR 上升迅速退化，因此不能把弱目标增益完全归因于预测的时间准确性；正则化或额外容量仍是可能解释。

C. 没有分离真值的真实事件

参考学习式无参考指标 [24], [25] 和语义音频嵌入 [26], [27]，我们训练、校准并冻结二分类器；测试 AUROC、AP 与 F1 分别为.9723、.9755、.9275。混合一致性要求 $\hat{N} = x - \hat{s}$。将 $\hat{s}$ 按 $\{-60, -30, -24, -18, -12, -6, 0\}$ dB 逐级恢复，检

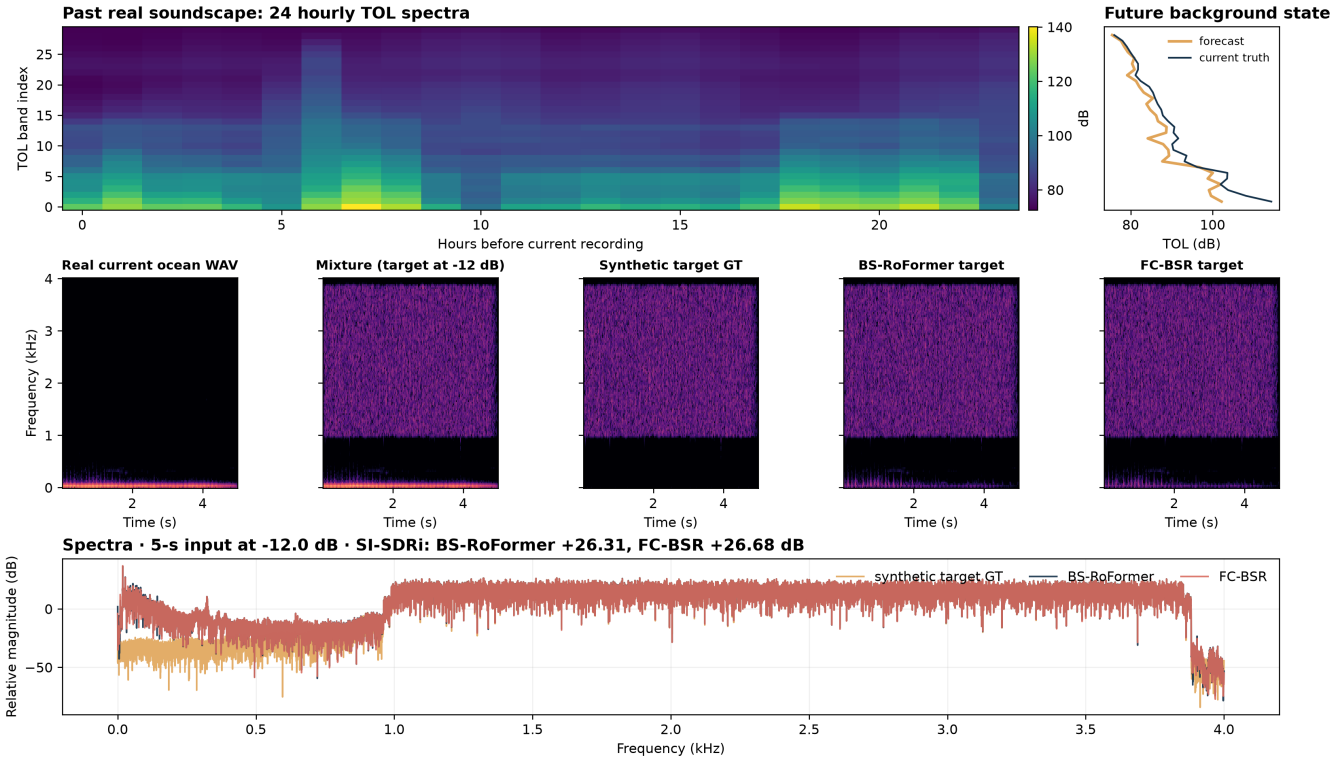


Fig. 3. 真实海洋背景中的一个代表性弱目标（−12 dB，5 秒）。该示例避免目标在视觉上压倒背景，并把 BS-RoFormer、FC-BSR 与精确目标并排比较。

TABLE III
1276 个真实事件上的匹配比较。

方法	$p(\hat{N})\downarrow$	$p(\hat{s})\uparrow$	单调率 ↑	区间外 ↓
BS-RoFormer	**.751**	.863	**.940**	**.279**
FC-BSR	.766	**.868**	.939	.288

查事件概率是否单调回升；Identity 与 all-to-event 排除平凡解，标注区间外变化审计背景保留。

12 个 5 秒历史窗的预测器把验证 MAE 从 2.076 降到 1.974 dB，随后冻结。在代理验证集上，BS-RoFormer 与 FC-BSR 的 SI-SDRi 为 11.125 与 11.088 dB。表 III 给出未修改真实事件结果。FC-BSR 的事件声轨概率略高（+.0051），但残余事件概率更高、单调率不变，且区间外改动增加；残余概率差 +.0145 的日期分块区间为 $[-.0177, .0269]$。因此这一层证明分离器能迁移到真实事件，但没有证明预测条件优于无条件模型。

IV. 讨论与结论

证据支持的结论比初始假设更窄：FiLM 是受控真值下最佳的条件接口；在 5 秒真实背景中，先验有助于弱目标。但其收益并不普遍：信号增强后增益反转，oracle 也未改善平均值，且未修改鲸声上没有显示预测条件优势。四种预测分辨率中还有三种由 persistence 获胜。这些负对照很关键：它们区分了“背景信息存在价值”与“当前架构总能利用该信息”。

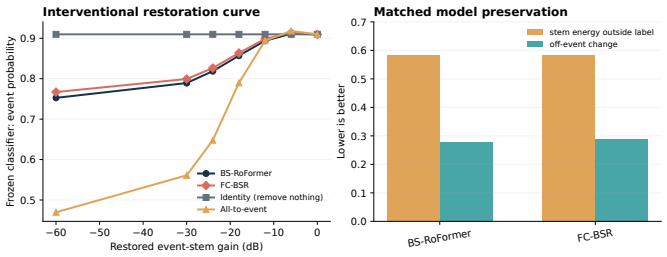


Fig. 4. 无参考恢复曲线与背景保留审计。两种模型都进行了非平凡语义分离，但 FC-BSR 在真实事件上没有全面胜出。

系统已适合实验检查：真实波形模型的 RTF 约为.0028，本地前端可显示预测并试听、下载两条估计声轨，但这不等于野外部署。后续应根据预测不确定性选择性启用条件，覆盖多站点、多季节，并为真实事件获取隔离声轨或更强局部参考。分类器恢复曲线是语义迁移证据，不能替代波形保真真值。

References

[1] J. L. Miksis-Olds, D. L. Bradley, and X. M. Niu, "Decadal trends in indian ocean ambient sound," *Journal of the Acoustical Society of America*, vol. 134, no. 5, pp. 3464–3475, 2013.

[2] Y. Luo and N. Mesgarani, "Conv-TasNet: Surpassing ideal time–frequency magnitude masking for speech separation," *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, vol. 27, no. 8, pp. 1256–1266, 2019.

[3] Y. Luo, Z. Chen, and T. Yoshioka, "Dual-path RNN: Efficient long sequence modeling for time-domain single-channel speech separation," in *Proc. IEEE ICASSP*, 2020, pp. 46–50.

[4] C. Subakan, M. Ravanelli, S. Cornell, M. Bronzi, and J. Zhong, "Attention is all you need in speech separation," in *Proc. IEEE ICASSP*, 2021, pp. 21–25.

[5] Z.-Q. Wang, S. Cornell, S. Choi, Y. Lee, B.-Y. Kim, and S. Watanabe, "TF-GridNet: Integrating full- and sub-band modeling for speech separation," in *Proc. IEEE ICASSP*, 2023, pp. 1–5.

[6] Y. Luo and J. Yu, "Music source separation with band-split RNN," *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, vol. 31, pp. 1893–1901, 2023.

[7] W.-T. Lu, J.-C. Wang, Q. Kong, and Y.-N. Hung, "Music source separation with band-split RoPE transformer," *arXiv preprint arXiv:2309.02612*, 2023. [Online]. Available: https://arxiv.org/abs/2309.02612

[8] S. Rouard, F. Massa, and A. Défossez, "Hybrid transformers for music source separation," in *Proc. IEEE ICASSP*, 2023, pp. 1–5.

[9] S. Wisdom, E. Tzinis, H. Erdogan, R. J. Weiss, K. Wilson, and J. R. Hershey, "Unsupervised sound separation using mixture invariant training," in *Advances in Neural Information Processing Systems*, vol. 33, 2020, pp. 3846–3857.

[10] E. Perez, F. Strub, H. de Vries, V. Dumoulin, and A. Courville, "FiLM: Visual reasoning with a general conditioning layer," in *Proc. AAAI Conference on Artificial Intelligence*, vol. 32, no. 1, 2018.

[11] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, "Attention is all you need," in *Advances in Neural Information Processing Systems*, vol. 30, 2017.

[12] H. Zhao, C. Gan, A. Rouditchenko, C. Vondrick, J. McDermott, and A. Torralba, "The sound of pixels," in *Proc. European Conference on Computer Vision*, 2018, pp. 570–586.

[13] D. Salinas, V. Flunkert, J. Gasthaus, and T. Januschowski, "DeepAR: Probabilistic forecasting with autoregressive recurrent networks," *International Journal of Forecasting*, vol. 36, no. 3, pp. 1181–1191, 2020.

[14] B. N. Oreshkin, D. Carpov, N. Chapados, and Y. Bengio, "N-BEATS: Neural basis expansion analysis for interpretable time series forecasting," in *International Conference on Learning Representations*, 2020.

[15] A. Zeng, M. Chen, L. Zhang, and Q. Xu, "Are transformers effective for time series forecasting?" in *Proc. AAAI Conference on Artificial Intelligence*, vol. 37, no. 9, 2023, pp. 11 121–11 128.

[16] Y. Nie, N. H. Nguyen, P. Sinthong, and J. Kalagnanam, "A time series is worth 64 words: Long-term forecasting with transformers," in *International Conference on Learning Representations*, 2023.

[17] T. Gneiting, "Making and evaluating point forecasts," *Journal of the American Statistical Association*, vol. 106, no. 494, pp. 746–762, 2011.

[18] NOAA Office of National Marine Sanctuaries and U.S. Navy, "SanctSound raw passive acoustic data," NOAA NCEI dataset, 2020.

[19] J. Lin, "Divergence measures based on the shannon entropy," *IEEE Transactions on Information Theory*, vol. 37, no. 1, pp. 145–151, 1991.

[20] D. Gillespie, M. Caillat, and J. Gordon, "DCLDE 2013 workshop dataset," 2019.

[21] Y. Shiu, K. J. Palmer, M. A. Roch, E. Fleishman, X. Liu, E.-M. Nosal, T. Helble, D. Cholewiak, D. Gillespie, and H. Klinck, "Deep neural networks for automated detection of marine mammal species," *Scientific Reports*, vol. 10, p. 607, 2020.

[22] E. Vincent, R. Gribonval, and C. Févotte, "Performance measurement in blind audio source separation," *IEEE Transactions on Audio, Speech, and Language Processing*, vol. 14, no. 4, pp. 1462–1469, 2006.

[23] J. Le Roux, S. Wisdom, H. Erdogan, and J. R. Hershey, "SDR—half-baked or well done?" in *Proc. IEEE ICASSP*, 2019, pp. 626–630.

[24] K. Kilgour, M. Zuluaga, D. Roblek, and M. Sharifi, "Fréchet audio distance: A reference-free metric for evaluating music enhancement algorithms," in *Proc. Interspeech*, 2019, pp. 2350–2354.

[25] E. M. Grais, H. Wierstorf, D. Ward, R. D. Mason, and M. D. Plumbley, "Referenceless performance evaluation of audio source separation using deep neural networks," in *Proc. European Signal Processing Conference*, 2019.

[26] Y. Wu, K. Chen, T. Zhang, Y. Hui, M. Nezhurina, T. Berg-Kirkpatrick, and S. Dubnov, "Large-scale contrastive language–audio pretraining with feature fusion and keyword-to-caption augmentation," in *Proc. IEEE ICASSP*, 2023, pp. 1–5.

[27] X. Xiao, H. Jin, Z. Chen, A. Gram, G. Wichern, and J. Le Roux, "A reference-free metric for language-queried audio source separation using contrastive language–audio pretraining," in *Proc. DCASE Workshop*, 2024.