高分辨率因果背景先验驱动的海洋声音分离

匿名作者
匿名单位

***Abstract*—**本文检验过去海洋声景能否提供有助于分离未来事件的背景先验。**DCLDE** 样本将标注干净的真实 **5** 秒海洋录音与合成海洋事件混合，过去 **60** 秒历史中屏蔽已标注鲸声。初始 **30** 频带 **GRU** 预测加 **FiLM** 在 **4,096** 个留出混合上没有优于 **BS-RoFormer**：目标 **SI-SDRi** 分别为 **9.497** 与 **9.631 dB**；即使使用当前真实 **30** 频带 **Oracle**，也只有 **9.535 dB**。信息阶梯表明保留时间维的等宽 **128** 频组更有价值。我们将该背景图及显式的“混合减背景”创新图送入匹配的残差适配器。当前背景真值 **Oracle** 达到 **16.767 dB**；改用过去 **60** 秒的 **Persistence** 和冻结 **GRU** 预测后，分别达到 **14.295** 与 **14.351 dB**。固定训练均值 **Zero** 与错日 **Shuffled** 分别达到 **12.156** 与 **11.944 dB**；**Persistence** 相比两者分别提高 **2.138** 与 **2.351 dB**。预测比 **Persistence** 高 0.056 **dB**，按录音日配对的 **95%** 区间为 $[0.036, 0.074]$，但仍低于 **Oracle** 2.416 **dB**。因此，残差接口本身已有收益，时间相关的历史背景又带来显著额外收益；当前 **GRU** 相比直接沿用上一窗只带来很小增益。合成目标和仅三个留出日限制了外推结论；同一批 **103** 个真实鲸声事件上，因果条件比错日 **Shuffled** 更好地保留标注区间外音频，但 **Shuffled** 的两项事件分类概率更优；真实事件上的排序尚未闭合。训练日经验目标池使等量真实到目标嵌入距离从 .483 降至 .322。以 **50/50** 程序/伪真实目标池重训 **Persistence** 后，相同真实鲸声上的 $p(\hat{N})$ 从 .829 降至 .652，但区间外改动从 .037 升至 .058，旧合成测试 **SI-SDRi** 从 **14.295** 降至 **12.195 dB**。目标真实性改善了语义代理指标，同时带来可测的保留与分布取舍。

***Index Terms*—**海洋声学，源分离，声景预测，**BS-RoFormer**，无参考评估

I. 引言

海洋背景随航运、天气、生物活动和季节变化 [1]。仅使用混合声音的分离器必须从同一观测中同时推断突发事件与变化背景。本文从历史声景提取严格因果的高分辨率先验：

$$\begin{aligned} x_t &= N_t + s_t, \qquad \widehat{B}_t = P_\psi(H_t), \\ \widehat{R}_t &= \log|X_t| - \widehat{B}_t, \\ [X_t, \widehat{B}_t, \widehat{R}_t] &\xrightarrow{\text{Residual+BSR}} (\hat{s}_t, \hat{N}_t), \end{aligned} \tag{1}$$

其中 H_t 屏蔽所有已标注事件及其保护区，N_t 是真实、标注干净的当前 5 秒录音；模型只观察 x_t, H_t，而 N_t, s_t 提供精确监督。X_t 为当前混合 STFT，$\widehat{B}_t$ 是预测背景的对数幅度图。旧 30 频带 FiLM 在留出集失效，促使我们通过信息阶梯选择 128 个频率组和显式残差接口（图 1）。

时域分离器 [2], [3]、注意力模型 [4], [5] 和子带系统 [6], [7] 提供了强大的仅混合输入骨干。混合 Transformer 与 MixIT 扩展了架构和监督方式 [8], [9]，但没有检验下一时刻背景预测。FiLM、交叉注意力与跨模态分离 [10]–[12] 启发了三种接口；递归、线性与分块预测模型则提供时间序列基线 [13]–[16]。

本文贡献为：（1）保留时间维的 128 频组因果背景图、显式创新及残差 BSR 接口；[1] （2）构造事件掩蔽的 60 秒历史和真实标注干净当前背景；（3）六路匹配对照，分辨适配器容量、错日背景、持续性预测、学习式预测及当前真值的作用；（4）用 30 频带 FiLM 的失败与频率信息阶梯解释方法选择。广分布信号与真实事件评估用于检查覆盖和迁移，不替代 DCLDE 全参考主实验。

[1]代码与复现实验说明：https://github.com/D-eval/ocean_noise_pred_splite。

II. 方法

A. 高分辨率因果残差分离器

主历史 $H_t \in \mathbb{R}^{12\times 79\times 128}$ 包含严格早于当前的 12 张 5 秒对数幅度图。在 2 kHz 录音上以 512 点 Hann STFT 和 128 点帧移计算，每窗保留 79 帧、128 个等宽频组。标注事件窗被掩蔽，只在过去 60 秒内部用邻近干净窗填补。轻量残差 GRU 将每张图压缩成四个时间块，处理 12 步后预测完整的未来 79×128 背景图 $\widehat{B}_t$；零初始化解码器以最后一张历史图为起点。预测器只在训练日干净背景上训练，按验证背景图 MAE 选点，并在分离训练前冻结。

在同一网格上计算 $\widehat{R}_t = \log|X_t| - \widehat{B}_t$。将 $[\widehat{B}_t, \widehat{R}_t]$ 对齐 BSR 帧网格，经零初始化的残差投影加到由混合声音得到的子带 token，再进入轴向注意力。因此所有条件分离器在训练前与同一个迁移初始化的普通 BSR 波形映射完全一致。用合成事件的精确声轨计算波形和多分辨率 STFT 损失。图 1 区分了训练真值与实际推理输入。

B. 前期 *30* 频带 *FiLM* 设计

前期历史特征 $H_t \in \mathbb{R}^{12\times 30}$ 由当前窗前 12 个 5 秒块计算得到 30 维对数频带功率；已标注事件及两侧 2 秒保护区被排除，归一化统计量只从训练集估计。残差 GRU 预测

$$z_t = \mathrm{LN}(\mathrm{GRU}(H_t)), \quad \widehat{S}_t = S_{t-1} + g_\psi(z_t). \tag{2}$$

零初始化精确表示 persistence；只有验证 MAE 优于 persistence 时才保留学习式预测 [17]。

BS-RoFormer 将混合 STFT 映射为子带 token X_k。在轴向 Transformer 前的相同位置比较

$$\begin{aligned} \text{拼接：}\ \widetilde{X}_k &= X_k + f([X_k; P_k(\widehat{S}_t)]), \\ \text{FiLM：}\ \widetilde{X}_k &= (1 + \tanh\gamma_k) \odot X_k + \beta_k, \\ \text{交叉注意力：}\ \widetilde{X} &= X + \mathrm{Attn}(X, E(\widehat{S}_t), E(\widehat{S}_t)). \end{aligned} \tag{3}$$

所有残差条件分支均从恒等映射开始。损失结合波形 L_1 与多分辨率复数 STFT；仅 TOL 代理实验加入 $0.2\|\widehat{S}_t - S_t\|_1$。真实波形实验在训练分离器前冻结预测器。

前期 30 频带信息审计固定骨干、混合样本、初始化和训练规则。真正无条件的 BS-RoFormer 绕过条件注入；Zero-FiLM 保留 FiLM 分支与同一冻结 GRU，但用 $c = 0$ 替换其输出。Shuffled-FiLM 将同一划分内的干净时窗索引错开半个周期，取得另一时窗的 $E(N_j)$；留出测试中该窗来自另一录音日。Persistence-FiLM 使用最后一个历史频谱 S_{t-1}，Forecast-FiLM 使用冻结 GRU 的预测。Oracle-FiLM

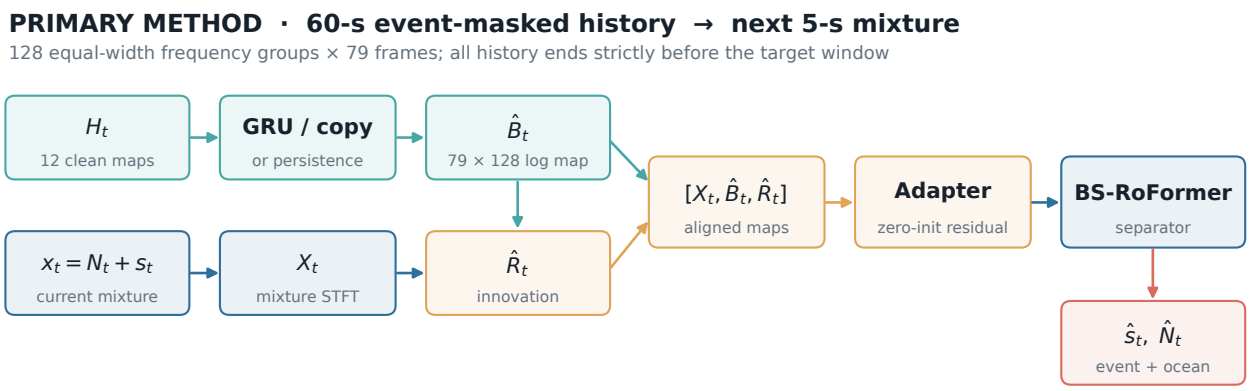


Fig. 1. 128 频组因果残差主架构。事件掩蔽的过去 60 秒历史预测未来 5 秒背景图；显式创新为 $\widehat{R}_t = \log|X_t| - \widehat{B}_t$。Zero、错日 Shuffled、Persistence、Forecast 和当前背景 Oracle 共用同一残差适配器。只有 Oracle 在输入端使用当前干净背景。

使用 $S_t^{\text{oracle}} = E(N_t)$，其中 N_t 是当前样本实际采用的干净背景波形，包含极少数混合峰值归一化后的幅度。本文明确称之为“30 频带 Oracle-FiLM”：E 丢失时间结构与相位，因此这一路既不是完整背景条件的上限，也不能限制更丰富表示下完美预测的价值。该条件仅在受控实验中可用。

C. 海洋感知合成信号分布

广分布生成器包含 13 类：谐波、线性啁啾、非谐波、脉冲列、调频音、带限噪声、鲸声上扫、下扫、拱形、S 形、脉冲包、船舶音调和船舶空化。鲸声代理由 1–3 个局部事件组成，随机改变时长、曲率、分音、渐入渐出与抖动。船舶音调和窄带空化分量以 0.8 概率采用 5–20 Hz 低频振荡器（LFO）音量包络；宽带分量不做该调制。训练 SNR 在 $[-18, 12]$ dB 均匀抽样。这些代理用于覆盖轮廓和调制样式，并不声称对应具体物种。

频谱位移同时用方向性 $D_{\text{KL}}(p\|q)$ 和有限对称 JS 散度 [18] 衡量，另报告频谱熵与信号–海洋频谱重叠。更大的 KL/JS 只代表覆盖范围更广，不等价于语义多样性。主 DCLDE 实验仅从其中 5 类鲸声和 2 类船噪抽样，六组模型使用同一目标分布。

D. 主数据构造与消融协议

主数据由按日期隔离的 2-kHz DCLDE 2013 录音及鲸声标注组成 [19], [20]。在 168 小时 WAV 中，移除已标注事件及两侧各 2 秒保护区后，得到 146.4 小时标注干净的 5 秒窗口。每个当前窗使用同一 WAV 中紧邻其前的 12 个 5 秒块构造高分辨率历史。标注事件及两侧 2 秒保护区被屏蔽；68,075 个合格当前窗中有 235 个历史仅缺一块，由过去 60 秒内部最近的干净块填补。历史不跨 WAV 边界，也不读取当前窗。筛选后共 94.5 小时符合条件，训练/验证/测试分别为 37.3/9.7/47.6 小时。每个当前背景 N_t 与上述 7 类海洋合成事件 s_t 相加得到 $x_t = N_t + s_t$。模型输入只有 x_t, H_t，而 N_t, s_t 是监督真值。主设置固定为 128 组逐帧残差接口、5 秒目标窗和过去 60 秒历史。

TABLE I
匹配的 5 秒条件注入消融（dB）。

注入方式	验证 SI-SDRi	测试 SI-SDRi	配对 Δ_0
无条件	4.864	4.059	0
拼接	5.343	4.432	+0.623
FiLM	**5.419**	**4.468**	**+0.692**
交叉注意力	5.128	4.261	+0.331

次级消融采用 NOAA–Navy SanctSound 小时级 TOL 产品 [21]。MB03 部署 01–02/03/04 分别用于训练/验证/测试。随机相位逆变换只产生受控频谱代理，不能视为恢复音频。条件机制、KL/JS 覆盖、预测时间尺度，以及 42 小时未标注连续 WAV 上的强度扫描均属于消融；后者缺乏事件标注，不能作为主干的干净背景证据。

全参考分离使用尺度不变投影的 SI-SDR 与 SI-SDRi [22], [23]。区间使用固定种子的配对 bootstrap；主测试按留出录音日分块。当前测试特征仅作监督目标，GRU 历史严格截止于 t 之前。

III. 实验与结果

A. 前期条件机制选择与信号多样性

前期 30 频带方案按验证集选择 FiLM。表 I 在 832 个固定 0-dB 配对样本（每族 64 个）上比较各接口，它将 SI-SDRi 从 4.850 提高到 5.541 dB。逐频带缩放与偏置可以直接表达“此处为预期能量”；拼接需要压缩加倍特征，交叉注意力则必须在相同预算内从粗条件中学习对齐。

FiLM 在五类鲸声代理上的增益依次为 0.869、0.835、0.919、0.906 与 0.806 dB。船舶音调最难：尽管相对增益为 0.320 dB，条件模型的绝对 SI-SDRi 仍为 −8.295 dB。总体增益与 JS 的相关性很弱（$r = -.057$），与频谱熵也仅为 $r = .122$；因此提高散度能扩大覆盖，却不能预测先验何时有用。

B. 前期 *30* 频带 *FiLM* 的 *DCLDE* 审计

原 FC-BSR 使用 FiLM+5 秒 +GRU+BS-RoFormer，以及上述事件掩蔽历史与标注干净的真实当前背景；训练集有 37.3 小时可用干净背景。旧两路结果把零条件 FiLM 检查点误称为无条件 BS-RoFormer；本实验将它按实际结构重新标注，在附上同一冻结 GRU 后确认波形输出完全一致，另行训练真正跳过条件注入的 BS-RoFormer。表 II 中的六路共用相同混合样本、骨干迁移初始化、优化预算、验证选点，并在三个留出录音日的 4,096 个样本上逐例核对 ID、SNR 与混合基准分数。图 3 展示这些样本按注入 SNR 分组后的曲线。

结构效应 Zero−BS-RoFormer 为 -0.0002 dB（95% 区间 $[-0.0068, 0.0088]$）。Forecast−BS-RoFormer 为 -0.134 dB（$[-0.327, 0.125]$），Oracle−BS-RoFormer 为 -0.096 dB（$[-0.238, 0.034]$）；Oracle−Forecast 仅为 $+0.039$ dB（$[-0.090, 0.155]$）。错时与 persistence 条件相对 Zero 也没有显示正的平均收益。Oracle 的验证 SI-SDRi 比 BS-RoFormer 高（11.372 对 10.946 dB），但没有形成明确的留出优势。三个测试录音日使小效应仍未确定；30 频带 Oracle 拥有更丰富的真实信息，然而独立优化的 FiLM 模型不必按信息量形成性能排序。

a) 全波形 *Oracle* 的抄答案校验。*:* 为检验 E 的信息损失能否解释 30 频带结果，我们冻结同一已训练 BS-RoFormer，在 8,192 个训练混合上拟合逐采样点三系数融合头：

$$\hat{s}_t = w_b \hat{s}_{\text{BSR}}(x_t) + w_x x_t + w_c c_t. \tag{4}$$

初始系数 $(1, 0, 0)$ 精确复现 BSR，用最小二乘求波形均方误差的全局最优解。同一结构分别输入全零、错时背景及真实当前背景波形；验证与测试各用 4,096 个样本。测试 ID、SNR、混合 SI-SDR 及冻结 BSR 输出均与表 II 逐例核对。当 $c_t = N_t$ 时，学得系数数值上等于 $(0, 1, -1)$，即精确抄得 $x_t - N_t = s_t$。测试波形最大绝对误差为 5.96×10^{-8}；80.755 dB 的有限 SI-SDRi 由指标数值底噪限制。零条件与错时条件均未改善 SI-SDRi（表 III）。此处是有意使用非因果真值、且接口不同的信息量和答案通路校验；它不是匹配架构的 FiLM 消融，也不证明 30 频带历史预测可以恢复相位对齐的当前背景波形。

b) Oracle 信息阶梯。*:* 我们固定冻结 BSR、三系数融合头、训练样本及 4,096 个匹配的测试混合，逐层压缩当前背景 N_t。在 2 kHz 音频上使用 512 点 Hann STFT（257 个频率 bin，帧步长 64 ms），将背景功率沿频率合并为 128/64/32 个等宽相邻组，或 128/64/48/30 个 20–950 Hz 对数频带；另沿时间合并为 0.25、1、5 秒。保留的幅度配合真实 N_t 相位或混合 x_t 相位做逆变换。边缘 bin 并入最近的对数带；名义 128 个对数带中，实际只有 95 个含 STFT bin。最粗的 30 频带/5 秒功率类似原始 $E(N_t)$，但数值定义并不完全相同。

图 2 显示这条固定答案通路在哪里失去留出收益。完整幅度改用混合相位，相对 BSR 仍提高 11.164 dB（日期分块区间 $[10.889, 11.594]$）。等宽 128 组仍提高 $+2.067$ dB（$[0.969, 3.386]$）；等宽 64 组为 -0.623 dB（$[-1.404, 0.259]$），可靠的正收益在这两级之间消失。对数 128 带已为 -0.529 dB（$[-1.257, 0.319]$），逐帧 30 带为 -0.672 dB（$[-1.323, 0.086]$）。即便逐帧 30 带保留真实背景相位，也仅提高 $+0.117$ dB（$[-0.671, 1.084]$）。相比之下，保留全部 257 个频率 bin、只把功率按 1 秒汇总并使用混合相位，仍提高 $+0.585$ dB（$[0.285, 1.132]$）；按整段 5 秒汇总则为 $+0.249$ dB（$[-0.044, 0.495]$）。因此在这一答案通路中，频率平均及其分带规则比单独汇总时间更容易使条件失效。这不构成信息论极限，也不是新增的 FiLM 消融。

C. 主实验：*128* 组逐帧残差条件

a) 训练后的高分辨率 *Oracle* 残差分离器。*:* 我们进一步在真正的 BS-RoFormer 中检验这一表示，而不是只使用冻结的线性抄答案头。当前实际背景 N_t 与混合 x_t 经 512 点、128 点帧移的 STFT，按 128 个等宽频率组取平均功率，形成保留时间维的 $\log|B_t|$；显式创新图在同一网格上定义为 $R_t = \log|X_t| - \log|B_t|$。将这两张图插值到 BSR 的帧网格后，通过零初始化线性投影加到由混合声音得到的子带 token，再送入轴向注意力。这是残差形式的 $[X_t, B_t, R_t]$ 输入，没有使用 FiLM 或预测器；训练前输出与普通 BSR 完全相同（最大波形差值为零）。

两种模型使用相同的按日期隔离 DCLDE 混合、骨干迁移初值、种子、批次顺序、6,000 次更新、AdamW/余弦日程、损失和验证最高分选点规则。原 BSR 选中第 5,300 步，新模型选中第 6,000 步。在 4,096 个匹配测试样本上，普通 BSR 的目标 SI-SDRi 为 9.631 dB，Oracle-Residual-BSR 为 16.767 dB；配对增益 $+7.136$ dB，按录音日分块的 95% 区间为 $[6.970, 7.282]$，三个留出日均为正。因此高分辨率当前背景与显式创新接口的组合在这个受控实验中确实有用。部署时无法获得真实 N_t；这项双模型可行性比较也没有单独排除新增适配器参数量的影响。

b) 因果高分辨率残差条件。*:* 随后将当前背景的 Oracle 图换成严格由过去 60 秒得到的两种条件。历史由 12 个 5 秒窗组成，每窗均为 79×128 的对数幅度图。与事件标注重叠的窗被掩蔽；若某个位置缺失，只从这 60 秒内选择距离最近的无事件窗填入。68,075 个合格当前窗中有 235 个受到这种填补影响。Persistence 直接使用最后一个干净历史图；轻量 GRU 先将每张图汇聚为四个时间块，处理 12 个历史步，再解码对 Persistence 的残差修正，输出完整的未来 79×128 背景对数幅度图；预测时不读取当前波形。预测器在训练日的干净背景上更新 3,000 次，按验证集对数幅度 MAE 选点并冻结。GRU 的验证 MAE 为 0.5456，Persistence 为 0.5518，相对下降 1.12%。在留出测试日上，对应的背景图 MAE 分别为 0.5308 和 0.5386。

对每种背景条件图 B，计算 $R = \log|X_t| - B$，将 $[X_t, B, R]$ 送入与 Oracle 完全相同的残差适配器。Zero 在每帧重复训练集固定的逐频组平均对数背景；Shuffled 使用另一录音日的标注干净 B_j：训练和测试各自在本划分内抽样；验证集仅有一天，因此从训练日取错误背景。Persistence 使用最后一个干净历史图，Forecast 使用冻结 GRU 输出。四路分离器共享迁移 BSR 骨干和零初始化适配器，初始波形输出与普通 BSR 完全相同；合成目标、训练样本顺序、6,000 次更新、优化器、损失、验证最高分选点规则、留出混合均相同。四路只改变条件图 B 的来源。

表 IV 分开了接口与背景信息的作用。Zero 比普通 BSR 高 $+2.525$ dB（按录音日配对的 95% 区间 $[2.262, 2.701]$），Shuffled 高 $+2.313$ dB（$[2.027, 2.905]$），因此不能把因果模型相对 BSR 的全部提升归因于正确历史。Zero 与 BSR 的差异同时包含新增适配器和创新通路中的当前混合对数谱，尚不能单独量化参数量的作用。固定适配器后，

TABLE II
前期 30 频带 FiLM 审计：4,096 个匹配的标注干净 5 秒背景与合成事件。数值为目标 SI-SDRi（dB）；方括号是按留出录音日配对 bootstrap 的 95% 区间。只有 30 频带 Oracle 使用 $E(N_t)$。

模型	验证	测试	相对 BSR Δ [95% 区间]	相对 Zero Δ [95% 区间]
BS-RoFormer	10.946	9.631	0	$+0.0002$ $[-0.009, 0.007]$
Zero-condition FiLM	10.967	9.631	-0.0002 $[-0.007, 0.009]$	0
Shuffled-condition FiLM	10.609	9.526	-0.105 $[-0.247, 0.020]$	-0.105 $[-0.256, 0.026]$
Persistence-condition FiLM	11.205	9.524	-0.107 $[-0.239, 0.083]$	-0.107 $[-0.232, 0.084]$
GRU-Forecast FiLM (FC-BSR)	11.213	9.497	-0.134 $[-0.327, 0.125]$	-0.134 $[-0.320, 0.125]$
30 频带 Oracle-FiLM, $E(N_t)$	11.372	9.535	-0.096 $[-0.238, 0.034]$	-0.095 $[-0.231, 0.035]$

TABLE III
与主实验相同的 4,096 个 DCLDE 测试混合上的全波形抄答案校验。目标 SI-SDRi 及相对冻结 BSR 按日期配对的差值（dB）。

冻结 BSR + 拟合融合头	SI-SDRi	Δ [95% 区间]
BSR；初始 $(1, 0, 0)$	9.631	0
全零波形	9.231	-0.400 $[-0.483, -0.269]$
错时背景波形	9.231	-0.400 $[-0.483, -0.269]$
当前实际 N_t 波形	80.755	$+71.124$ $[69.945, 72.081]$
解析式 $x_t - N_t$	80.755	$+71.124$ $[69.945, 72.081]$

TABLE IV
4,096 个干净背景 DCLDE 混合上的匹配测试。五路残差模型共用相同的 128 频组适配器；Zero 使用训练集固定均值，Shuffled 使用另一录音日背景。只有 Oracle 使用当前真值。数值为目标 SI-SDRi 均值（dB）。

条件	SI-SDRi	相对 BSR 增益
BSR（仅混合）	9.631	—
Zero-Residual	12.156	+2.525
Shuffled-Residual	11.944	+2.313
Persistence-Residual	14.295	+4.664
GRU-Forecast-Residual	14.351	+4.720
Oracle-Residual	16.767	+7.136

Persistence 比 Zero 高 $+2.138$ dB（$[1.775, 2.377]$），比错日 Shuffled 高 $+2.351$ dB （$[1.571, 2.661]$）；三个测试日均为正。这表明与当前时刻相关的历史背景确实提供了超出结构和任意背景图的信息。Forecast 相对 Persistence 仅提高 $+0.056$ dB（$[0.036, 0.074]$），虽三日同向，幅度仍小。Forecast 恢复了 Oracle 相对 BSR 增益的 66.1%，与 Oracle 仍差 2.416 dB （$[2.114, 2.640]$）。

D. 次级消融：预测时间尺度与未标注背景强度

以下实验来自 SanctSound 或未标注连续 WAV，不是干净背景主实验。时间尺度诊断固定相同留出样本；5 秒预测器的验证 MAE 为 1.366 dB，略优于 persistence 的 1.386 dB，其余尺度选择 persistence。这项结果仅说明该消融域中 5 秒特征的预测略有优势，不能替代主设置的留出全参考检验。

另一个未标注 SanctSound WAV 消融在 1152 个配对测试混合上比较零条件 FiLM、当前真值频谱 oracle、因果预测和错时条件。这里的 oracle 属于次级数据域；表 II 中的主域 30 频带 Oracle 使用标注干净 DCLDE 的实际 N_t 提取 $E(N_t)$。跨训练 SNR 平均后，零条件 FiLM 为 23.470 dB，Forecast-FC-BSR 为 22.871 dB （$\Delta = -0.599$，区间 $[-0.851, -0.346]$），oracle 平均值也更低。这暴露了简单分辨率诊断没有显示的条件化/容量影响。图 4 进一步表明：

TABLE V
真实背景上的预测分辨率诊断。

步长	预测器	条件模型	基线	增益 [95% 区间]
5 秒	GRU	29.753	28.527	1.226 [1.082,1.381]
30 秒	persistence	29.630	28.534	1.095 [0.935,1.265]
1 分钟	persistence	29.661	28.533	1.128 [0.971,1.298]
10 分钟	persistence	29.711	28.535	1.176 [1.036,1.326]

条件模型、基线与增益均为目标 SI-SDRi（dB）。

在 $-18, -15, -12, -9, -6$ dB，预测条件分别提高 0.728、0.643、0.525、0.366、0.157 dB；从 -3 dB 开始转为落后。错时条件对最弱目标也有收益，却随 SNR 上升迅速退化，因此不能把弱目标增益完全归因于预测的时间准确性；正则化或额外容量仍是可能解释。

E. 没有分离真值的真实事件

参考学习式无参考指标 [24], [25] 和语义音频嵌入 [26], [27]，我们训练、校准并冻结二分类器；测试 AUROC、AP 与 F1 分别为.9723、.9755、.9275。混合一致性要求 $\hat{N} = x - \hat{s}$。将 $\hat{s}$ 按 $\{-60, -30, -24, -18, -12, -6, 0\}$ dB 逐级恢复，检查事件概率是否单调回升；Identity 与 all-to-event 排除平凡解，标注区间外变化审计背景保留。

本次直接评估冻结的四个 128 频组残差模型，样本与前期 FiLM 审计的 103 个测试鲸声完全相同。每段历史只包含同一 WAV 中严格早于当前的 12 张标注干净背景图；6 段各缺 1 张，在过去 60 秒内部用最近干净窗填补。Zero 使用训练均值，Shuffled 使用另一测试日的干净背景，Persistence 使用最后一张历史图，Forecast 将历史送入冻结 GRU；条件均不读取当前鲸声。表 VI 与图 6 给出结果。

相对 Zero，Persistence 使 $p(\hat{N})$ 下降 .0624（按日配对 95% 区间 $[-.0682, -.0547]$），$p(\hat{s})$ 上升 .0469（$[.0198, .1006]$），区间外变化下降 .0255（$[-.0386, -.0077]$）；Forecast 与 Zero 比较也同向，$p(\hat{N})$ 差为 $-.0531$，区间外变化差为 $-.0260$。但错日 Shuffled 的 $p(\hat{N})$ 比两种因果条件更低、$p(\hat{s})$ 更高：Persistence 减 Shuffled 分别为 $+.0471$（$[.0317, .0706]$）与 $-.0606$（$[-.0731, -.0404]$）。Persistence 的区间外改动则显著更小，差为 $-.0408$（$[-.0519, -.0320]$）。四路单调率都接近饱和，区分力很弱。因此分类器概率没有重现受控全参考实验的排序：它可能奖励更激进的事件提取，而因果条件更好地保留了事件区间外音频。真实隔离声轨仍不可得。

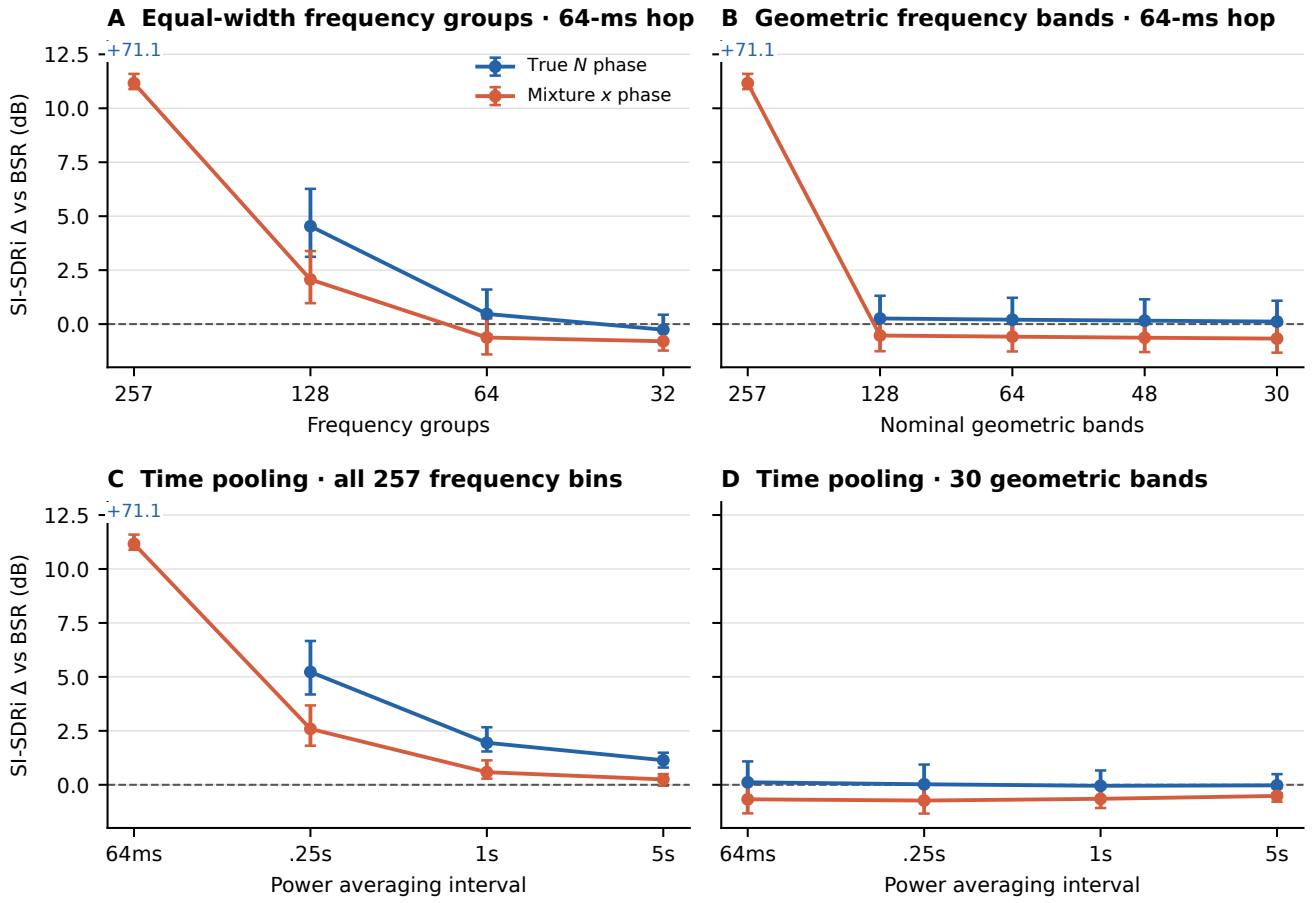


Fig. 2. 同一组 DCLDE 测试混合上的当前背景 Oracle 信息阶梯。每个点在训练混合上拟合相同结构的三系数答案头；误差棒为相对冻结 BSR 的 SI-SDRi 按日期配对的 95% 区间。完整分辨率且使用真实相位的 N_t 提高 71.1 dB，超出绘图范围；混合相位是独立的信息损失。阈值依赖分带方式和当前答案接口。

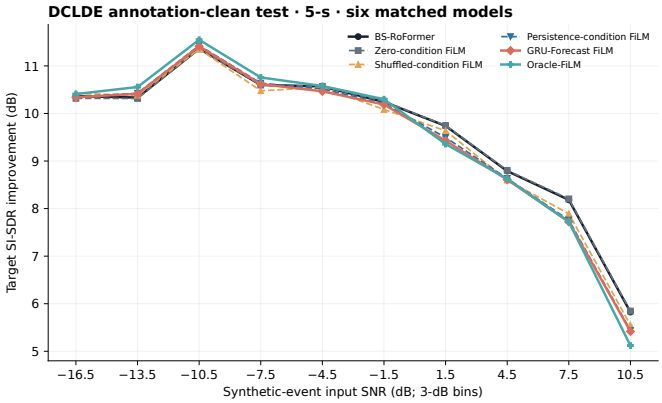


Fig. 3. 标注干净 DCLDE 背景上的前期 30 频带 FiLM 审计：六路匹配模型按 3-dB 输入 SNR 分组的目标 SI-SDRi 均值。总体平均的日期分块区间见表 II。

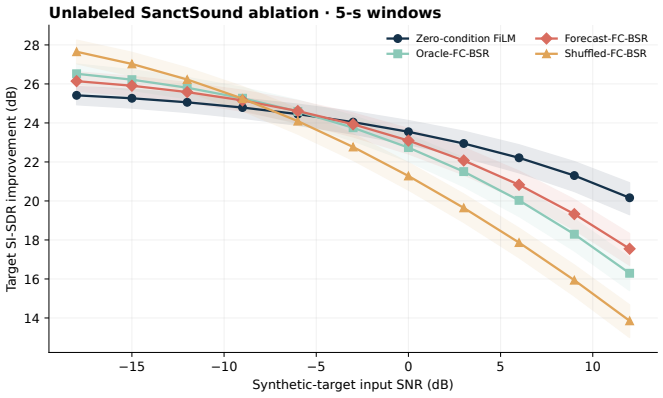


Fig. 4. 未标注 SanctSound WAV 消融：5 秒目标强度扫描。曲线为四种条件，阴影为配对 95% 区间；该图不是标注干净主实验。

F. 分类器底噪与合成目标覆盖

为解释较高的 $p(\hat{N})$，我们先把标注干净的测试音频送入同一冻结分类器，并截成与分离输出相同的 9,984 个采

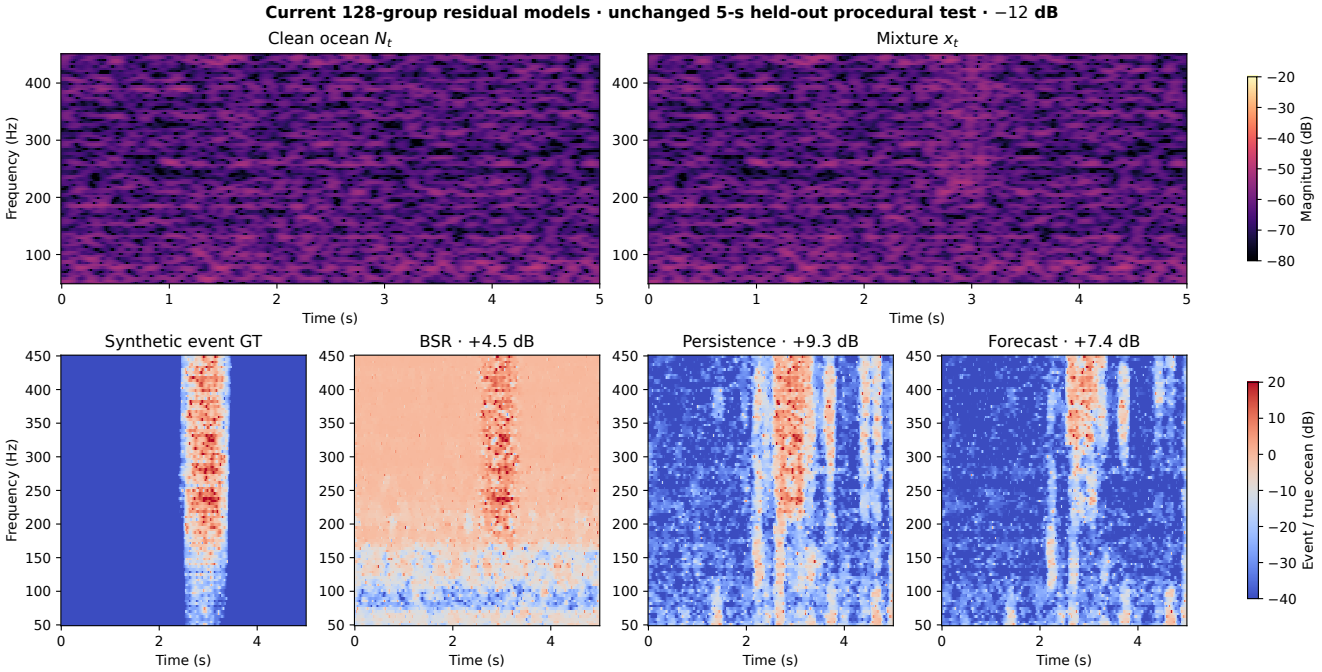


Fig. 5. 当前 128 组残差分离器在未改动的留出程序合成鲸声脉冲包上的结果（−12 dB，5 秒）；从 96 个固定样本中按三种模型 SI-SDRi 的联合中位数选例。海洋背景与混合声音共用绝对幅度色标；下排事件声轨共用相对真实背景幅度的 dB 色标。与普通 BSR 相比，Persistence 和 Forecast 明显压低非目标海洋成分，但仍存在局部竖向伪影。对全部 96 个样本，真值目标缺失的时频格点上，BSR、Persistence、Forecast 的事件声轨相对海洋背景对比度中位数分别为 −1.37、−31.44、−36.46 dB。该受控合成指标不能代表真实鲸声的隔离保真度。

TABLE VI
同一批 103 个真实鲸声上的冻结 128 频组残差模型比较。四路使用相同混合声音；没有真实分离声轨。区间外指标为标注外背景相对改动。

方法	$p(x)$	$p(\hat{N})\downarrow$	$p(\hat{s})\uparrow$	单调率 ↑	区间外 ↓
Zero-Residual	.909	.891	.802	.990	.062
Shuffled-Residual	.909	.781	.910	.989	.078
Persistence-Residual	.909	.829	.849	.992	.037
GRU-Forecast-Residual	.909	.838	.842	.989	.036

样点。按测试日比例抽取的 4,096 个干净窗平均事件概率为 .153；与 103 个真实事件同 WAV、紧邻事件之前的干净窗为 .176；两组中位数均为 .093。真实混合平均为 .909，四路分离背景的 .781–.891 显著高于干净对照；逐例减去同 WAV 干净对照后的平均差为 .606–.715。该差距说明分类器底噪不能独自解释高响应，但不能换算为泄漏的鲸声能量；分离伪影或漏标事件也可能触发分类器。

我们在每个配对干净窗上按训练时的五种鲸声类型与 $[-18, 12]$ dB 强度范围合成 32 条混合，共 3,296 条，其平均事件概率为 .407。覆盖代理指标取冻结分类器倒数第二层的 64 维激活，并从有事件片段中减去同 WAV 的干净背景激活，按合成样本方差逐维缩放。真实事件之间留一最近邻的中位距离为 .233。若在全部 3,296 条合成样本中搜索，真实到合成的中位距离为 .262，但候选数过多。每轮每个真实事件只取一条合成样本，凑成等量的 103 条；重复 32 轮后，中位最近邻距离为 .483，是真实到真实距离的 2.08 倍。超过真实最近邻距离第 95 百分位阈值的事件比例中位数为 51.5%；使用全部合成样本时只有 3.9%。因此合成样本在等量、分类器依赖的表征中对真实事件的覆盖较稀疏，值得改进目标采样；但没有真实隔离鲸声，真实背景相对前一干净窗的变化也进入该嵌入差；此指标或检测概率都不能单独确定分离背景高响应的物理原因。

G. 训练日目标校准与覆盖验收

我们只用三个训练日拟合目标形态。2798 个标注事件窗中，2616 个在同一 WAV 内找到前后干净参考且具有足够声学超额。对局部背景对数谱插值后，取标注时段及 40–950 Hz 内混合减背景的正超额，平滑成软掩码，并使用混合相位逆变换，得到伪鲸声轨；它不是隔离真值。训练事件提供时长、频率界与轨迹、扫频斜率和曲率、带宽、谐波数与衰减、振幅包络、频率抖动、脉冲间隔和事件数。经验程序合成路线对同一个真实鲸声轮廓联合样本作轻微

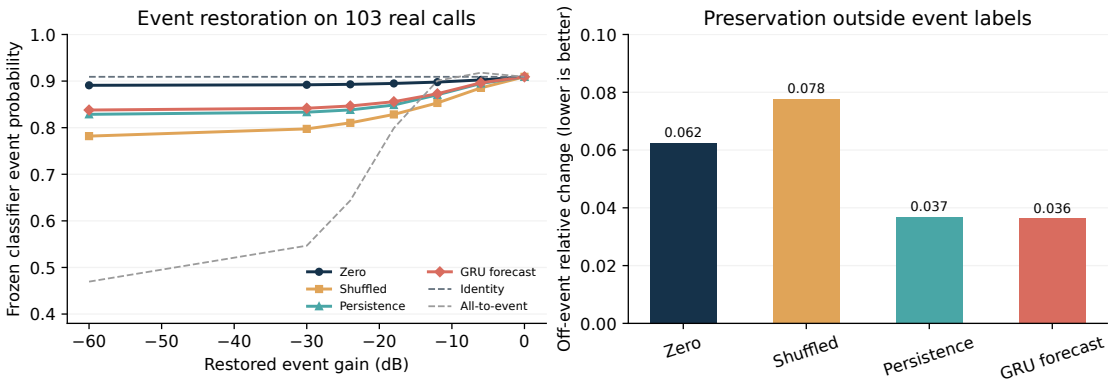


Fig. 6. 四路匹配残差模型的冻结分类器恢复曲线与区间外保留。Identity 和 all-to-event 为平凡解对照。错日 Shuffled 的事件概率更强，但对标注事件区间外音频的改动大于两种因果条件。

扰动，同时保留原有的船舶音调与空化噪声；船噪占程序路线的 4/7，使总鲸声/船噪比例在期望上与旧训练池一致。另一条路线随机化伪真实声轨的时刻与相位。两路各占新目标池的一半。留出分类器不参与参数拟合或样本筛选。

在相同的 103 个真实事件、32 轮每轮等量候选协议下，新池每轮均包含约一半经验程序目标和一半伪真实目标。真实到目标的中位最近邻距离从 .483 降至 .322；超过真实近邻第 95 百分位阈值的比例中位数从 51.5% 降至 3.4%，32 轮距离均改善，达到预设训练验收条件。冻结分类器对新混合的平均响应从 .407 升至 .647，但这只是外部诊断，不能充当优化目标或声轨保真的证据。

H. 目标池修订后的分离

我们用相同迁移初始化与验证选点规则，各训练 Persistence 与 Forecast 残差分离器 6000 步；背景 GRU 与事件分类器始终冻结。表 VII 与原版严格配对。在同一批真实鲸声上，新 Persistence 的 $p(\hat{N})$ 降低 .1766（按录音日配对 95% 区间 $[-.1920, -.1479]$），$p(\hat{s})$ 提高 .0668（$[.0414, .1166]$）；新 Forecast 的两项变化分别为 $-.1129$ 和 $+.0527$。但区间外改动分别增加 .0215（$[.0151, .0324]$）和 .0068（$[.0002, .0132]$）。新 Persistence 的事件提取更强，新 Forecast 更好地保留标注区间外音频。对完全不变的旧合成测试，SI-SDRi 分别下降 2.100 与 2.620 dB。目标池修订后，冻结 GRU 也没有胜过 Persistence。保留船噪避免了中间鲸声专用池在船舶音调上的严重退化，但旧鲸声代理分数并未保持。新 $p(\hat{N})$ 仍明显高于配对干净背景的 .176。没有真实隔离声轨，这些结果说明目标分布改变了分类器响应，不能证明真实分离波形全面改善。

为单独检查优化程度，我们固定小训练集：相同损失和骨干下，128 个旧程序目标在 3000 步内的训练 SI-SDRi 从 13.85 升至 17.20 dB；128 个经验目标在 20000 步内从 10.57 升至 15.56 dB，末端 SI-SDRi 已明显趋缓；目标缺失区的事件/海洋对比度中位数却从 -32.85 降至 -60.68 dB。这表明受控混合的剩余误差不能简单归结为背景泄漏。随后从原本较强的 Persistence 权重出发，以原学习率的十分之一依次使用 0%、25%、50% 伪真实目标。训练日伪声轨按 80/20 划分，旧程序与留出经验目标各有固定验证套。联合验证选择 25% 阶段的第 6500 步：两套 SI-SDRi 从 16.26/11.12 升至 16.44/11.84 dB。再单独训练 50% 阶段 4000 步虽使目标缺失区更暗，联合 SI-SDRi 却下降。选中模型在不变旧合成测试上为 14.421 dB，但真实鲸声的 $p(\hat{N})/p(\hat{s}) = .819/.823$，没有保住 50/50 模型的 .652/.916。因此延长训练能提高小集拟合并避免旧域遗忘，却不能独自解决真实目标取舍。在固定的 128 个训练混合上，小权重 SI-SDR 附加项比原损失多得 .40 dB；但按相同初始化训练完整数据的 50% 阶段 4000 步，两套验证集的联合分数未超过起点，因此保留原损失。当前受控泄漏审计也不支持继续强化目标缺失区惩罚。

IV. 讨论与结论

主域 30 频带 Oracle 只诊断当前接口：FiLM 即使得到当前实际干净波形的 $E(N_t)$，留出平均值仍未超过无条件 BS-RoFormer，且配对区间跨零。全波形抄答案校验则精确成功，因此这一负结果不能说明真实背景没有可用信息；30 频带压缩与 FiLM 注入各自的影响仍未分清。固定融合头的信息阶梯进一步显示：等宽 128 频组或全频 bin 的 1 秒功率汇总仍能产生确定的收益，等宽 64 组和 30 个对数频带则没有。然而原 FiLM 结果不能仅归因于这一断点，因为接口并不相同。训练后的 128 组 Oracle-Residual-BSR 在留出混合上提高 $+7.136$ dB，说明真实高分辨率背景与显式创新可以帮助 BSR 骨干。将当前背景真值换成过去 60 秒的 Persistence 或冻结 GRU 预测后，相对 BSR 仍分别有 $+4.664$ 和 $+4.720$ dB 增益。固定均值 Zero 与错日 Shuffled 也分别提高 $+2.525$ 和 $+2.313$ dB，说明扩大输入接口解释了部分相对 BSR 的收益。固定这个接口后，Persistence 仍比 Zero 高 $+2.138$ dB、比 Shuffled 高 $+2.351$ dB：正确时刻的历史信息确实有价值。预测相对 Persistence 在三个测试日上稳定但仅提高 $+0.056$ dB；距 Oracle 还有 2.416 dB，说明更好的因果先验仍有空间。Zero 对照仍无法区分参数容量与创新通路提供当前混合对数谱的作用；合成目标监督及仅三个留出日限制了外推。Zero-FiLM 与无条件骨干几乎重合，Forecast 也没有超过 Zero 或 Shuffled 的明确证据。因此不能把预测误差单独认定为瓶颈；5 秒静态 30 维频带摘要与 FiLM 接口可能不足以对齐分离器的时频 token。FiLM 在频谱代理消融中仍是最好的接口，未标注 WAV 强度消融也显示弱目标收益，但两者都不能证明主域增益。新的真实鲸声审计呈现权衡：两种因果条件相对 Zero 改善事件概率和区间外保留，但错日 Shuffled 在两项

TABLE VII
目标池修订后同一批真实事件上的冻结评估，以及完全不变的旧合成测试 SI-SDRi。课程阶段按两套独立验证集选点；128 频组接口与背景预测器均固定。

条件	训练目标	旧合成 SI-SDRi (dB)	真实 $p(\hat{N})\downarrow$	真实 $p(\hat{s})\uparrow$	区间外 ↓
Persistence	原程序目标	14.295	.829	.849	.037
Persistence	50/50 经验目标	12.195	.652	.916	.058
Persistence	课程微调（25% 伪真实）	14.421	.819	.823	.037
GRU Forecast	原程序目标	14.351	.838	.842	.036
GRU Forecast	50/50 经验目标	11.731	.725	.895	.043

事件分类概率上胜出，同时明显损害区间外保留；Forecast 对 Persistence 也并非全面胜出。因此真实事件尚未证明正确历史提高了语义分离，而是揭示了代理分类器下的事件检测与背景保留权衡。旧 30 频带 FiLM 真实事件对照仍属前期实验。只有三个留出录音日，且没有真实隔离声轨，限制了该结论。干净对照排除了“分类器普遍底噪过高”作为 $p(\hat{N})$ 的唯一解释；等量嵌入距离显示分类器空间内的合成到真实目标覆盖缺口。训练日目标采样明显缩小了该覆盖缺口，并改善真实事件的两项分类器概率；但区间外改动增加、旧合成域 SI-SDRi 下降，故不是全面分离提升。现有证据仍不能将目标失配与分离伪影、标注不确定性完全分开。

既有 30 频带 FiLM 前端可用于实验检查：在已准备历史特征的 CPU 冒烟测试中，单个 5 秒块 RTF 为 0.014；界面可显示预测并试听、下载两条估计声轨，但尚未部署新的 128 组残差模型，也不等于野外部署。下一步应在目标域适配时更好地保留背景，检验其他目标池与站点，待目标稳健性成立后再提高背景预测对事件相关时频结构的辨别能力；还应为真实事件获取隔离声轨或更强局部参考。分类器恢复曲线是语义迁移证据，不能替代波形保真真值。

References

[1] J. L. Miksis-Olds, D. L. Bradley, and X. M. Niu, “Decadal trends in indian ocean ambient sound,” *Journal of the Acoustical Society of America*, vol. 134, no. 5, pp. 3464–3475, 2013.

[2] Y. Luo and N. Mesgarani, “Conv-TasNet: Surpassing ideal time–frequency magnitude masking for speech separation,” *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, vol. 27, no. 8, pp. 1256–1266, 2019.

[3] Y. Luo, Z. Chen, and T. Yoshioka, “Dual-path RNN: Efficient long sequence modeling for time-domain single-channel speech separation,” in *Proc. IEEE ICASSP*, 2020, pp. 46–50.

[4] C. Subakan, M. Ravanelli, S. Cornell, M. Bronzi, and J. Zhong, “Attention is all you need in speech separation,” in *Proc. IEEE ICASSP*, 2021, pp. 21–25.

[5] Z.-Q. Wang, S. Cornell, S. Choi, Y. Lee, B.-Y. Kim, and S. Watanabe, “TF-GridNet: Integrating full- and sub-band modeling for speech separation,” in *Proc. IEEE ICASSP*, 2023, pp. 1–5.

[6] Y. Luo and J. Yu, “Music source separation with band-split RNN,” *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, vol. 31, pp. 1893–1901, 2023.

[7] W.-T. Lu, J.-C. Wang, Q. Kong, and Y.-N. Hung, “Music source separation with band-split RoPE transformer,” *arXiv preprint arXiv:2309.02612*, 2023. [Online]. Available: https://arxiv.org/abs/2309.02612

[8] S. Rouard, F. Massa, and A. Défossez, “Hybrid transformers for music source separation,” in *Proc. IEEE ICASSP*, 2023, pp. 1–5.

[9] S. Wisdom, E. Tzinis, H. Erdogan, R. J. Weiss, K. Wilson, and J. R. Hershey, “Unsupervised sound separation using mixture invariant training,” in *Advances in Neural Information Processing Systems*, vol. 33, 2020, pp. 3846–3857.

[10] E. Perez, F. Strub, H. de Vries, V. Dumoulin, and A. Courville, “FiLM: Visual reasoning with a general conditioning layer,” in *Proc. AAAI Conference on Artificial Intelligence*, vol. 32, no. 1, 2018.

[11] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, “Attention is all you need,” in *Advances in Neural Information Processing Systems*, vol. 30, 2017.

[12] H. Zhao, C. Gan, A. Rouditchenko, C. Vondrick, J. McDermott, and A. Torralba, “The sound of pixels,” in *Proc. European Conference on Computer Vision*, 2018, pp. 570–586.

[13] D. Salinas, V. Flunkert, J. Gasthaus, and T. Januschowski, “DeepAR: Probabilistic forecasting with autoregressive recurrent networks,” *International Journal of Forecasting*, vol. 36, no. 3, pp. 1181–1191, 2020.

[14] B. N. Oreshkin, D. Carpov, N. Chapados, and Y. Bengio, “N-BEATS: Neural basis expansion analysis for interpretable time series forecasting,” in *International Conference on Learning Representations*, 2020.

[15] A. Zeng, M. Chen, L. Zhang, and Q. Xu, “Are transformers effective for time series forecasting?” in *Proc. AAAI Conference on Artificial Intelligence*, vol. 37, no. 9, 2023, pp. 11 121–11 128.

[16] Y. Nie, N. H. Nguyen, P. Sinthong, and J. Kalagnanam, “A time series is worth 64 words: Long-term forecasting with transformers,” in *International Conference on Learning Representations*, 2023.

[17] T. Gneiting, “Making and evaluating point forecasts,” *Journal of the American Statistical Association*, vol. 106, no. 494, pp. 746–762, 2011.

[18] J. Lin, “Divergence measures based on the shannon entropy,” *IEEE Transactions on Information Theory*, vol. 37, no. 1, pp. 145–151, 1991.

[19] D. Gillespie, M. Caillat, and J. Gordon, “DCLDE 2013 workshop dataset,” 2019.

[20] Y. Shiu, K. J. Palmer, M. A. Roch, E. Fleishman, X. Liu, E.-M. Nosal, T. Helble, D. Cholewiak, D. Gillespie, and H. Klinck, “Deep neural networks for automated detection of marine mammal species,” *Scientific Reports*, vol. 10, p. 607, 2020.

[21] NOAA Office of National Marine Sanctuaries and U.S. Navy, “SanctSound raw passive acoustic data,” NOAA NCEI dataset, 2020.

[22] E. Vincent, R. Gribonval, and C. Févotte, “Performance measurement in blind audio source separation,” *IEEE Transactions on Audio, Speech, and Language Processing*, vol. 14, no. 4, pp. 1462–1469, 2006.

[23] J. Le Roux, S. Wisdom, H. Erdogan, and J. R. Hershey, “SDR—half-baked or well done?” in *Proc. IEEE ICASSP*, 2019, pp. 626–630.

[24] K. Kilgour, M. Zuluaga, D. Roblek, and M. Sharifi, “Fréchet audio distance: A reference-free metric for evaluating music enhancement algorithms,” in *Proc. Interspeech*, 2019, pp. 2350–2354.

[25] E. M. Grais, H. Wierstorf, D. Ward, R. D. Mason, and M. D. Plumbley, “Referenceless performance evaluation of audio source separation using deep neural networks,” in *Proc. European Signal Processing Conference*, 2019.

[26] Y. Wu, K. Chen, T. Zhang, Y. Hui, M. Nezhurina, T. Berg-Kirkpatrick, and S. Dubnov, “Large-scale contrastive language–audio pretraining with feature fusion and keyword-to-caption augmentation,” in *Proc. IEEE ICASSP*, 2023, pp. 1–5.

[27] X. Xiao, H. Jin, Z. Chen, A. Gram, G. Wichern, and J. Le Roux, “A reference-free metric for language-queried audio source separation using contrastive language–audio pretraining,” in *Proc. DCASE Workshop*, 2024.